

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



03

QUINZENA 1

O CUSTO INVISÍVEL DA IA

03

QUINZENA 1

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

O CUSTO INVISÍVEL DA IA

INTRODUÇÃO

Quando você abre um aplicativo de IA e digita uma pergunta, a interação parece instantânea e sem peso. A resposta chega em segundos, o aplicativo é gratuito e não há nenhuma indicação de custo visível. Este material torna visível o que o *design* da interface esconde: uma cadeia longa de infraestrutura física, consumo de energia, uso de água e trabalho humano que sustenta cada resposta que você recebe.



ORIGEM DO MATERIAL

O conteúdo deste *e-book* articula as evidências apresentadas no Módulo 1 do Workshop Fulbright sobre IA na Educação em Engenharia (Katz *et al.*, 2025) com três obras de referência: *Atlas of AI*, de Kate Crawford (2021); *Ghost work*, de Mary Gray e Siddharth Suri (2019); e os relatórios da Agência Internacional de Energia (IEA, 2024). Todos os dados numéricos desta seção têm fonte identificada; estimativas que não puderam ser verificadas são marcadas como tal.

1. A ILUSÃO DA IMATERIALIDADE

Kate Crawford (2021), pesquisadora do AI Now Institute da NYU e do CSIRO australiano, abre seu livro *Atlas of AI* com uma visita a uma mina de lítio no deserto do Atacama, no Chile. A escolha é intencional: a ideia de que a inteligência artificial (IA) é uma tecnologia sem corpo, etérea, que existe apenas no espaço digital, começa a desmoronar quando se percebe que todo sistema de IA começa com mineração de terras-raras, fabricação de *chips* em fábricas de semicondutores e construção de instalações físicas de enorme escala. Crawford (2021) chama esse conjunto de pressupostos o “mito da imaterialidade”: a crença de que computação é imaterial, *clean*, sem consequências físicas. Os dados que ela e outros pesquisadores reuniram contradizem esse mito de forma verificável.

A consequência prática do mito da imaterialidade é que os usuários de IA tomam decisões de uso sem informação sobre as externalidades reais dessas escolhas. Quando uma empresa decide treinar um modelo de linguagem proprietário para uma aplicação interna, geralmente não está incluindo no cálculo de custo o consumo de energia correspondente, a pegada hídrica ou o trabalho humano envolvido na curadoria dos dados. Isso não é desonestidade: é consequência de uma convenção técnica e de mercado que torna esses custos invisíveis. A primeira dimensão de literacia em IA, segundo o *framework* de Almatrafi *et al.* (2024), é reconhecer sistemas de IA. Uma extensão necessária para isso é reconhecer os custos que esses sistemas carregam.

2. DATA CENTERS: A INFRAESTRUTURA FÍSICA

Modelos de linguagem grande, como o GPT-4 (OpenAI), o Claude (Anthropic) e o Gemini (Google), não rodam no dispositivo que você usa. Eles rodam em *data centers*: instalações industriais com dezenas de milhares de servidores de alto desempenho, sistemas de refrigeração contínua, geradores de *backup* e conexões de rede de altíssima capacidade. Um único *rack* de servidores modernos com GPUs de alto desempenho, como os que executam inferência de LLMs, pode consumir entre 10 e 30 quilowatt de energia, o equivalente ao consumo de 10 a 30 residências. Um *data center* de grande escala pode ter centenas de *racks*.

O calor gerado por esse processamento precisa ser dissipado. Os métodos de resfriamento variam: resfriamento a ar (o mais comum), resfriamento a água (mais eficiente energeticamente, mas com alto consumo hídrico) e resfriamento líquido

de imersão (mais eficiente ainda, mas ainda em escala limitada). A Microsoft (2022) reportou consumo de 6,4 bilhões de litros de água para refrigeração de seus *data centers* em 2022, parte significativa relacionada à expansão da infraestrutura para IA. O Google (2023) reportou 5,6 bilhões de litros no mesmo ano. Esses números são relevantes especialmente em regiões com escassez hídrica, onde a instalação de *data centers* entra em conflito com necessidades locais de abastecimento.

3. CONSUMO DE ENERGIA: O PESO DO TREINAMENTO E DA INFERÊNCIA

O ciclo de energia de um sistema de IA tem dois momentos muito diferentes em escala: o treinamento, que acontece uma ou poucas vezes e é extremamente intensivo, e a inferência, que acontece a cada consulta e é individualmente barata, mas acumula em escala. Compreender essa distinção é importante para avaliar o impacto real de diferentes decisões de *design*.

Atividade	Consumo estimado de energia	Fonte verificada
Uma busca no Google	~0,0003 kWh por consulta	Google, 2023
Uma consulta a um LLM (ex.: ChatGPT)	0,001 a 0,01 kWh (estimativa; OpenAI não divulga dados)	AI Power [...], 2024; Patterson <i>et al.</i> , 2022
Treinamento do GPT-3 (2020)	1.287 MWh (≈ 552 toneladas de CO ₂)	Patterson <i>et al.</i> , 2022
Data centers de IA no mundo (2024)	~200 TWh/ano; projeção de ~500 TWh em 2026	IEA, 2024
Consumo de água da Microsoft para refrigeração (2022)	6,4 bilhões de litros	Microsoft, 2022
Consumo de água do Google para refrigeração (2022)	5,6 bilhões de litros	Google, 2023

O CUSTO DE TREINAR UM MODELO

Patterson *et al.* (2022), em artigo publicado na *Communications of the ACM*, estimaram que treinar o GPT-3, versão anterior ao GPT-4, emitiu aproximadamente 552 toneladas de CO₂ equivalente, considerando o mix energético dos *data centers* usados. Para contexto: um voo transatlântico de ida e volta (São Paulo–Nova York) emite cerca de 2 toneladas de CO₂ por passageiro. O treinamento do GPT-3 equivale a cerca de 276 voos desse tipo. As versões subsequentes, como o GPT-4,

tiveram seus custos de treinamento não divulgados publicamente pela OpenAI, mas estimativas independentes (Rahman; Owen; You, 2024) sugerem custos computacionais significativamente maiores.

A Agência Internacional de Energia (IEA, 2024), em seu relatório *Electricity 2024*, projetou que os *data centers* especializados em IA consumirão cerca de 200 TWh de energia elétrica em 2024, com projeção de chegar a 500 TWh em 2026. Para contexto, o Brasil inteiro consumiu cerca de 600 TWh em 2022 (EPE, 2023). O impacto climático desse consumo depende da matriz energética de onde os *data centers* estão localizados: *data centers* alimentados por energia renovável têm pegada de carbono muito menor do que os alimentados por carvão ou gás natural.

O CUSTO DE CADA INFERÊNCIA EM ESCALA

A inferência é o processo de usar um modelo já treinado para responder a uma consulta. Individualmente, o consumo é pequeno. Em escala, o efeito acumulado é expressivo. A Goldman Sachs (AI Power [...], 2024) estimou que uma consulta típica a um LLM consome entre 10 e 30 vezes mais energia do que uma busca equivalente no Google. Com centenas de milhões de consultas diárias nos principais modelos, o consumo acumulado se torna relevante. Essa comparação deve ser lida com cautela: o escopo e a complexidade das tarefas que um LLM realiza são diferentes das de uma busca, então a comparação não é simétrica. O ponto principal não é que LLMs são “piores” do que motores de busca: é que o custo de uma interação com IA é mais alto do que a interface gratuita e instantânea sugere.

4. GHOST WORK: O TRABALHO QUE A INTERFACE NÃO MOSTRA

CONCEITO

Ghost work, que em português é “trabalho fantasma”, é o termo criado pela pesquisadora Mary Gray (Microsoft Research) e pelo economista Siddharth Suri para descrever o trabalho humano invisível que sustenta sistemas de IA. No livro *Ghost work* (Gray; Suri, 2019), os autores documentam que plataformas digitais dependem de um exército de trabalhadores que realizam tarefas discretas de rotulagem, moderação e avaliação sem vínculo empregatício formal, sem benefícios trabalhistas e sem visibilidade pública.

Tipo de tarefa	O que envolve	Condições documentadas
Rotulagem de dados de treinamento	Identificar objetos em imagens, classificar sentimentos em textos, transcrever áudio	Pago por tarefa (microtask), frequentemente frações de centavo por item; sem benefícios trabalhistas (Gray; Suri, 2019)
Moderação de conteúdo	Revisar e classificar conteúdo explícito, violento ou abusivo para que não apareça em outputs do modelo	Trabalhadores no Quênia recebiam menos de US\$ 2/hora e relataram trauma psicológico por exposição a conteúdos perturbadores (Perrigo, 2023)
Avaliação de respostas (RLHF)	Comparar dois outputs de LLM e indicar qual é melhor, mais seguro ou mais preciso	Usado para ajustar modelos como o ChatGPT; trabalhadores precisam conhecer os critérios da empresa, mas têm pouco poder de negociação (Perrigo, 2023)

O CASO DOS TRABALHADORES DO QUÊNIA

Em janeiro de 2023, a revista *Time Magazine* publicou uma reportagem investigativa detalhando as condições de trabalho de moderadores de conteúdo contratados pela empresa Sama, que prestava serviços para a OpenAI no Quênia (Perrigo, 2023). Os trabalhadores eram pagos com menos de dois dólares por hora para revisar textos com conteúdo explícito de violência, abuso sexual e outros materiais perturbadores, necessário para que o modelo aprendesse a recusar tais solicitações. Vários trabalhadores relataram sintomas de estresse pós-traumático, e a empresa foi alvo de processo judicial. O caso tornou público o que havia sido até então uma dimensão invisível do desenvolvimento de LLMs: a moderação de conteúdo, etapa necessária para o ajuste fino de modelos generativos, envolve exposição humana a conteúdo extremamente perturbador em condições que raramente incluem suporte psicológico adequado.

Esse não é um problema isolado de uma empresa ou de um contrato específico. Gray e Suri (2019) documentaram padrões similares em múltiplas plataformas e países, argumentando que o modelo de negócios de *crowdwork* baseado em microtarefas cria sistematicamente condições de precariedade para os trabalhadores, independentemente da empresa contratante. A captura de dados para treinamento sem consentimento explícito, incluindo obras de artistas, textos de jornalistas e publicações acadêmicas obtidas por *scraping*, é outro ponto de conflito ativo, com processos judiciais em andamento nos EUA e na Europa.



PERGUNTA PARA REFLEXÃO

Quando você usa uma ferramenta de IA “de graça”, o que está sendo pago e por quem?

Mitchell Gerhardt levantou essa pergunta no Workshop Fulbright de 2025 (Katz *et al.*, 2025), e ela não é retórica. Os custos ambientais e os custos do trabalho humano existem independentemente de aparecerem na interface. Torná-los visíveis é parte do que significa usar tecnologia com consciência.

5. O QUE MUDA QUANDO VOCÊ SABE DISSO

O objetivo deste módulo não é produzir culpa pelo uso de ferramentas digitais; isso seria desproporcional e impraticável. É ampliar o quadro de referência com que você avalia tecnologias: de um quadro que só inclui a interface e o resultado imediato para um quadro que inclui a cadeia de produção, os custos externos e os grupos humanos envolvidos. Esse alargamento de quadro é o que o campo de estudos de ciência e tecnologia (*Science and Technology Studies* – STS) chama de “seguir os actantes”: rastrear o que sustenta um sistema além do que é visível para o usuário final (Latour, 2005).

Na prática, isso se traduz em perguntas concretas. Quando uma empresa avalia adotar um sistema de IA, o custo de inferência em escala (energia, água, infraestrutura) deve ser parte do cálculo. Quando um engenheiro decide se vai usar um modelo maior ou um modelo menor para uma tarefa, saber que modelos maiores consomem proporcionalmente mais energia é informação relevante. Quando uma organização cria uma política de uso de IA, considerar quais dados foram usados para treinar o modelo, em que condições foram coletados e como foram rotulados é parte da *due diligence* ética.

REFERÊNCIAS

As obras abaixo são verificáveis e estão disponíveis nas plataformas indicadas.

AI POWER demand: an accelerating growth story. **Goldman Sachs Research**, 2024.

ALMATRAFI, O. *et al.* Base dos seis níveis de literacia em IA: reconhecer, conhecer, usar, avaliar, criar, navegar eticamente. **AI Literacy Framework**, 2024.

CRAWFORD, K. **Atlas of AI**: power, politics, and the planetary costs of artificial intelligence. New Haven: Yale University Press, 2021.

EMPRESA DE PESQUISA ENERGÉTICA [EPE]. **Balanco Energético Nacional 2023**. Rio de Janeiro: EPE, 2023. Disponível em: <https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/balanco-energetico-nacional-2023>. Acesso em: 29 maio 2026.

GOOGLE. **Google Environmental Report 2023**. Mountain View: Google, 2023. Disponível em: <https://sustainability.google/reports/google-2023-environmental-report/>. Acesso em: 29 maio 2026.

GRAY, M.; SURI, S. **Ghost work**: how to stop Silicon Valley from building a new global underclass. New York: Houghton Mifflin Harcourt, 2019.

INTERNATIONAL ENERGY AGENCY [IEA]. **Electricity 2024**: analysis and forecast to 2026. Paris: IEA, 2024. Disponível em: <https://www.iea.org/reports/electricity-2024>. Acesso em: 29 maio 2026.

KATZ, B. *et al.* Integrating artificial intelligence into engineering education. *In*: WORKSHOP FULLBRIGHT., 2025, São Paulo. **Anais [...]**, São Paulo: Centro de Inovação da USP, 2025. Módulo 1: Gerhardt, M. Introduction to Generative AI.

LATOUR, B. **Reassembling the social**: an introduction to actor-network theory. Oxford: Oxford University Press, 2005.

MICROSOFT. **Environmental Sustainability Report 2022**. Redmond: Microsoft, 2022. Disponível em: <https://blogs.microsoft.com/on-the-issues/2022/07/26/microsoft-environmental-sustainability-report-2022/>. Acesso em: 29 maio 2026.

PATTERSON, D. *et al.* The carbon footprint of machine learning training will plateau, then shrink. **Computer**, [S. l.: s. n.], v. 55, n. 7, p. 18-28, 2022.

PERRIGO, B. Exclusive: OpenAI used Kenyan workers on less than \$2 per hour to make ChatGPT less toxic. **Time Magazine**, 2023. Disponível em: <https://time.com/6247678/openai-chatgpt-kenya-workers/>. Acesso em: 29 maio 2026.

RAHMAN, R.; OWEN, D.; YOU, J. Tracking compute of large AI models. **Epoch AI**, 2024. Disponível em: <https://epoch.ai/publications/tracking-large-scale-ai-models>. Acesso em: 29 maio 2026.

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
O custo invisível da IA

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **11 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.