

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



04

QUINZENA 1

QUANDO SE PARA DE QUESTIONAR:
NATURALIZAÇÃO E VIESES ALGORÍTMICOS

04

QUINZENA 1

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

QUANDO SE PARA DE QUESTIONAR:
NATURALIZAÇÃO E VIESES ALGORÍTMICOS

INTRODUÇÃO

Você acorda, verifica o *feed*, pede uma música ao assistente de voz, usa o GPS para escolher o caminho. Em cada um desses momentos, sistemas de inteligência artificial (IA) tomaram decisões por ou com você, e provavelmente você não parou para perguntar: Qual objetivo esse sistema está otimizando? Quem o projetou? Para quem ele funciona bem? Não é descuido: é o que acontece quando uma tecnologia se naturaliza. Este módulo examina como esse processo ocorre e quais são suas consequências concretas.



ORIGEM DO MATERIAL

O conteúdo deste *e-book* articula o Módulo 1 do Workshop Fulbright sobre IA na Educação em Engenharia (Katz *et al.*, 2025) com as obras de Neil Postman (1992), Bruno Latour (2005), Joy Buolamwini e Timnit Gebru (2018), Safiya Umoja Noble (Algorithms of Oppression, 2018) e o framework de literacia em IA de Almatrafi *et al.* (2024).

1. O QUE É NATURALIZAÇÃO TECNOLÓGICA

Naturalização é o processo pelo qual uma tecnologia, um hábito ou uma relação social passa a parecer natural, inevitável e óbvia. Deixa-se de perceber sua existência e, com isso, deixa-se de questionar seu funcionamento, os valores que ela carrega e os efeitos que produz. O sociólogo Bruno Latour, na Teoria Ator-Rede desenvolvida ao longo das décadas de 1980 e 1990 e sistematizada em *Reassembling the Social* (Latour, 2005), observou que objetos tecnológicos carregam o que ele chamou de “inscrições”: valores, escolhas e suposições que foram embutidos pelos seus criadores e que passam a operar de forma silenciosa quando o objeto se naturaliza. Um cinto de segurança obrigatório inscrito no carro assume que o motorista pode ser imprudente. Um algoritmo de recomendação inscrito em uma plataforma assume que maximizar o clique é o objetivo correto. Quando se para de ver o cinto como artefato com história e passa-se a vê-lo apenas como “parte do carro”, a inscrição fica invisível.

Neil Postman (1992), no livro *Technopoly: the surrender of culture to technology*, descreveu um processo em três estágios pelo qual culturas se relacionam com tecnologias. No primeiro estágio, a tecnologia é usada por ferramentas: ela serve às tradições e valores existentes, sem reorganizá-los. No segundo estágio, torna-se tecnocrática: a tecnologia começa a influenciar as instituições, mas ainda coexiste com outras formas de autoridade. No terceiro estágio, a tecnologia vira tecnopólio: passa a ser a própria fonte de legitimidade, e qualquer prática não mediada por tecnologia começa a parecer suspeita ou inferior. Postman (1992) escrevia nos anos 1990 sobre televisão e computadores pessoais, mas a estrutura do argumento aplica-se com precisão ao modo como parte da cultura contemporânea começou a tratar os *outputs* de IA generativa: como mais confiáveis do que textos escritos por humanos simplesmente por serem produzidos por um sistema técnico.

Para o campo da literacia em IA, a naturalização é o estado de partida que precisa ser revertido antes de qualquer aprendizado mais profundo. Almatrafi *et al.* (2024) identificaram que a dimensão de “Reconhecer”, a primeira do *framework* de literacia, inclui não apenas identificar sistemas de IA no cotidiano, mas perceber que eles existem onde antes pareciam ausentes. Uma pessoa que acha que “não usa IA” porque não usa ChatGPT, mas usa Spotify, Instagram e Google Maps todos os dias, está em estado de naturalização. O primeiro passo não é aprender a usar IA melhor: é ver o que já estava lá.

2. AS QUATRO ILUSÕES DA IA

A relação acrítica com a IA organiza-se em quatro ilusões principais. Todas elas são produzidas pelo mesmo mecanismo: o *design* das interfaces oculta a infraestrutura, o mecanismo de funcionamento, os custos e as condições de produção. O usuário vê o resultado (a resposta, a recomendação, a decisão) sem ver o processo que o gerou. Mitchell Gerhardt, no Módulo 1 do Workshop Fulbright de 2025 (Katz *et al.*, 2025), descreveu essa questão como central para o ensino de literacia em IA: “Se o modelo foi treinado com dados da internet americana, os valores culturais que ele aprende serão diferentes dos dados coletados no Brasil.”

Ilusão	O que o usuário crê	O que de fato ocorre	Consequência documentada
Confiabilidade	A IA sabe a resposta e verifica os fatos antes de responder	O modelo gera texto estatisticamente plausível; não consulta fontes; não sabe quando erra (Bender <i>et al.</i> , 2021)	Aceitação de dados incorretos sem verificação; citações inexistentes em trabalhos acadêmicos
Neutralidade	A IA é objetiva porque é uma máquina, sem opinião ou discriminação	O modelo herda os vieses estatísticos dos dados de treinamento, que refletem desigualdades históricas	Erros 43x maiores em reconhecimento de faces de mulheres negras vs. homens brancos (Buolamwini; Gebru, 2018)
Gratuidade	Usar IA não tem custo: o aplicativo é gratuito	Há custo ambiental (energia, água) e custo humano (ghost work em condições precárias)	Invisibilidade das externalidades ambientais e sociais do uso; custos reais não entram no cálculo de adoção (Crawford, 2021)
Universalidade	A IA funciona igualmente bem para todos, em todos os idiomas e contextos	Modelos treinados com >90% de dados em inglês têm desempenho muito menor em português e outras línguas sub-representadas	Assimetria de benefícios por idioma, renda e acesso à infraestrutura digital (Unesco, 2025)

A ILUSÃO DA CONFIABILIDADE: O PROBLEMA DA ALUCINAÇÃO

A ilusão de confiabilidade é particularmente relevante no contexto acadêmico. Emily Bender, pesquisadora da Universidade de Washington, Timnit Gebru, Margaret Mitchell e Angelina McMillan-Major publicaram em 2021 o artigo “*On the dangers of stochastic parrots: can language models be too big?*” (Bender *et al.*, 2021), que documentou de forma sistemática o fenômeno das alucinações em modelos de linguagem. O título, papagaios estocásticos, descreve exatamente o mecanismo:

modelos que geram texto plausível a partir de distribuições de probabilidade sobre sequências de *tokens*, sem qualquer verificação factual ou compreensão semântica. O resultado é que o modelo pode produzir uma referência bibliográfica completamente fabricada (autor real, título plausível, volume e número de página verossímeis) com o mesmo tom assertivo que usaria para uma referência real. Pesquisadores relataram encontrar referências inexistentes em trabalhos gerados por IA que passaram por revisão inicial sem verificação das fontes.

A ILUSÃO DA UNIVERSALIDADE: DESIGUALDADE POR IDIOMA E INFRAESTRUTURA

O relatório *AI Competency Framework for Citizens*, publicado pela Organização das Nações Unidas para a Educação, a Ciência e a Cultura (Unesco) em 2025, identificou a desigualdade de acesso a sistemas de IA como uma dimensão estrutural de literacia que não pode ser tratada apenas como questão técnica. Modelos de linguagem foram treinados com corpora em que o inglês representa mais de 90% do conteúdo (Katz *et al.*, 2025). A consequência não é apenas uma diferença de qualidade de tradução, mas de profundidade de repertório com que o modelo opera. Para tarefas que exigem nuances culturais, jurídicas ou históricas do contexto brasileiro, o modelo tem menos material de referência e produz respostas mais rasas ou mais propensas a erro. Um estudante que faz perguntas em português sobre o sistema previdenciário brasileiro ou sobre jurisprudência do Supremo Tribunal de Justiça (STJ) está trabalhando com um modelo menos equipado do que um estudante americano que faz perguntas equivalentes em inglês sobre direito americano. A ilusão da universalidade invisibiliza essa assimetria.

3. VIESES ALGORÍTMICOS: O QUE SÃO E DE ONDE VÊM

Um viés algorítmico ocorre quando um sistema de IA produz resultados sistematicamente mais precisos, mais favoráveis ou mais justos para alguns grupos do que para outros. A causa mais comum não é intenção maliciosa: é a presença de vieses nos dados de treinamento, que refletem desigualdades históricas e estruturais da sociedade. Quando um modelo aprende a partir de dados que representam mal determinados grupos, porque esses grupos foram excluídos historicamente das fontes de dados ou aparecem em contextos negativos ou estereotipados, o modelo aprende esses padrões e os reproduz em escala.

Essa reprodução de vieses tem uma característica particularmente problemática: o sistema os entrega com a mesma aparência de objetividade que qualquer outro resultado. Um filtro de *spam* que identifica incorretamente *e-mails* de grupos específicos não avisa que está fazendo isso. Um sistema de reconhecimento facial que erra muito mais para um grupo demográfico não avisa o operador sobre essa disparidade. O viés é estrutural, não visível na interface, e isso o torna difícil de detectar sem auditoria ativa.

O ESTUDO GENDER SHADES

Em 2018, Joy Buolamwini, pesquisadora do MIT Media Lab, e Timnit Gebru, pesquisadora de IA e ex-líder do time de ética em IA do Google, publicaram o estudo "*Gender shades: intersectional accuracy disparities in commercial gender classification*" na Conference on Fairness, Accountability, and Transparency (FAccT) (Buolamwini; Gebru, 2018). O estudo auditou três sistemas comerciais de reconhecimento e classificação de gênero de grandes empresas de tecnologia, usando um *dataset* propositalmente construído para incluir diversidade de gênero, cor da pele e geografia: o Pilot Parliaments Benchmark (PPB), com imagens de parlamentares de países africanos e países escandinavos. Os resultados foram os seguintes:

Grupo demográfico (Buolamwini; Gebru, 2018)	Taxa de erro média	Interpretação
Homens de pele mais clara (PP1)	0,8%	Melhor desempenho no estudo. Grupo sobrerrepresentado nos datasets de treinamento.
Mulheres de pele mais clara (PP2)	3,3%	Pior desempenho entre os grupos de pele mais clara. Diferença em relação a PP1 é estatisticamente significativa.
Homens de pele mais escura (PP3)	12,1%	15x mais erros do que PP1. Cor da pele é fator de desempenho independente do gênero.
Mulheres de pele mais escura (PP4)	20,8% (até 34,7% em um dos sistemas)	Pior desempenho. A intersecção de gênero e cor da pele produz disparidade máxima. Um dos sistemas auditados errou mais de 1 em cada 3 classificações para este grupo.

A magnitude da disparidade foi expressiva: entre o grupo com melhor desempenho (homens de pele mais clara, ~0,8% de erro) e o com pior (mulheres de pele mais escura, até 34,7% de erro em um dos sistemas), a diferença chegou a mais de 43 vezes. A explicação metodológica de Buolamwini e Gebru (2018) foi direta: os *datasets* de treinamento usados pelas empresas auditadas representavam majoritariamente homens de pele clara. O modelo aprendeu melhor o que mais viu. O estudo introduziu o conceito de interseccionalidade na avaliação de sistemas de

IA: o efeito de gênero e o efeito de cor da pele não se somam linearmente: eles se multiplicam de forma não óbvia, e qualquer avaliação que examine apenas uma dimensão de cada vez perderá as disparidades na interseção. O *Gender Shades* tornou-se referência para o campo e motivou revisões nos *datasets* de treinamento de vários sistemas comerciais após sua publicação.

OUTROS CASOS DOCUMENTADOS DE VIÉS ALGORÍTMICO

Caso	O que aconteceu	Fonte verificada
Amazon Recruiting Tool	Sistema de IA treinado em currículos históricos penalizava automaticamente currículos com a palavra “feminino” e candidatos de faculdades femininas. Desativado ao ser descoberto internamente.	Dastin, 2018.
COMPAS	Algoritmo de avaliação de risco de reincidência criminal usado em tribunais dos EUA apresentou taxa de falsos positivos para réus negros duas vezes maior do que para réus brancos.	Angwin <i>et al.</i> , 2016. Nota: a Northpointe questionou a metodologia; o debate metodológico continua ativo na literatura.
Buscas racializadas	Mecanismos de busca retornavam resultados sexualizados e estereotipados para termos associados a mulheres negras, enquanto termos equivalentes para outros grupos retornavam resultados neutros ou positivos.	Noble, 2018.

POR QUE VIESES SURGEM MESMO SEM INTENÇÃO

O caso da Amazon (Dastin, 2018) ilustra um mecanismo frequente: dados históricos carregam histórias de exclusão. Se um modelo é treinado com dez anos de contratações de uma empresa que não contratava mulheres para cargos de engenharia, ele aprende que ser mulher é um preditor negativo de sucesso na função. Não por decisão dos engenheiros: por lógica de otimização. O modelo encontrou um padrão nos dados e generalizou. A discriminação não foi inserida no código; foi aprendida dos dados. Isso tem uma implicação importante para qualquer profissional que projete, audite ou use sistemas de aprendizado de máquina: os dados de treinamento precisam ser examinados com a mesma atenção que o algoritmo.

O caso COMPAS, documentado pela equipe do ProPublica em 2016 (Angwin *et al.*, 2016), é mais complexo porque envolve uma disputa metodológica ativa. A equipe do ProPublica identificou que o algoritmo COMPAS, usado por tribunais americanos

para avaliar risco de reincidência criminal, apresentava taxa de falsos positivos para réus negros aproximadamente duas vezes maior do que para réus brancos. A empresa Northpointe, desenvolvedora do sistema, contestou a metodologia, argumentando que o algoritmo era igualmente preciso quando se mede calibração: a correspondência entre o escore atribuído e a taxa real de reincidência. O debate subsequente na literatura mostrou que diferentes definições de “equidade” em algoritmos podem ser matematicamente incompatíveis: um sistema não pode, em geral, satisfazer simultaneamente todas as métricas de *fairness* desejáveis (Chouldechova, 2017). Esse resultado é importante: a discussão sobre viés algorítmico não é apenas técnica, mas normativa: exige decisões sobre quais critérios de justiça são prioritários, e essas decisões não podem ser delegadas ao algoritmo.



PONTO CENTRAL

Reconhecer vieses algorítmicos não é sobre desconfiar de toda IA: é sobre saber fazer as perguntas certas. Quem os dados de treinamento representam? Quem avaliou o desempenho do sistema e em qual população? Qual métrica de equidade foi usada e quais outras métricas foram desconsideradas? Essas perguntas não têm respostas automáticas, por isso não podem ser respondidas pela própria IA.

4. A DESNATURALIZAÇÃO COMO PRÁTICA

Desnaturalizar não é parar de usar tecnologia, mas desenvolver a capacidade de ver o que estava invisível: nomear o sistema que opera, identificar o objetivo que ele otimiza, perguntar para quem ele funciona bem e para quem ele funciona não tão bem. Mitchell Gerhardt, no Workshop Fulbright de 2025 (Katz *et al.*, 2025), propôs uma pergunta que serve de fio condutor para este processo: “O que esse exercício revelou sobre a sua própria relação com a ferramenta, não sobre a ferramenta em si?” Essa inversão é importante. O objetivo não é produzir uma análise abstrata do sistema: é que cada pessoa identifique onde a naturalização operou na sua própria trajetória: os momentos em que confiou sem verificar, assumiu que a ferramenta era neutra ou não percebeu o custo.

Para estudantes de Engenharia, essa prática tem relevância direta e futura: muitos dos sistemas que você vai projetar, recomendar, avaliar ou colocar em produção ao longo da carreira envolverão alguma forma de aprendizado de máquina.

Saber que esses sistemas herdam os padrões dos seus dados de treinamento, inclusive desigualdades históricas, é parte da formação técnica, não um complemento ético opcional. O relatório *Framework de Competências de IA para Cidadãos* da Unesco (2025) coloca a dimensão de equidade digital no centro da literacia: não como sensibilidade cultural, mas como competência técnica necessária para quem projeta sistemas que operam em sociedades desiguais.

REFERÊNCIAS

As obras abaixo são verificáveis e estão disponíveis nas plataformas indicadas.

ALMATRAFI, O. *et al.* Base dos seis níveis de literacia em IA: reconhecer, conhecer, usar, avaliar, criar, navegar eticamente. **AI Literacy Framework**, 2024.

ANGWIN, J. *et al.* Machine Bias. **ProPublica**, 2016. Disponível em: <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>. Acesso em: 29 maio 2026.

BENDER, E. M. *et al.* On the dangers of stochastic parrots: can language models be too big? **FAccT '21**, [S. l.: s. n.], p. 610-623, 2021. Disponível em: <https://dl.acm.org/doi/epdf/10.1145/3442188.3445922>. Acesso em: 29 maio 2026.

BUOLAMWINI, J.; GEBRU, T. Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification. **Proceedings of Machine Learning Research**, [S. l.: s. n.], v. 81, p. 1-15, 2018. Disponível em: <http://proceedings.mlr.press/v81/buolamwini18a.html>. Acesso em: 29 maio 2026.

CHOULDECHOVA, A. Fair prediction with disparate impact: a study of bias in recidivism prediction instruments. **Big Data**, [S. l.: s. n.], v. 5, n. 2, p. 153-163, 2017.

DASTIN, J. Amazon scraps secret AI recruiting tool that showed bias against women. **Reuters**, 2018. Disponível em: <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>. Acesso em: 29 maio 2026.

KATZ, B. *et al.* Integrating artificial intelligence into engineering education. In: WORKSHOP FULLBRIGHT., 2025, São Paulo. **Anais [...]**, São Paulo: Centro de Inovação da USP, 2025. Módulo 1: Gerhardt, M. Introduction to Generative AI.

LATOUR, B. **Reassembling the social**: an introduction to actor-network theory. Oxford: Oxford University Press, 2005.

NOBLE, S. U. **Algorithms of oppression**: how search engines reinforce racism. New York: NYU Press, 2018.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS PARA A EDUCAÇÃO, A CIÊNCIA E A CULTURA [UNESCO]. **AI competency framework for citizens**. Paris: Unesco, 2025.

Disponível em: https://unesdoc.unesco.org/ark:/48223/pf0000391601_por. Acesso em: 29 maio 2026.

POSTMAN, N. **Technopoly**: the surrender of culture to technology. New York: Alfred A. Knopf, 1992.

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
Quando se para de questionar: naturalização e vieses algorítmicos

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **13 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.