

TEMPLATE

2

QUINZENA 2 • POR DENTRO DOS LLMS

Template do grupo

A metacognição da alucinação

GRUPO	INTEGRANTES
Grupo 05	Caroline, Lucas, Thales

ANTES DE COMEÇAR: ESCREVER AQUI É OPCIONAL

O grupo não precisa preencher este documento. Se preferir, copiem as quatro perguntas e respondam em um arquivo novo, no editor que quiserem, ou direto no fórum. O template existe só para organizar a discussão: o que vale é o conteúdo das respostas, não o formato em que elas chegam.

O QUE FAZER

Depois que cada integrante analisou o seu caso sozinho, o grupo se reúne no fórum para discutir. O objetivo não é somar as respostas individuais, e sim refletir juntos, trocar ideias, discordar quando for o caso e chegar a conclusões em comum.

Respondam às perguntas como grupo. Uma resposta boa mostra a discussão de vocês, não apenas a conclusão.

1 Partilha: cada integrante apresenta o seu caso, o que foi conferir, o que encontrou e o tipo de alucinação.

Façam um resumo rápido de cada caso e anotem aqui os tipos que apareceram no grupo, um por integrante.

- **Lucas (Caso A · Santos Dumont):** Analisou o texto biográfico sobre Santos Dumont. A IA acertou dados históricos e feitos (Cabangu, Prêmio Deutsch de 1901, voo do 14-bis e Demoiselle), porém alucinou ao afirmar que ele patenteou o 14-bis e recebeu royalties. A checagem documental provou que Dumont colocou seus projetos em domínio público. Classificou como **Viés de Corpus** (*O preconceito automático*), decorrente da predominância estatística no corpus de que inventores protegem suas criações por lucro.
- **Thales (Caso A · Santos Dumont):** Também analisou o caso de Santos Dumont e desconfiou do trecho sobre patentes devido ao conhecimento prévio sobre o idealismo de Dumont. Na averiguação em fontes de referência (Wikipedia/artigos históricos), confirmou que ele fazia testes públicos e abertos, ao contrário dos irmãos Wright. Classificou o erro como **Alucinação Factual** (*O blefe*), apontando possível contaminação/comparação indevida com os irmãos Wright (que patentearam e lucraram), gerando uma falsidade com tom extremamente convincente.
- **Caroline (Caso D · A Confeiteira / Tomada de Decisão):** Analisou a situação de uma confeitira sobrecarregada que consultou a IA sobre contratar ou não uma assistente. A IA respondeu de forma evasiva e superficial, apenas listando prós e contras genéricos ("se contratar tem custo fixo, se não contratar economiza mas se desgasta"), sem pedir dados concretos do negócio (faturamento, margem ou demanda real). Classificou como **Vagueza Confortável** (*A evasão*) e **Ausência de Contexto** (*A generalização*), pois o modelo simulou uma consultoria sem se comprometer com uma análise aplicável.

2

Comparando os casos de todos, qual o grupo considera o mais difícil de perceber e qual o mais perigoso na vida real?

Esta pergunta não tem resposta certa. Discutam, defendam pontos de vista diferentes e cheguem juntos a uma posição, explicando o motivo da escolha.

O mais difícil de perceber: O grupo observou que os erros mais difíceis de detectar possuem duas naturezas complementares: a *alucinação camuflada em fatos verdadeiros* (como no caso de Santos Dumont, em que a IA acertou 90% do texto com precisão, fazendo o dado falso sobre patente soar verossímil) e a *vagueza confortável* (no caso da confeitaria, onde a resposta parece prudente e equilibrada por listar dois lados, mas mascara uma completa ausência de profundidade técnica).

O mais perigoso na vida real: Conforme debatido no grupo, a **Alucinação Factual (O Blefe) alimentada por Viés** é a mais danosa no cotidiano prático, pois é a principal raiz da proliferação de *fake news* e de distorções históricas aceitas quando o leitor não tem conhecimento prévio. Paralelamente, a **Vagueza Confortável e Ausência de Contexto** representam alto risco em negócios e gestão, pois geram falsa sensação de consultoria e podem induzir microempreendedores a decisões financeiras erradas por falta de dados reais.

3

O que os casos têm em comum na forma como o erro nasce? Por que dá para dizer que a alucinação é estrutural, e não um defeito que a próxima versão vai corrigir?

Pensem no que une casos tão diferentes. O que existe, ou não existe, no funcionamento do modelo que faz o erro aparecer em todos eles?

A alucinação é um fenômeno **estrutural e intrínseco à própria arquitetura dos LLMs**, e não um mero defeito temporário. Em todos os casos analisados pelo grupo, a causa raiz é a mesma: os modelos de linguagem são sistemas probabilísticos cujo objetivo matemático é prever o próximo *token* mais estatisticamente plausível a partir do contexto, e **não consultar uma base ontológica de fatos reais ou raciocinar sobre o mundo concreto**.

Quando o modelo fala de Santos Dumont, associa por pura proximidade estatística "inventor famoso" a "patente e lucros". Quando responde à confeitaria, gera um texto com o formato padrão de "prós e contras" comum na internet para evitar conflitos retóricos. A alucinação nasce do mesmo mecanismo que confere capacidade generativa e síntese ao modelo; suprimir a probabilidade eliminaria a própria razão de ser dos LLMs.

4

Os erros têm nome de comportamento humano. O que significa a máquina errar como a gente erra, e o que isso muda no jeito de vocês confiarem na IA?

Conversem sobre o que muda, na prática de vocês, saber que a máquina repete jeitos humanos de errar.

O fato de a máquina errar reproduzindo comportamentos humanos (*o blefe, o preconceito automático, a evasão, a generalização*) reflete diretamente a sua fonte de aprendizado: o corpus composto por textos produzidos pela cultura humana. Os modelos espelham em escala ampliada nossos próprios vieses de generalização, preconceitos estatísticos e a tendência retórica de preencher lacunas de conhecimento com narrativas convincentes.

O que muda na nossa confiança (Nossa Regra Prática):

- **Para ideação, estruturação, síntese e sintaxe de código:** Podemos confiar na IA como um poderoso acelerador e parceiro de produtividade.
- **Para fatos históricos, dados numéricos, citações bibliográficas e decisões de negócios:** A desconfiança é obrigatória e a checagem em fontes primárias/contexto real é inegociável. A responsabilidade final e a curadoria da verdade factual permanecem sendo prerrogativas humanas.

ANTES DE POSTAR NO FÓRUM

- ☐ Todos os casos do grupo aparecem na resposta.
- ☐ A discussão está visível, inclusive onde vocês discordaram.
- ☐ As escolhas do grupo vêm com o motivo, não só com a conclusão.