

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



02

QUINZENA 2

ATENÇÃO, TEMPERATURA E PLAUSIBILIDADE

02

QUINZENA 2

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

ATENÇÃO, TEMPERATURA E PLAUSIBILIDADE

BASE CONCEITUAL DO MÓDULO 2



ORIGEM DO MATERIAL

O conteúdo deste e-book articula o mecanismo de atenção descrito por Vaswani et al. (2017) com o Módulo 1 do Workshop Fulbright sobre IA na Educação de Engenharia (Gerhardt, 2025) e com a demonstração de Wolfram (2023) sobre geração de texto por probabilidade. Videoaulas deste *e-book*: VA Q2-02 e VA Q2-2.2..

Você já viu, no módulo anterior, que o modelo não lê palavras: ele lê *tokens*, pedaços de texto convertidos em número, e cada *token* tem um endereço num mapa de significados chamado *embedding*. Agora, falta entender o que o modelo faz com esses endereços quando processa uma frase inteira: como ele decide, entre todos os *tokens*, quais merecem mais **peso** para decidir o que vem a seguir. É esse mecanismo, chamado **atenção**, que permite ao modelo manter a coerência de um texto por parágrafos inteiros, e também a origem de um problema central desta quinzena: o **modelo pode ser coerente e mesmo assim estar errado**.

Pense numa situação simples. Você está lendo um contrato de dez páginas e alguém pergunta uma informação específica que está no meio do texto. **Você não presta atenção igual em cada palavra**: busca ativamente o trecho relevante e ignora o resto. Fazer isso rápido e automaticamente, para cada palavra de cada frase, é o que o **mecanismo de atenção** faz dentro do modelo.

1. O PROBLEMA QUE A ATENÇÃO RESOLVE

Antes da arquitetura, ou seja, o desenho geral de como a rede neural é construída, conhecida como *Transformer*, os modelos processavam o texto *token por token*, na ordem em que ele aparecia, sem revisitar o que já tinha passado. Isso criava um problema concreto: quanto mais distante um *token* estava do ponto atual da leitura, menos influência ele tinha na decisão do modelo. Um modelo lendo a última palavra de uma frase longa podia já ter perdido o efeito das primeiras palavras, mesmo que elas fossem essenciais para o sentido.

Vaswani et al. (2017), pesquisadores do Google, propuseram uma solução diferente batizada de ***Transformer***: em vez de processar *token por token* em fila, o modelo passa a olhar para todos os *tokens* da frase ao mesmo tempo e decide, para cada um deles, o quanto os outros tokens importam. Essa capacidade de olhar para tudo de uma vez e decidir o que importa mais é o que se chama mecanismo de atenção, e é o que resolve o problema do esquecimento de contexto. Google, Anthropic e OpenAI usam essa mesma arquitetura como base do Gemini, do Claude e do ChatGPT, cada um com seus próprios ajustes.

2. CAMADAS: O MODELO REFINA A LEITURA EM ETAPAS

O mecanismo de atenção não acontece uma única vez. Ele se repete várias vezes seguidas, cada repetição refinando um pouco mais a interpretação da frase, parecido com revisar um texto em várias passadas: na primeira leitura você entende o assunto geral, na segunda percebe detalhes, na terceira nota nuances que passaram despercebidas antes.

Cada uma dessas repetições do processamento se chama camada. Um modelo de linguagem grande empilha dezenas de camadas, uma depois da outra: a saída de uma camada vira a entrada da próxima. **A cada camada, a representação de cada *token*, o endereço dele no mapa de significados, vai sendo ajustada para refletir melhor o contexto da frase inteira.**

3. COMO O MODELO DECIDE O QUE IMPORTA: O CÁLCULO DE ATENÇÃO

Para entender o cálculo, vale voltar ao mapa de significados do módulo anterior. Cada *token* tem um endereço nesse mapa, uma lista de números. A atenção usa esses endereços para medir o **quanto dois *tokens* se relacionam**: quanto mais parecida a direção dos dois endereços no mapa, maior a relação entre eles. **Essa medida de semelhança entre dois pontos do mapa é o coração de todo o cálculo, e é dela que nasce o peso que vamos usar daqui em diante.**

O modelo transforma essas semelhanças numa lista de números que representam a importância relativa de cada *token* para o *token* atual. **Cada um desses números é um peso**: quanto mais parecidos forem os dois endereços comparados, maior o peso entre eles. Os pesos de um mesmo *token*, somados, sempre totalizam 100%, porque a atenção disponível é sempre a mesma quantidade fixa, apenas distribuída de forma diferente entre os candidatos. **Essa lista de pesos é o que se chama distribuição, porque distribui a atenção disponível entre eles.**

Para realizar esse cálculo, **cada *token* gera três versões** numéricas de si mesmo, derivadas do seu endereço no mapa e batizadas de **QUERY, KEY e VALUE**. A **Query** representa o que aquele *token* está buscando no restante da frase. A **Key** representa o que cada *token* tem a oferecer como resposta a uma busca. E o **Value** representa a informação que o *token* efetivamente carrega, aquela que será usada se ele for considerado relevante. O peso entre dois *tokens* vem de comparar a **Query** de um com a **Key** do outro usando a mesma ideia de proximidade explicada acima: quanto mais parecida a direção dessas duas versões numéricas, maior o peso resultante. No fim, o modelo soma os **Values** de todos os *tokens*, cada um multiplicado pelo seu peso, e produz uma nova representação para aquele *token*, agora enriquecida pelo contexto da frase inteira.

Vetor	O que representa	Analogia intuitiva
Query (Q)	O que este <i>token</i> está buscando no contexto.	A pergunta que o <i>token</i> faz aos outros.
Key (K)	O que este <i>token</i> oferece como ponto de busca.	O cartaz que cada <i>token</i> exhibe.
Value (V)	A informação que este <i>token</i> carrega de fato.	O conteúdo entregue quando encontrado.

4. CABEÇAS DE ATENÇÃO: VÁRIOS OLHARES AO MESMO TEMPO

O cálculo descrito na seção anterior não acontece uma única vez por camada: ele se repete em paralelo, várias vezes, cada repetição usando uma versão diferente das mesmas fórmulas. Cada uma dessas repetições paralelas se chama **cabeça de atenção**, e um modelo grande costuma usar dezenas delas em cada camada.

A razão de existirem várias cabeças é que uma relação entre palavras pode ser observada de formas diferentes. Uma cabeça pode se especializar em notar quem faz o quê numa frase, por exemplo identificar que uma palavra é o sujeito e outra é o verbo da ação. Essa relação de função gramatical entre as palavras tem um nome técnico: **relação sintática**. Outra cabeça pode se especializar em notar que duas palavras diferentes se referem à mesma coisa, mesmo estando distantes uma da outra na frase. Essa relação de significado entre palavras também tem nome técnico: **relação semântica**. Ao final, o modelo combina o resultado de todas as cabeças numa única representação, que carrega ao mesmo tempo pistas gramaticais e pistas de significado.

5. VER ISSO NA PRÁTICA: "BANCO" EM DOIS CONTEXTOS

A tabela abaixo mostra pesos de atenção reais, medidos ao processar a palavra banco em duas frases com sentidos opostos. Repare que os pesos de cada coluna somam 100%, exatamente como descrito na seção anterior, e que o verbo e o complemento da frase são os *tokens* que mais diferenciam um contexto do outro.

Token	"Sentei no banco da praça"	"Transferi no banco digital"
banco (palavra-alvo)	0,40 (peso próprio)	0,38 (peso próprio)
verbo (sentei/transferi)	0,28 (ancora o sentido)	0,30 (ancora o sentido)
complemento (praça/digital)	0,20 (desambigua)	0,22 (desambigua)
artigo (da/no)	0,07	0,06
demais tokens	0,05	0,04

O modelo não recebe nenhuma regra pronta dizendo que banco perto de praça significa assento. **Ele aprendeu, processando bilhões de frases, que esses pares de palavras aparecem com frequência em contextos parecidos, o que os deixa próximos no mapa de significados.** O mecanismo de atenção usa essa proximidade aprendida para calcular, automaticamente, os pesos certos para cada situação.



GUARDE ESTA IDEIA

Atenção produz coerência, não garante verdade. Essa ideia volta com mais profundidade na seção 8, quando ela se torna central para entender por que os modelos erram.

6. O LLM NÃO PESQUISA, ELE ESTIMA

Uma confusão comum é tratar um modelo de linguagem, como o ChatGPT, o Gemini ou o Claude, **como um motor de busca sofisticado**, um sistema que vai atrás de informações guardadas em algum banco de dados. Essa comparação está errada. **Um motor de busca recupera documentos que já existem**, escritos por alguém, e aponta a fonte. **Um modelo de linguagem faz uma conta diferente:** ele calcula, a cada passo, uma lista de pesos parecida como a que vimos na atenção, só que agora aplicada a todas as palavras possíveis do vocabulário, o dicionário de *tokens* visto no módulo anterior, para **decidir qual delas é a mais provável de vir a seguir**.

Isso significa que **o modelo não consulta nada durante a geração da resposta**. Ele não acessa a internet, não verifica uma base de dados, **não confere se o que vai escrever é verdade**. Cada palavra é escolhida com base em **padrões aprendidos durante o treinamento**, que ficou congelado numa data específica. **Quando um modelo afirma um fato, ele está produzindo a continuação mais provável dado tudo o que veio antes, não recuperando um dado de um arquivo.**

Dimensão	Motor de busca	LLM (modelo de linguagem)
Mecanismo	Recupera documentos indexados.	Gera sequências de <i>tokens</i> .
Fonte da resposta	Documentos reais, com URL rastreável.	Padrões aprendidos no treinamento.
Atualização	Contínua (indexação permanente).	Congelada na data de corte.
Verificação	Aponta a fonte; você verifica o conteúdo.	Não verifica; apresenta como fluente.

Essa distinção tem consequência direta para o uso acadêmico: citar um modelo de linguagem como fonte de um fato equivale a citar a probabilidade estatística dessa afirmação, não a verificação dela. Qualquer informação que vier de um modelo, seja ChatGPT, Gemini ou Claude, precisa ser conferida numa fonte primária antes de ser usada num trabalho.

7. TEMPERATURA: O QUANTO O MODELO ARRISCA

A lista de pesos usada para escolher a próxima palavra, mencionada na seção anterior, tem um nome técnico: **DISTRIBUIÇÃO DE PROBABILIDADE**. É uma lista com uma chance para cada palavra possível do vocabulário, e todas as chances juntas somam 100%. O parâmetro chamado temperatura controla o quanto essa lista fica concentrada nas palavras mais prováveis, ou espalhada entre várias palavras com chances parecidas.

Wolfram (2023) demonstra esse processo com um exemplo direto. Ao completar a frase "***The best thing about AI is its ability to***", o sistema gera uma lista de palavras candidatas com uma probabilidade associada a cada uma. Se o modelo sempre escolhesse a palavra mais provável da lista, o texto ficaria repetitivo e sem variação. Escolher, de vez em quando, uma palavra um pouco menos provável é o que **produz textos mais variados e criativos**, e é exatamente isso que a temperatura regula. Wolfram observa que uma temperatura próxima de 0,8 costuma funcionar bem para geração de texto livre, sem que exista uma explicação teórica fechada para esse valor específico, apenas a constatação empírica de que funciona.

A temperatura padrão de plataformas de uso geral costuma ficar entre 0,7 e 1,0. Em ferramentas voltadas a desenvolvedores é possível ajustar esse valor diretamente; em plataformas de uso geral, quem define a temperatura padrão é a empresa que opera a plataforma, a OpenAI no caso do ChatGPT, o Google no caso do Gemini, a Anthropic no caso do Claude, e o valor não fica visível para quem usa a interface.

Temperatura	Distribuição de probabilidade	Comportamento típico	Uso recomendado
T = 0,1 (baixa)	Concentrada: 1 ou 2 <i>tokens</i> dominam com mais de 90% de probabilidade.	Respostas determinísticas, repetitivas e conservadoras.	Extração de dados, geração de código, classificações.
T = 0,7 (média)	Balanceada: alguns <i>tokens</i> competem com probabilidades similares.	Respostas variadas, coerentes e com alguma criatividade.	Redação geral, resumos, respostas a perguntas abertas.
T = 1,5 (alta)	Dispersa: muitos <i>tokens</i> com probabilidades próximas.	Respostas imprevisíveis, criativas e frequentemente incoerentes.	Brainstorming, criação de nomes, exploração de ideias.

8. PLAUSIBILIDADE NÃO É O MESMO QUE VERDADE

A escolha da próxima palavra é sempre uma aposta na opção mais provável dado o contexto, nunca uma consulta a um fato registrado em algum lugar. Um exemplo ajuda a enxergar essa diferença. Imagine perguntar a um modelo, seja ChatGPT, Gemini ou Claude, qual é a capital de um país, e ele responder com o nome da cidade mais conhecida daquele país, não com o nome real da capital administrativa. Isso não acontece por falta de informação: acontece porque, nos textos usados para treinar o modelo, aquela cidade mais conhecida aparece associada ao país com muito mais frequência do que o nome correto da capital. O modelo escolheu a palavra estatisticamente mais provável, que não era a resposta correta.

Tipo de erro	O que acontece	Por que acontece
Cidade trocada pela capital	Cita a cidade mais conhecida de um país em vez da capital administrativa.	A cidade mais citada nos dados de treino tem mais peso estatístico do que o nome correto.
Citação inventada	Produz um título de artigo plausível com referência inexistente.	Títulos acadêmicos seguem padrões previsíveis; o modelo os replica sem verificar.
Contradição interna	Afirma uma coisa no início e o contrário no final de uma resposta longa.	A atenção perde força sobre <i>tokens</i> distantes conforme o texto cresce.



PARA REFLEXÃO

Identificar que um modelo errou não é suficiente para usá-lo bem. O passo seguinte é **entender por que ele errou**: foi por plausibilidade estatística, porque a palavra mais frequente não era a correta? Por temperatura alta, porque a distribuição dispersa gerou uma palavra improvável? Por corte de treinamento, porque o fato ocorreu depois? Diagnósticos diferentes pedem estratégias de verificação diferentes.

9. ESTRATÉGIAS PRÁTICAS DE USO RESPONSÁVEL

Compreender atenção, temperatura e plausibilidade transforma a relação com o modelo: em vez de aceitar cada *output* como verdade ou rejeitá-lo como erro aleatório, é possível diagnosticar o tipo de problema e adotar a estratégia certa.

Situação	Diagnóstico provável	O que fazer
O modelo afirmou um fato que parece errado	Erro de plausibilidade estatística.	Verificar em fonte primária antes de usar.
O modelo inventou uma referência bibliográfica	Geração de padrão plausível sem base factual.	Nunca usar referências de um modelo sem verificar no Google Acadêmico ou Scopus.
Respostas muito repetitivas para o mesmo <i>prompt</i>	Temperatura baixa; distribuição muito concentrada.	Reformular o <i>prompt</i> com variações ou ajustar a configuração se disponível.
Resposta contraditória ao longo de um texto longo	Perda de coerência por limite de janela de contexto.	Dividir a tarefa em partes menores e verificar consistência manualmente.

RESUMO ESQUEMÁTICO DOS CONCEITOS

O quadro abaixo retoma, em ordem, os conceitos deste módulo, do texto bruto até a palavra final escolhida pelo modelo.

Conceito	O que significa aqui
<i>Token e embedding</i>	Cada palavra vira número e ganha um endereço no mapa de significados (visto no Módulo 1).
Camada	Uma repetição do processamento; o modelo empilha dezenas delas.
Atenção	Cálculo que mede a relação entre <i>tokens</i> e gera um peso para cada par.
Peso	Número que mede a importância relativa entre dois tokens; a soma dos pesos de um <i>token</i> é sempre 100%.
<i>Query, Key e Value</i>	As três versões numéricas de um token usadas para calcular o peso.
Cabeça de atenção	Uma repetição paralela do cálculo de atenção, cada uma focando um tipo de relação.
Distribuição de probabilidade	Lista de chances, uma por palavra possível, que soma 100%.
Temperatura	Parâmetro que concentra ou espalha essa distribuição.
Plausibilidade	A palavra escolhida é a mais provável estatisticamente, não necessariamente a verdadeira.

REFERÊNCIAS

As obras abaixo foram usadas como base para o conteúdo deste e-book e são verificáveis nas fontes indicadas.

GERHARDT, M. Introdução aos Modelos de Linguagem de Grande Escala. In: KATZ, B. et al. **Innovating Engineering Education with Generative AI. Workshop Fulbright**, USP, setembro de 2025. [Módulo 1]

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org>

VASWANI, A. et al. Attention Is All You Need. **Advances in Neural Information Processing Systems**, v. 30, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>

WOLFRAM, S. **What Is ChatGPT Doing... and Why Does It Work?** Wolfram Media, 2023. Disponível em: <https://writings.stephenwolfram.com/2023/02/what-is-chat-gpt-doing-and-why-does-it-work/>

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
Atenção, temperatura e plausibilidade

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **12 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.