


IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



03

QUINZENA 2

ALUCINAÇÃO COMO
CONSEQUÊNCIA ESTRUTURAL

POR QUE O MODELO ERRA E COMO
RECONHECER CADA TIPO DE ERRO

03

QUINZENA 2

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

ALUCINAÇÃO COMO
CONSEQUÊNCIA ESTRUTURAL

POR QUE O MODELO ERRA E COMO
RECONHECER CADA TIPO DE ERRO

BASE CONCEITUAL DO MÓDULO 3



ORIGEM DO MATERIAL

O conteúdo deste e-book articula o Módulo 1 do Workshop Fulbright sobre IA na Educação de Engenharia (Gerhardt, 2025) com a pesquisa de referência sobre alucinação em modelos de linguagem: a revisão sistemática de Ji et al. (2023) e a avaliação empírica de Bang et al. (2023). O caso judicial da abertura é real e está documentado na decisão do tribunal (Mata v. Avianca, 2023).

Este módulo explica por que os modelos de linguagem às vezes apresentam informações falsas como se fossem verdadeiras. Você vai ver que esse comportamento não é uma falha passageira: ele nasce do próprio modo de funcionar desses sistemas. Vai conhecer também os cinco tipos de erro mais comuns e aprender o que verificar em cada situação de uso. Esse diagnóstico é o que permite usar a IA com critério, sem confiança cega e sem rejeição total.

Em 2023, um caso julgado em Nova York mostrou o tamanho do problema. Dois advogados entregaram ao tribunal uma petição que citava seis decisões judiciais como precedentes, casos julgados no passado que servem de apoio ao argumento do advogado. Os nomes dos casos, os números dos processos e os trechos de fundamentação estavam no formato correto. Quando o juiz Kevin Castel mandou localizar as decisões, nenhuma delas existia: todas tinham saído do ChatGPT, que os advogados usaram como ferramenta de pesquisa sem verificar o resultado. O tribunal aplicou multa de 5 mil dólares aos advogados, e o processo, Mata v. Avianca, virou o exemplo citado em tribunais do mundo inteiro quando o assunto é uso de IA sem verificação (Mata v. Avianca, 2023).

Esse tipo de produção tem nome técnico: alucinação. E ela não é um defeito que a próxima versão do modelo vai corrigir. É uma consequência estrutural do modo como os modelos de linguagem funcionam.

1. O QUE É ALUCINAÇÃO NOS LLMS

Alucinação, no contexto dos modelos de linguagem grandes (LLMs), é a geração de informações falsas, imprecisas ou inventadas que aparecem com a estrutura de uma afirmação confiável. Datas precisas, nomes corretos, números verossímeis: tudo pode estar presente em um texto que, verificado, revela conteúdo sem correspondência com a realidade. A revisão sistemática de Ji et al. (2023), tipo de estudo que reúne e organiza o que a pesquisa já produziu sobre um tema, publicada na revista científica ACM Computing Surveys, define o fenômeno como a geração de conteúdo sem sentido ou infiel à fonte que deveria sustentá-lo.

O Módulo 2 mostrou o mecanismo por trás disso: o modelo escolhe cada palavra pela plausibilidade estatística dada pelo contexto, nunca por consulta a um fato registrado. A alucinação é o que acontece quando essa aposta, que costuma acertar, erra o alvo factual sem dar nenhum sinal de que errou. Não existe alarme interno, porque para o modelo não há diferença entre uma frase verdadeira e uma frase apenas provável.

Essa distinção afasta uma leitura comum e equivocada: o modelo não mente. Mentir exige intenção; exige saber que algo é falso e afirmá-lo mesmo assim. O modelo não tem essa consciência. Ele gera a continuação mais plausível do texto recebido, e essa continuação pode estar factualmente errada sem que exista, em nenhum ponto do processo, algo parecido com má-fé. Por isso a irritação com o modelo que inventou uma referência é tão inútil quanto a confiança cega no modelo que parece saber a resposta.

2. POR QUE A ALUCINAÇÃO É ESTRUTURAL, NÃO ACIDENTAL

Os módulos desta quinzena contam uma história única. No Módulo 1, você viu que o texto vira números (*tokens*) e que cada token ganha um endereço num mapa de significados (*embeddings*). No Módulo 2, viu que o mecanismo de atenção decide o que importa no contexto e que a temperatura regula o quanto o modelo arrisca ao escolher a próxima palavra. Em nenhuma dessas etapas existe um passo chamado conferir se é verdade. O treinamento inteiro persegue um único objetivo: dar a maior probabilidade possível a sequências de palavras parecidas com as do *corpus* de treinamento, o conjunto de textos usado para ajustar os pesos do modelo, aqueles números internos que você conheceu no Módulo 2.

A revisão de Ji et al. (2023) confirma que a alucinação emerge desse objetivo de aprendizado, não de falta de dados nem de treinamento insuficiente. Enquanto o objetivo for maximizar a plausibilidade da sequência, sem restrição factual, algum nível de alucinação será esperado em qualquer modelo desse tipo, seja o ChatGPT, o Gemini ou o Claude.

A mesma revisão organiza o fenômeno em duas formas. Na alucinação intrínseca (de dentro), o texto gerado contradiz a informação que recebeu como base: você fornece um artigo e o resumo afirma o contrário do que o artigo diz. Na alucinação extrínseca (de fora), o texto acrescenta informações que não podem ser verificadas na base fornecida: o resumo inclui um dado que não está no artigo, inventado por fora dele. A segunda forma é a mais difícil de perceber, porque nada no material de origem denuncia o acréscimo.

Quando não recebe nenhum material de base e responde de cabeça, o modelo usa o que a pesquisa chama de memória paramétrica: o conhecimento comprimido nos pesos durante o treinamento, congelado na data em que o treinamento terminou. Bang et al. (2023) mostraram que o ChatGPT produz mais alucinações extrínsecas justamente nessa situação, porque não tem acesso a uma base externa para conferir o que afirma. É o caso das decisões judiciais de Mata v. Avianca: perguntado sobre precedentes específicos, o modelo respondeu com o padrão estatístico de uma decisão judicial, não com decisões reais.



CONCEITO-CHAVE

Como imaginar a memória paramétrica: o modelo não guarda os textos do treinamento, assim como você não guarda cada aula palavra por palavra. Ele guarda uma síntese estatística, algo como as anotações que sobram depois que os livros voltaram para a biblioteca. Com boas anotações dá para reconstruir muita coisa certa; também dá para reconstruir, com a mesma segurança, coisas que nunca estiveram nos livros.

3. OS CINCO TIPOS DE ERRO: UMA TAXONOMIA PRÁTICA

A alucinação não se manifesta de uma única forma, e tratar todo erro como alucinação genérica impede calibrar a verificação. A disciplina adota uma taxonomia, isto é, uma classificação organizada por tipos de erro. São cinco, cada um com um análogo humano: o comportamento correspondente que qualquer pessoa reconhece da própria experiência. Essa conexão é intencional. Ela mostra que erros

dessa natureza não são exclusivos das máquinas e que você já tem repertório para entendê-los. No módulo anterior, você viu exemplos pontuais de erro de plausibilidade; a tabela abaixo organiza o quadro completo.

Tipo de erro	Análogo humano	O que é	Exemplo concreto
Alucinação factual	O blefe	O modelo afirma algo falso com total segurança. Cita relatórios inexistentes, inventa datas, atribui afirmações a quem nunca as fez.	Lista de publicações com títulos inventados, datas erradas ou revistas que não publicaram aquele artigo.
Viés de <i>corpus</i>	O preconceito automático	Reproduz padrões estatísticos dos dados de treinamento. Não raciocina sobre o que é justo: repete o que aprendeu a tratar como normal.	Associações automáticas entre profissões e gênero, ou entre regiões geográficas e características negativas.
Vagueza confortável	A evasão	Produz texto que parece dizer muito sem se comprometer com nada. É uma estratégia aprendida para reduzir o risco de contradição.	Resposta que lista vantagens e desvantagens sem tomar posição quando uma posição direta seria mais útil.
Coerência sem verdade	O sofisma	Texto bem estruturado, argumento aparentemente lógico, gramática impecável. O conteúdo é falso ou distorcido. É o tipo mais perigoso.	Explicação tecnicamente convincente de um conceito de engenharia com definições incorretas.
Ausência de contexto	A generalização	Responde à pergunta genérica quando a pergunta era específica. O modelo não sabe quem pergunta, de onde, em que circunstância.	Recomendação de normas técnicas internacionais quando a pergunta pedia normas aplicáveis no Brasil.

Dois tipos merecem atenção especial pela dificuldade de detecção. A alucinação factual é a de Mata v. Avianca: afirmação falsa com estrutura impecável. A coerência sem verdade é a versão mais perigosa dela, porque o erro não está num dado isolado, e sim na arquitetura do argumento: definições incorretas encadeadas com lógica aparente. O juiz do caso classificou a fundamentação de uma das decisões falsas como um texto sem sentido jurídico, apesar da aparência convincente. Para quem não domina o assunto, esse tipo de erro é quase invisível; é ele que torna arriscado usar o modelo para aprender um conteúdo do zero sem nenhuma fonte de apoio.

O viés de *corpus* e a vagueza confortável têm um traço em comum: os dois nascem de escolhas humanas, não do acaso. O viés reproduz os padrões dos textos que pessoas escreveram ao longo de décadas; a vagueza é um estilo de resposta que o modelo aprendeu a preferir durante o ajuste feito por avaliadores humanos. O Módulo 4 mostra quem são essas pessoas, como esse ajuste funciona e por que ele produz uma voz padronizada.

A ausência de contexto fecha a lista com o erro mais fácil de provocar sem perceber. O modelo não sabe quem pergunta, de onde e para quê. Pergunte sobre normas de segurança em instalações elétricas e a resposta pode vir baseada em padrões internacionais, quando o que você precisava era a norma brasileira aplicável ao seu projeto. O erro não está no conteúdo: está no descasamento entre a pergunta que você fez e a pergunta que o modelo respondeu. A defesa é especificar o contexto no próprio *prompt*: país, norma, nível, finalidade.

4. COMO VERIFICAR: O QUE CHECAR E QUANDO CHECAR

Entender a alucinação muda o modo de usar a ferramenta. Não se trata de abandonar o modelo, e sim de saber o que verificar em cada situação. Bang et al. (2023) avaliaram o ChatGPT em 23 conjuntos de dados cobrindo 8 tarefas de processamento de linguagem e mediram acurácia média de 63,41% em 10 categorias de raciocínio, ou seja, o modelo acertou cerca de dois terços das respostas. O número interessa menos pelo valor exato e mais pelo que revela: em tarefas que exigem raciocínio ou fatos específicos, a taxa de erro é alta demais para dispensar verificação.

O nível de exigência depende do uso. Para *brainstorming*, o custo de um erro factual é baixo: o objetivo é gerar pontos de partida, não afirmar fatos. Para pesquisa acadêmica, relatórios técnicos ou qualquer produção em que a precisão importa, a verificação externa é obrigatória. A tabela abaixo gradua essa exigência.

Tipo de uso	Nível de risco	O que verificar
Brainstorming e ideias iniciais	Baixo	Não exige verificação factual. Use as ideias como ponto de partida.
Revisão de conceitos conhecidos	Médio	Cheque definições técnicas e termos específicos em material de referência.
Pesquisa e referências bibliográficas	Alto	Localize cada referência citada na fonte original antes de usar.
Textos técnicos e relatórios	Alto	Valide todos os dados numéricos, normas e afirmações de causa e efeito.
Decisões com consequências reais	Máximo	Não use o <i>output</i> como única fonte. Consulte o documento original (a fonte primária).

Uma rotina prática para o seu semestre: use o modelo para estruturar raciocínio, explorar caminhos e produzir rascunhos; verifique em fonte primária todo dado específico, toda referência citada e toda afirmação técnica que vai entrar em trabalho acadêmico ou profissional. A verificação não é um custo extra do uso de IA. É a etapa que transforma um texto plausível em um trabalho com autoria responsável.

5. O QUE MUDA NA SUA PRÁTICA COMO ESTUDANTE

Tratar como defeito passageiro algo que pertence ao projeto do sistema leva a duas atitudes ruins: esperar que a próxima versão resolva, ou desistir da ferramenta. Quem entende a alucinação como consequência estrutural adota uma terceira posição, a calibragem: o modelo é um sistema de estimativa de plausibilidade, muito útil onde plausibilidade basta e arriscado onde só a verdade factual serve.

Essa posição desloca a responsabilidade para o lugar certo. Um estudante que entrega um relatório com referências inventadas não pode alegar que o modelo errou: a decisão de não verificar foi humana, como foi humana a decisão dos advogados de Mata v. Avianca. A autoria de qualquer produção acadêmica ou profissional continua sendo de quem assina.

Resta uma pergunta que este módulo deixou aberta de propósito. Se a vagueza confortável é um estilo que o modelo aprendeu a preferir, quem ensinou? O próximo módulo apresenta as pessoas invisíveis que ajustam o comportamento desses sistemas, o processo que produz a voz padronizada dos assistentes e o que isso significa para quem escreve com IA.



PARA REFLEXÃO

Na atividade deste módulo, você vai escolher um tema que domina por experiência própria: sua cidade, sua formação anterior, um esporte, um ofício. Vai pedir a um modelo (ChatGPT, Gemini ou Claude) uma explicação detalhada sobre esse tema e mapear onde ele acerta, onde generaliza e onde inventa. A pergunta que orienta a atividade não é "o modelo errou?". É "que tipo de erro apareceu e o que isso revela sobre o funcionamento do sistema?"

O quadro abaixo retoma os conceitos deste módulo.

Conceito	O que significa aqui
Alucinação	Geração de informação falsa ou inventada com a estrutura de uma afirmação confiável.
Alucinação intrínseca	O texto gerado contradiz o material fornecido como base.
Alucinação extrínseca	O texto acrescenta informação que não pode ser verificada no material fornecido.
Memória paramétrica	Conhecimento comprimido nos pesos do modelo durante o treinamento, congelado na data de corte.
<i>Corpus</i> de treinamento	Conjunto de textos usado para ajustar os pesos do modelo.
Plausibilidade	A palavra escolhida é a mais provável estatisticamente, não necessariamente a verdadeira (visto no Módulo 2).
Taxonomia dos cinco tipos	Alucinação factual, viés de <i>corpus</i> , vagueza confortável, coerência sem verdade e ausência de context.

REFERÊNCIAS

As obras abaixo foram usadas como base para o conteúdo deste e-book e são verificáveis nas fontes indicadas.

BANG, Y. et al. A Multitask, Multilingual, Multimodal Evaluation of ChatGPT on Reasoning, Hallucination, and Interactivity. In: **Proceedings of the 13th International Joint Conference on Natural Language Processing (IJCNLP-AACL)**. Nusa Dua: ACL, 2023. Disponível em: <https://aclanthology.org/2023.ijcnlp-main.45/>

GERHARDT, M. Introdução aos Modelos de Linguagem de Grande Escala. In: KATZ, B. et al. **Innovating Engineering Education with Generative AI. Workshop Fulbright**, USP, setembro de 2025. [Módulo 1]

Jl, Z. et al. **Survey of Hallucination in Natural Language Generation**. ACM Computing Surveys, v. 55, n. 12, art. 248, 2023. Disponível em: <https://dl.acm.org/doi/10.1145/3571730>

MATA v. Avianca, Inc. 678 F. Supp. 3d 443. United States District Court, Southern District of New York, 2023. Decisão disponível em: <https://law.justia.com/cases/federal/district-courts/new-york/nysdce/1:2022cv01461/575368/54/>

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
Alucinação como consequência estrutural

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **10 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.