


IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



04

QUINZENA 2

RLHF, GHOST WORK E A ILUSÃO DE UNIVERSALIDADE

QUEM ENSINA A IA A PARECER ÚTIL E POR QUE ELA NÃO FUNCIONA IGUAL PARA TODOS

04

QUINZENA 2

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

RLHF, *GHOST WORK* E A ILUSÃO
DE UNIVERSALIDADE

QUEM ENSINA A IA A PARECER ÚTIL E POR QUE
ELA NÃO FUNCIONA IGUAL PARA TODOS

BASE CONCEITUAL DO MÓDULO 4



ORIGEM DO MATERIAL

O conteúdo deste e-book articula o Módulo 1 do Workshop Fulbright sobre IA na Educação de Engenharia (Gerhardt, 2025) com a pesquisa que fundamenta o RLHF (Christiano et al., 2017; Ouyang et al., 2022), a investigação sobre trabalho humano em IA (Gray; Suri, 2019) e os estudos sobre desequilíbrio linguístico e homogeneização do texto (Bender et al., 2021; Blasi et al., 2022; Padmakumar; He, 2024). Os números citados foram verificados nas fontes primárias indicadas.

Este módulo abre a etapa do treinamento que transforma um previsor de palavras em um assistente educado. Você vai entender como funciona o RLHF, o ajuste feito a partir de avaliações humanas. Vai conhecer o papel dos trabalhadores invisíveis dentro desse processo. E vai ver duas consequências desse modo de construção: o modelo não trata todas as línguas do mesmo jeito e tende a escrever tudo com a mesma voz.

Você já reparou que os assistentes de IA são polidos? Eles não xingam, pedem desculpas quando erram, evitam responder pedidos perigosos. Esse comportamento não nasce do texto da internet. Pesquisadores que testaram modelos treinados apenas com esse texto, sem ajuste posterior, observaram o contrário: toxicidade, inconsistência, respostas inadequadas. A educação dos modelos tem método, tem custo e tem pessoas por trás.

A Quinzena 1 apresentou as três fases do treinamento de um modelo de linguagem: o pré-treino, o ajuste fino e o RLHF. Ela também mostrou que existe trabalho humano invisível sustentando esses sistemas. Este módulo junta as duas histórias em uma só: o RLHF é o lugar onde o trabalho invisível vira o comportamento do modelo.

1. RLHF: COMO O MODELO APRENDE A SE COMPORTAR

RLHF significa *Reinforcement Learning from Human Feedback*, aprendizado por reforço com feedback humano. O e-book do Módulo 2 da Quinzena 1 disse em uma linha o que essa técnica faz: avaliadores humanos classificam respostas e o modelo aprende a preferir as mais bem avaliadas. Agora vamos abrir essa linha e ver como o processo acontece, etapa por etapa, e o que exatamente o modelo aprende no caminho.

Primeiro, o problema que o RLHF resolve. O pré-treino ensina o modelo a prever a próxima palavra. Um modelo que só passou por essa fase completa frases com fluência, mas não sabe conversar: não segue instruções, não recusa pedidos perigosos, não distingue uma resposta útil de uma resposta apenas provável. O RLHF existe para fechar a distância entre prever texto e ajudar uma pessoa.

O processo documentado pela equipe da OpenAI no artigo que descreveu o InstructGPT (Ouyang et al., 2022) funciona em etapas encadeadas. Na primeira, o modelo gera várias respostas diferentes para o mesmo *prompt*: cinco, dez, às vezes mais. Na segunda, trabalhadores humanos comparam essas respostas e as ordenam da melhor para a pior, seguindo critérios definidos pela empresa: utilidade, segurança, tom adequado. Aqui entra a peça que costuma faltar nas explicações rápidas. Um modelo comercial responde a milhões de pedidos por dia, e nenhuma equipe humana consegue avaliar tudo. As comparações feitas pelos trabalhadores servem então de material de treino para um segundo modelo, chamado modelo de recompensa. A única tarefa dele é imitar o julgamento dos avaliadores: ele recebe uma resposta e devolve uma nota, prevendo o quanto um avaliador humano gostaria dela. Na última etapa, o aprendizado por reforço, a técnica em que um sistema melhora por tentativa e recompensa, ajusta o modelo de linguagem para buscar as notas mais altas do modelo de recompensa.

Esse desenho tem uma consequência direta: a preferência de um grupo pequeno de pessoas se multiplica. O modelo de recompensa aprende o gosto de algumas centenas ou milhares de avaliadores e aplica esse gosto a cada resposta que o sistema gera dali em diante. O ajuste funciona bem segundo os próprios critérios: no estudo da OpenAI, os usuários preferiram as respostas do modelo ajustado em 71% das comparações com o modelo original (Ouyang et al., 2022). A pergunta que este módulo faz é outra: funciona segundo o critério de quem?

Etapa	O que acontece	Quem age	Resultado
1. Geração	O modelo produz múltiplas respostas para o mesmo <i>prompt</i> .	Modelo de linguagem	Conjunto de respostas candidatas
2. Comparação	Trabalhadores ordenam as respostas da melhor para a pior, segundo critérios definidos pela empresa.	Avaliadores humanos (<i>ghost workers</i>)	Ordenação de preferências
3. Modelo de recompensa	Um segundo modelo aprende a imitar o julgamento dos avaliadores e passa a dar nota sozinho, em escala.	Modelo de recompensa	Nota automática para qualquer resposta
4. Ajuste	O aprendizado por reforço ajusta o modelo de linguagem para buscar notas altas.	Algoritmo de aprendizado por reforço	Modelo com comportamento ajustado




Figura 1. O ciclo do RLHF: o julgamento humano vira nota automática.
Elaborada a partir de Ouyang et al. (2022).

O ponto crítico que o RLHF revela: o modelo não está aprendendo o que é verdade. Está aprendendo o que os avaliadores preferiram nas respostas que compararam. A origem da técnica confirma isso. O artigo que fundou a área (Christiano et al., 2017) propôs treinar sistemas a partir de preferências humanas justamente para os casos em que ninguém consegue definir de antemão o que seria a resposta correta. A preferência substitui a verdade como alvo do treinamento.

Uma conexão direta com o módulo anterior: lembra da vagueza confortável, o tipo de erro em que o modelo evita posicionamentos claros mesmo quando uma resposta direta seria mais útil? O Módulo 3 deixou uma pergunta aberta de propósito: se a vagueza é um estilo que o modelo aprendeu a preferir, quem ensinou? Agora você tem a resposta. Se os avaliadores penalizaram respostas que geravam controvérsia, o modelo de recompensa aprendeu a dar nota baixa para elas, e o modelo de linguagem aprendeu a evitá-las. A evasão é um comportamento ensinado, não uma falha acidental.

2. GHOST WORK: QUEM ESTÁ DENTRO DO CICLO

Quem são os avaliadores da segunda etapa? A Quinzena 1 já apresentou o termo que descreve esse trabalho: *ghost work*, o trabalho humano invisível que sustenta os sistemas de IA, documentado por Mary Gray e Siddharth Suri, pesquisadores da Microsoft Research (Gray; Suri, 2019). Foi lá também que você conheceu o caso dos moderadores de conteúdo no Quênia, pagos menos de dois dólares por hora para revisar material perturbador (Perrigo, 2023). Este módulo não repete essa história. Ele mostra o que ela tem a ver com o comportamento do modelo que você usa.

No RLHF, o trabalhador invisível não está apenas limpando dados nem filtrando conteúdo. Ele está decidindo o que o modelo vai considerar uma boa resposta. Cada comparação que ele faz, seguindo um manual de instruções escrito pela empresa, vira um exemplo de treino para o modelo de recompensa. O julgamento dele, feito em segundos e repetido milhares de vezes por dia, em geral por tarefa e sem vínculo formal, fica gravado no produto final. Quando o assistente responde com aquele tom prestativo e cauteloso, você está lendo o resultado agregado dessas decisões.

Gray e Suri deram nome a esse padrão: o paradoxo da última milha da automação. Cada avanço que promete eliminar o trabalho humano cria uma nova camada de trabalho humano, necessária para treinar, corrigir e manter o sistema, só que menos visível do que a anterior. A cadeia também tem geografia: as empresas contratam onde a hora de trabalho custa menos. Gray e Suri acompanharam trabalhadores nos Estados Unidos e na Índia; a reportagem do caso queniano mostrou o mesmo arranjo em outro continente.



PONTO CRÍTICO

No RLHF, a invisibilidade do *ghost work* ganha uma camada extra. O que fica escondido não é só o esforço dos trabalhadores: é o julgamento deles. As respostas que você recebe carregam preferências de pessoas que você não vê, aplicadas segundo critérios que você não leu. A pergunta prática que isso deixa para o usuário: quando uma resposta soa equilibrada e segura, equilibrada para quem?

3. A ILUSÃO DE UNIVERSALIDADE: O CORPUS DESEQUILIBRADO

A Quinzena 1 nomeou a ilusão da universalidade: a impressão de que o modelo funciona igualmente bem para qualquer pessoa, em qualquer língua, sobre qualquer assunto. Lá, você viu a consequência: repertório mais raso em português e desigualdade de acesso. Aqui você vai ver o mecanismo que produz essa diferença e uma forma prática de calibrar a confiança por tema.

Pense num tema que você domina. Pode ser sua área de formação anterior, seu bairro, um esporte, um ofício. Agora imagine fazer a mesma pergunta ao modelo duas vezes: uma em português, outra em inglês. Muitos usuários que fizeram esse exercício relataram uma diferença clara: em inglês, a resposta tende a trazer mais dados específicos, mais referências, mais termos técnicos usados com precisão. Em português, a resposta pode sair mais genérica, com menos detalhe.

A diferença começa na composição do corpus, o conjunto de textos usado no pré-treino. No GPT-3, um dos modelos com dados mais documentados publicamente, 93% das palavras do corpus estavam em inglês (Brown et al., 2020). A segunda língua mais presente, o francês, ficava abaixo de 2%. O português aparecia em fração ainda menor. O repertório estatístico do modelo em inglês é, portanto, muito mais denso do que em qualquer outra língua. Você viu no Módulo 1 uma primeira consequência disso: o tokenizador, treinado principalmente em inglês, quebra palavras de outras línguas em mais *tokens*, o que encarece o processamento e consome mais espaço da janela de contexto, o limite de texto que o modelo consegue considerar de uma vez. A segunda consequência é de conteúdo: para temas documentados principalmente em português, ou específicos de contextos brasileiros, o modelo tem menos padrões internos, e o risco de alucinação ou de generalização aumenta.




Figura 2. Distribuição de línguas no corpus de treinamento do GPT-3, em porcentagem de palavras (Brown et al., 2020).

Essa desigualdade não é só uma impressão de usuários: ela já foi medida. Blasi, Anastasopoulos e Neubig (2022) construíram uma forma de estimar a utilidade das tecnologias de linguagem através das cerca de 6.500 línguas do mundo e encontraram desigualdades sistemáticas: as línguas com mais recursos digitais concentram quase todo o desempenho, enquanto a maioria fica com tecnologia de qualidade baixa ou inexistente. O português está numa posição intermediária: é uma das línguas mais faladas do mundo, mas segue atrás do inglês em volume de dados e em desempenho medido. Bender e colegas (2021) já haviam alertado para o risco de construir modelos como se uma língua representasse a experiência linguística de todos.

Para um estudante de engenharia, o efeito prático aparece em situações concretas: normas técnicas brasileiras, legislação nacional, contextos regionais. A tabela abaixo ajuda a calibrar o nível de confiança por tipo de tema.

Situação	Em inglês	Em português	Impacto para o usuário brasileiro
Termos técnicos de engenharia amplamente documentados.	Respostas mais precisas, com referências verificáveis.	Respostas úteis, com alguma perda de especificidade.	Baixo: o conhecimento técnico geral é bem representado.
Normas técnicas e legislação nacional.	Referências internacionais mais precisas.	Risco maior de generalização ou erro factual.	Alto: verificação obrigatória em fontes primárias nacionais.
Contextos regionais e culturais brasileiros.	Pouca cobertura útil.	Cobertura limitada, com risco de estereótipos.	Alto: o modelo não tem repertório adequado para esse contexto.
Temas amplamente cobertos em português (ex.: legislação, cultura).	Perspectiva anglocêntrica.	Melhor cobertura, mas ainda aquém do inglês.	Médio: resultados úteis, mas que exigem checagem crítica.

4. A VOZ PADRONIZADA: AUTORIA SEM AUTOR

Há uma segunda consequência do modo como os modelos foram construídos, mais sutil e igualmente importante para quem vai usar IA em produção acadêmica. Quando o modelo gera texto livremente, tende a produzir sempre o mesmo registro. Registro, na linguística, é o modo de escrever ou de falar que a pessoa ajusta à situação: você não escreve uma mensagem para um amigo do mesmo jeito que escreve um relatório de estágio. O registro típico dos assistentes de IA é neutro, genérico, bem estruturado, sem opinião marcada. Nesta disciplina, chamamos esse fenômeno de voz padronizada.

A voz padronizada tem duas causas, e você já conhece as duas. A primeira vem do pré-treino: o modelo aprende os padrões mais frequentes de milhões de textos e tende a reproduzir a média deles. A segunda vem do RLHF: se os avaliadores preferiram respostas seguras, organizadas e sem arestas, o modelo de recompensa aprendeu a premiar exatamente esse estilo. O resultado é um texto que pertence a ninguém: tem introdução, desenvolvimento e conclusão, usa os termos certos, respeita a gramática, mas não carrega escolhas argumentativas próprias.

Esse efeito já foi medido em experimento controlado. Padmakumar e He (2024) pediram a grupos de pessoas que escrevessem ensaios argumentativos em três condições: sem ajuda, com um modelo de linguagem básico e com um modelo ajustado por *feedback* humano. Quem escreveu com o modelo ajustado produziu textos mais parecidos entre si, com menos variedade de conteúdo e de vocabulário; a redução foi estatisticamente significativa. O modelo básico não causou o mesmo efeito. O estudo liga a homogeneização à etapa de treinamento que você estudou na primeira seção deste *e-book*: o mesmo ajuste que deixa o modelo educado deixa os textos de usuários diferentes cada vez mais iguais.

Para um calouro de engenharia, a implicação é direta. Usar IA para escrever um texto acadêmico inteiro é delegar ao modelo a produção de um texto com voz padronizada. Esse texto pode estar correto em vários níveis técnicos, mas não representa o pensamento de quem o assina, e quem avalia produção acadêmica com frequência reconhece a ausência de escolhas próprias. Isso não significa que usar IA para escrever seja sempre inadequado. Significa que o texto gerado é um ponto de partida, não um ponto de chegada. O trabalho de autoria acontece depois: escolher o que manter, o que reformular, o que questionar, o que acrescentar de perspectiva própria. Autoria é a assinatura do julgamento, não da digitação.

5. O QUE MUDA NA SUA PRÁTICA

Este módulo fecha a parte conceitual da Quinzena 2. Ao longo dos quatro módulos, você viu como o modelo processa texto (*tokens e embeddings*), como ele decide o que é relevante e o quanto arrisca na escolha da palavra seguinte (atenção e temperatura), por que ele erra de formas previsíveis (alucinação como consequência estrutural) e agora quem o ensinou a se comportar e por que ele não funciona igual para todos.

Esse conhecimento é aplicável a cada uso da ferramenta. Saber que o comportamento do modelo foi ajustado por preferências humanas específicas permite questionar o tom das respostas. Saber que o corpus é desequilibrado permite calibrar a confiança por tema e por idioma. Saber que a voz padronizada existe, e que ela nasce do mesmo ajuste que deixa o modelo educado, permite reconhecer quando um texto ainda não tem autoria real.

A ferramenta que parece simples tem uma história longa atrás dela: um corpus desequilibrado, um ciclo de ajuste alimentado por trabalho invisível e uma voz média que se impõe quando ninguém decide no lugar dela. Conhecer essa história não obriga você a nenhuma conclusão imediata sobre usar ou não usar. Mas torna impossível continuar usando com a mesma ingenuidade. Essa perda de ingenuidade é o objetivo central desta quinzena.



PARA REFLEXÃO

Na atividade deste módulo, você vai traduzir um *prompt* para o inglês e rodar as duas versões na mesma ferramenta: ChatGPT (OpenAI), Gemini (Google) ou Claude (Anthropic), a que você preferir. Anote pelo menos três diferenças que observar (de detalhe, de tom, de precisão técnica ou de referências) e registre o achado no fórum individual: ele é o seu registro pessoal de uma assimetria que agora você viu. O módulo tem ainda um quiz de cinco questões sobre RLHF e *ghost work*. A pergunta que orienta a observação não é qual versão é melhor. É: o que a diferença revela sobre como o modelo foi construído e para quem ele foi construído?

REFERÊNCIAS

As obras abaixo foram usadas como base para o conteúdo deste e-book e são verificáveis nas fontes indicadas.

BENDER, E. M. et al. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? In: **FAccT: ACM Conference on Fairness, Accountability, and Transparency**, 2021. p. 610-623. Disponível em: <https://dl.acm.org/doi/10.1145/3442188.3445922>

BLASI, D.; ANASTASOPOULOS, A.; NEUBIG, G. Systematic Inequalities in Language Technology Performance across the World's Languages. In: **Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)**, Dublin, 2022. p. 5486-5505. Disponível em: <https://aclanthology.org/2022.acl-long.376/>

BROWN, T. et al. **Language Models are Few-Shot Learners**. Advances in Neural Information Processing Systems (NeurIPS), 2020. Disponível em: <https://arxiv.org/abs/2005.14165>

CHRISTIANO, P. et al. **Deep Reinforcement Learning from Human Preferences**. Advances in Neural Information Processing Systems (NeurIPS), 2017. Disponível em: <https://arxiv.org/abs/1706.03741>

GERHARDT, M. Introdução aos Modelos de Linguagem de Grande Escala. In: KATZ, A. et al. **Innovating Engineering Education with Generative AI. Workshop Fulbright**, USP, setembro de 2025. [Módulo 1]

GRAY, M.; SURI, S. *Ghost Work: How to Stop Silicon Valley from Building a New Global Underclass*. Boston: Houghton Mifflin Harcourt, 2019.

OUYANG, L. et al. **Training Language Models to Follow Instructions with Human Feedback**. Advances in Neural Information Processing Systems (NeurIPS), 2022. Disponível em: <https://arxiv.org/abs/2203.02155>

PADMAKUMAR, V.; HE, H. Does Writing with Language Models Reduce Content Diversity? In: **International Conference on Learning Representations (ICLR)**, 2024. Disponível em: <https://arxiv.org/abs/2309.05196>

PERRIGO, B. **Exclusive**: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic. Time, 18 jan. 2023. Disponível em: <https://time.com/6247678/openai-chatgpt-kenya-workers/>

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
RLHF, *ghost work* e a ilusão de universalidade

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **12 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.