



RLHF, ghost work e a ilusão de universalidade

Quem ensina a IA a parecer útil e por que ela não funciona igual para todos



Por trás da resposta polida da IA há técnica, trabalho humano e escolhas culturais.



Chatbot



Pessoas avaliadoras



Diversidade e contexto



Dados e sistemas



Ética e impacto



A interface mostra **automação**. O processo revela **mediação humana**.





A IA não nasce educada

O polimento vem de processos posteriores.



Modelos treinados apenas com texto da internet podem ser tóxicos, inconsistentes ou inadequados. O **polimento** vem de processos posteriores.



Tóxico



Inconsistente



Inadequado




Polido por pessoas



RLHF: como o modelo aprende a se comportar

O modelo aprende preferências humanas



1

1. Geração

o modelo cria várias respostas



2

2. Classificação

humanos ranqueiam as respostas



3

3. Ajuste

o modelo aprende a repetir padrões preferidos



RLHF não ensina o modelo a saber a verdade. Ensina quais respostas **humanos preferem** segundo critérios definidos.



Múltiplas respostas



Preferências humanas



Ranking



Recompensa



Melhoria contínua do modelo



O modelo aprende preferências, não verdades

Ele aprende o que é premiado, não o que é necessariamente correto.



A vagueza confortável pode ser ensinada.



Quem trabalha para a IA parecer automática?

Por trás da simplicidade, existe trabalho humano em todo o mundo.



Rotular, classificar e moderar conteúdo são tarefas humanas reais, muitas vezes invisíveis para o usuário final.



Usuário vê:



resposta instantânea



VS

Processo real:



Rotulagem

Dados são identificados e marcados.



Classificação

Informações são categorizadas.



Moderação

Conteúdo é revisado para remover ou sinalizar riscos.



Ajuste

Respostas são avaliadas e corrigidas.



Mapa de trabalho global



Etiquetas de dados



Trabalho invisível



Nem todo custo aparece na tela

Parte do trabalho envolve revisar conteúdos violentos, abusivos ou perturbadores para que eles não apareçam nos outputs.



Conteúdo sinalizado



Protege usuários



Horas de foco e repetição



Decisões que deixam rastro



Conteúdo violento



Abuso verbal



Conteúdo perturbador

Fila de moderação

⚠ Sinalizado

🕒 Em análise

✅ Aprovado

⚠ Sinalizado

🗑 Removido



A interface final é limpa, segura e confiável.



Como posso ajudar você hoje?

Pergunte qualquer coisa...



Seguro

Ambiente protegido



Confiável

Respostas de qualidade



Feito para você

Experiência personalizada



Ghost work não é metáfora.
É trabalho real, realizado por pessoas reais.



A IA não funciona igual para todos

O corpus de treinamento é desequilibrado. O inglês tem presença muito maior do que o português e outras línguas.



EN


Inglês

Explain the causes of the Industrial Revolution.



Chatbot

The Industrial Revolution (18th–19th centuries) was driven by a combination of factors, including technological innovations (steam engine, mechanization), abundant natural resources (coal, iron), capital accumulation, growth of trade and markets, population increase, and institutional changes. These elements interacted to boost productivity, urbanization, and the rise of factories, transforming economies and societies.



O corpus de treinamento é desequilibrado. O inglês tem presença muito maior do que o português e outras línguas.

PT

Português

Explique as causas da Revolução Industrial.



Chatbot

A Revolução Industrial foi causada por fatores como avanços tecnológicos, crescimento do comércio, uso de máquinas e mudanças na sociedade.

...



Mais dados no corpus



Mais repertório estatístico



Resposta mais específica



Menos dados no corpus



Menos repertório estatístico



Maior risco de generalização



Quando o contexto brasileiro fica frágil

Normas técnicas, legislação nacional e contextos regionais exigem verificação em fontes primárias.

MATRIZ DE RISCO

	Termos técnicos gerais — risco menor	BAIXO
	Normas e legislação — risco alto	ALTO
	Contextos regionais — risco alto	ALTO
	Cultura e realidade local — exige checagem	EXIGE CHECAGEM

RESPOSTA DA IA



Segundo a IA, para projeto de lajes em edificações, deve-se seguir a NBR 6118:2014, considerando os limites de flecha indicados...

...

NORMA TÉCNICA BRASILEIRA

ABNT NBR 6118:2023



Projeto de estruturas de concreto — Procedimento

Limites de flecha
Seção 13.3.2

FONTE PRIMÁRIA

PÁGINA OFICIAL

gov.br

Ministério das Cidades

Legislação e Normas

Acesso a normas da ABNT

FONTE OFICIAL

ARTIGO ACADÊMICO



Estudo sobre desempenho de lajes em diferentes regiões do Brasil

Revista de Engenharia Civil
v. 45, n. 2, 2023

FONTE ACADÊMICA

COMPARAÇÃO E ANÁLISE

- ☒ Alinhamento com norma técnica?
- ☒ Base legal atualizada?
- ☐ Contexto regional considerado?
- ☐ Dados e referências confiáveis?



DOCUMENTO OFICIAL



LEGISLAÇÃO



VERIFICAÇÃO



ENGENHARIA

DADOS
CONTEXTOS
CONFIANÇA



Texto correto não é o mesmo que pensamento autoral

A voz padronizada é fluente, neutra e bem organizada, mas pode não revelar julgamento próprio.



A voz padronizada é fluente, neutra e bem organizada, mas pode não revelar **julgamento próprio**.



Autoria é a **assinatura do julgamento**, não da digitação.



Escrever



Pensar



Revisar

ANTES

Texto padronizado gerado por IA


IA

A educação desempenha um papel fundamental no desenvolvimento social e individual. Diversos autores destacam sua importância para a formação cidadã e para o progresso da sociedade. Além disso, é importante considerar os desafios enfrentados na prática educativa, como a desigualdade e a falta de recursos, que impactam os resultados de aprendizagem.

Fluente

Neutro

Bem organizado



Correto. Completo. Impessoal.
Sem posicionamento próprio.

DEPOIS

Texto revisado com autoria e julgamento

A educação desempenha um papel fundamental no desenvolvimento social e individual. **No entanto, no contexto brasileiro, ainda persiste uma desigualdade estrutural** que limita o acesso e a permanência dos estudantes na escola. **O projeto de leitura aumentou em 30% a participação dos alunos**, evidenciando que práticas significativas fazem diferença.^[1]

Contexto

Evidência

Posicionamento

Referência

COMENTÁRIOS

Contexto específico (Brasil)

Evidência concreta (Dados do IBGE)

Exemplo real (Proj. Leitura)

REFERÊNCIAS

[1] IBGE. PNAD 2023.

[2] Silva, J. (2021).

...



Revisado. Argumentado. Autoral.
Com julgamento e assinatura própria.



1. TEXTO GERADO

Fluente, genérico, sem posicionamento.



2. REVISÃO CRÍTICA

Questiona, investiga, identifica lacunas.



3. ESCOLHA AUTORAL

Inclui evidências, exemplos e posicionamento.



4. TEXTO COM JULGAMENTO

Assume posição e sustenta com critérios próprios.



O que muda na sua prática

Use IA calibrando confiança: pergunte, compare, verifique, contextualize e assuma autoria.



RLHF — comportamento aprendido

Modelos respondem a partir de padrões de recompensa humana.



Ghost work — trabalho invisível

Rotuladores, moderadores e curadores sustentam a IA sem visibilidade.



Corpus desequilibrado — desigualdade linguística

Línguas e culturas com mais dados têm mais voz e alcance.



Voz padronizada — risco autoral

Textos tendem à homogeneidade, ameaçando a singularidade e a autoria.



Perder a **ingenuidade** é o objetivo desta quinzena.



Pergunte
com clareza



Compare
com critério



Verifique
com rigor



Contextualize
com propósito



Assuma
sua autoria



Escolhas
éticos, sempre