

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



03

QUINZENA 3

QUANDO A IA ACERTA UMA TAREFA
E ERRA A VIZINHA

03

QUINZENA 3

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

QUANDO A IA ACERTA UMA TAREFA
E ERRA A VIZINHA

INTRODUÇÃO

O QUE VOCÊ VAI ENCONTRAR AQUI

1. A fronteira de competência é irregular
2. Por que a fronteira é irregular: a questão da frequência
3. Por que o erro não vem com aviso
4. Três perguntas para decidir quando verificar
5. O que fazer com isso ainda nesta semana
6. Referências, com endereço para conferir

Tempo estimado de leitura: 10 minutos



ORIGEM DO MATERIAL

A ideia de fronteira irregular vem do experimento de Dell'Acqua, McFowland III, Mollick e colegas (2023), da Harvard Business School. A explicação pela frequência nos dados de treinamento se apoia em Kandpal et al. (ICML 2023) e na revisão de Ji et al. (2023). A discussão sobre o tom confiante usa Kalai et al. (2025), que é um *preprint*: um trabalho divulgado antes de passar pela revisão de outros pesquisadores da área. O caso jurídico é Moffatt v. Air Canada (2024). Todos os números vêm dessas publicações, e os endereços estão nas referências para você conferir.

Em novembro de 2022, um passageiro canadense entrou no site de uma companhia aérea para comprar uma passagem de última hora, depois da morte da avó. Perguntou ao atendente virtual do site se havia desconto para esse caso. O atendente respondeu que sim, e que ele poderia pedir o reembolso da diferença em até noventa dias depois da compra. Ele comprou, viajou e pediu o reembolso.

A companhia recusou. A política real da empresa não permitia pedido depois da viagem. O atendente virtual tinha dado uma informação que não existia, com a mesma naturalidade com que dava informações corretas o dia inteiro. O caso foi parar no tribunal, e a defesa da empresa é o detalhe que interessa a você:

alegou que o atendente virtual era uma entidade separada, responsável pelos próprios atos.

O tribunal rejeitou o argumento. O atendente é parte do site, e a empresa responde por tudo o que está no site dela. (Moffatt v. Air Canada, 2024)

Guarde duas coisas dessa história. A primeira é que o erro tinha cara de acerto: uma frase bem construída, plausível, sobre um assunto banal. A segunda é que a **responsabilidade recaiu sobre a empresa**, e a máquina seguiu respondendo perguntas no dia seguinte. Este módulo é sobre reconhecer, antes de usar, onde esse tipo de erro se concentra.

1. A FRONTEIRA DE COMPETÊNCIA É IRREGULAR

Comece por uma situação mais próxima. Você pede à IA que explique um conceito de cálculo e a explicação vem clara, bem estruturada, com exemplos. No dia seguinte, pede que ela resolva um exercício de física do seu professor, com a notação que ele usa, no contexto da matéria daquela semana. A resposta parece igualmente convincente. Você compara com o gabarito e está errada.


A intuição comum é que uma ferramenta dessas tem um limite de dificuldade: acerta tudo até certo ponto e falha do ponto em diante. **O limite existe, e ele é irregular:** a IA acerta tarefas que parecem difíceis e erra tarefas que parecem simples. A dificuldade aparente decide pouco.

Quem deu nome a isso foi a equipe da Harvard Business School que estudou 758 consultores usando IA em tarefas reais de trabalho, o mesmo experimento que o Módulo 2 apresenta. Os autores chamaram esse limite de **fronteira irregular**, em inglês *jagged frontier*. E mediram os dois lados dela. Nas tarefas de dentro, os consultores que usaram a ferramenta entregaram trabalho com qualidade mais de 40% superior. Em uma tarefa cuidadosamente escolhida para ficar de fora, as mesmas pessoas tiveram 19 pontos percentuais a menos de chance de chegar à resposta correta, na comparação com quem

A FRONTEIRA DE COMPETÊNCIA NÃO É UMA LINHA RETA

O que separa acerto de erro não é a dificuldade aparente da tarefa.

Figura 1. A mesma ferramenta, a mesma pessoa, resultados opostos conforme o lado da fronteira.



Termo cunhado por Dell'Acqua, McFowland III, Mollick e colegas (2023) como *jagged frontier*, a fronteira irregular.



PONTO CRÍTICO

Toda ferramenta tem limite, e a IA acompanha a regra. O que torna esta fronteira perigosa é **ela ser invisível de fora**: nada no resultado indica de que lado da linha você está. A tarefa que a IA domina e a tarefa em que ela falha chegam até você com a mesma cara.

2. POR QUE A FRONTEIRA É IRREGULAR: A QUESTÃO DA FREQUÊNCIA

A explicação vem de como o modelo foi construído, e a Quinzena 2 já preparou o terreno: um modelo de linguagem produz o que é estatisticamente frequente nos dados com que foi treinado. A consequência é direta. Assunto que aparece muito nesses dados, ele reproduz bem. Assunto que aparece pouco, ele reproduz mal.

Isso foi medido. Kandpal e colegas, em trabalho apresentado na *International Conference on Machine Learning* de 2023, fizeram uma coisa engenhosa. Pegaram perguntas factuais, foram até os dados de pré-treino do modelo, o grande conjunto de textos com que ele aprendeu antes de qualquer ajuste posterior, e contaram


quantos documentos existiam ali sobre cada assunto. Depois cruzaram essa contagem com o acerto do modelo em cada pergunta.

A relação apareceu limpa: quanto menos documentos, menos acerto. E os autores foram além. Estimaram o que seria preciso para o modelo acertar bem as perguntas com pouco apoio nos dados, e a resposta é desanimadora: seria necessário aumentar o tamanho dos modelos **em muitas ordens de grandeza**, ou seja, multiplicá-lo por dez, por cem, por mil, e ainda seguir multiplicando. Ou seja, isso é uma característica de como esses sistemas aprendem, e o caminho de simplesmente aumentar o modelo esbarra nesse limite.

QUANTO MENOS O ASSUNTO APARECE NO TREINAMENTO, MENOS A IA ACERTA

Relação medida entre o número de documentos sobre um fato nos dados de pré-treino e o acerto nas perguntas sobre ele.

Figura 2. A frequência do assunto nos dados de treinamento é o que melhor prevê o acerto.



Forma da relação segundo Kandpal, Deng, Roberts, Wallace e Raffel (ICML 2023). A curva é ilustrativa: o estudo mede a tendência, não estes pontos.

Repare onde isso coloca a sua vida. A notação do seu professor, o regulamento da sua universidade publicado neste semestre, a terminologia interna da empresa onde você estagia, a norma técnica que mudou no ano passado: **tudo isso mora na parte rara da curva.** E é justamente esse tipo de informação que você mais precisa acertar, porque é o que o seu contexto cobra.



DICA PRÁTICA

Antes de perguntar, faça um teste de dez segundos: **esse assunto está em mil sites ou está em três?**

Se a resposta que você espera poderia ter sido escrita por qualquer pessoa do mundo, você está na parte segura. Se ela depende de um documento específico da sua instituição, da sua empresa ou do seu semestre, você está na parte de risco, e o resultado precisa ser conferido na fonte original antes de ser usado.

3. POR QUE O ERRO NÃO VEM COM AVISO

Falta explicar a parte mais incômoda. Se o modelo não sabe, por que ele não diz que não sabe? Por que a resposta errada chega com o mesmo tom seguro da resposta certa?

Existe uma explicação recente e bem simples para isso, proposta em 2025 por pesquisadores da OpenAI e do Georgia Tech. **Esse trabalho é um preprint**, ou seja, já está público e ainda passa pelo crivo dos pares. Você vai encontrar muito material assim, e saber distinguir um preprint de um artigo já revisado faz parte do que esta disciplina desenvolve.

O argumento deles: modelos de linguagem são treinados e avaliados como quem faz prova de múltipla escolha. Nas provas que medem o desempenho desses sistemas, **chutar melhora a nota e responder "não sei" rende zero**. E como são essas provas que orientam o ajuste dos modelos, o comportamento que pontua bem nelas é o comportamento que acaba reforçado. Um modelo que arrisca uma resposta plausível pontua mais do que um modelo que admite incerteza, e depois de milhões de rodadas com esse incentivo o resultado é previsível.

O tom confiante é o comportamento que o sistema de pontuação premiou.

Para você, a consequência prática é a que interessa. **O tom da resposta e a correção da resposta são independentes um do outro**. O sinal que você usaria para avaliar uma pessoa, o jeito de falar de quem está inseguro, fica de fora aqui: a resposta chega com a mesma segurança nos dois casos. Por isso a decisão de verificar é tomada olhando a tarefa, antes de a resposta chegar.

O fenômeno tem um nome na área. Quando um modelo produz conteúdo fluente e factualmente incorreto, a literatura chama isso de **alucinação**. A revisão de

Ji e colegas (2023), publicada na *ACM Computing Surveys*, mapeia o problema em diferentes tarefas de geração de texto e mostra que ele aparece em produtos e empresas diferentes: é uma característica da tecnologia.

4. TRÊS PERGUNTAS PARA DECIDIR QUANDO VERIFICAR

A saída é ter critério explícito para saber onde o risco está concentrado. Desconfiar de tudo paralisa, e ainda desperdiça uma ferramenta que funciona muito bem na maior parte do tempo.

Antes de ler as três, vale separá-las das três do Módulo 2, porque elas se parecem e decidem coisas diferentes. As do Módulo 2 decidem como dividir o trabalho com a ferramenta antes de começar. As desta seção decidem se o resultado que chegou precisa ser conferido antes de ser usado. O ganho de aprendizado aparece nas duas listas porque vale nos dois momentos. Já **auditabilidade** e **verificabilidade** parecem a mesma palavra e guardam sentidos distintos: auditabilidade é conseguir mostrar de onde veio cada parte do trabalho, verificabilidade é ter base suficiente para perceber um erro se ele estiver ali. Dá para ter uma sem a outra.

TRÊS PERGUNTAS ANTES DE ACEITAR UM RESULTADO

Se a resposta for a da faixa cinza, verifique antes de usar.

Figura 3. As três perguntas da verificação. Basta uma resposta na faixa cinza para valer a verificação.

VERIFICABILIDADE	GANHO DE APRENDIZADO	RARIDADE DA SITUAÇÃO
Eu tenho conhecimento para perceber um erro se ele estiver aí?	Fazer isso sozinho me ensina algo que preciso saber neste semestre?	Isso envolve dado local, norma recente ou contexto da minha instituição?
→ Não tenho	→ Sim, ensina	→ Sim, envolve

A solução não é desconfiar de tudo: desconfiar de tudo paralisa. É saber onde o risco está concentrado.

PRIMEIRA: VERIFICABILIDADE

Você tem conhecimento suficiente para perceber um erro, se ele estiver ali? Note o alcance da pergunta: ela mede se você conseguiria **reconhecer que a resposta está errada**, o que é bem mais fácil do que fazer a tarefa sozinho e ainda assim exige base. Se a resposta for não, o caminho é buscar uma segunda fonte, em vez de fazer mais uma pergunta à mesma ferramenta.

Esse é o ponto em que o esforço muda de lugar em vez de desaparecer. A pesquisa da Microsoft Research com a Carnegie Mellon, que o Módulo 2 apresenta, descreve exatamente esse deslocamento: com IA no processo, o trabalho sai da execução e vai para a verificação. Assumir essa segunda parte é o que completa a tarefa.

SEGUNDA: GANHO DE APRENDIZADO

Fazer isso por conta própria ensina algo que você precisa saber neste semestre? O Módulo 2 desenvolve esse critério em detalhe, inclusive com o dado de que o ganho de produtividade com IA é maior justamente para quem tem menos experiência. Aqui basta a versão curta: delegar uma etapa que você precisava internalizar poupa tempo agora e cobra depois, quando o conhecimento for exigido sem apoio.

TERCEIRA: RARIDADE DA SITUAÇÃO

Este é o critério que a seção 2 sustentou com evidência, e é o mais fácil de aplicar porque depende apenas de você conhecer a **origem da informação**. A tarefa envolve dado local, norma recente, terminologia interna, regra da sua instituição? Quanto mais específica a situação, maior a chance de o resultado ser plausível e impreciso, simplesmente porque aquele dado ficou de fora do treinamento da ferramenta.

COMO ISSO APARECE EM CADA EIXO

No Eixo de Computação: a IA explica com precisão o que é uma busca binária, o método que encontra um item em uma lista ordenada cortando a lista ao meio a cada passo, porque é um dos algoritmos mais documentados que existem. Peça a ela para aplicar essa busca a uma lista específica que você criou, com as suas condições, e o código pode vir com um erro sutil no ponto em que a busca deveria parar. O programa é aceito pelo computador, executa até o fim e devolve resultado errado em um caso que você deixou de testar.

No Eixo de Negócios e Produção: a IA escreve um relatório genérico sobre análise de falhas em processos industriais sem dificuldade. Peça a ela para interpretar os dados do laudo de manutenção da empresa onde você estagia, com a terminologia interna que ela nunca viu, e o resultado pode conter imprecisões que só quem conhece o contexto percebe.

O padrão é o mesmo: a tarefa genérica e frequente vai bem; a tarefa local, específica e rara é onde o risco mora.

5. O QUE FAZER COM ISSO AINDA NESTA SEMANA

As três perguntas funcionam antes, e demoram menos de um minuto. O hábito que este módulo pede é pequeno: **antes de aceitar um resultado, decida se ele precisa ser verificado**, olhando a tarefa e não a resposta.

Quando a verificação for necessária, ela tem um procedimento, e é o mesmo do Módulo 1: localize a afirmação da qual o resultado depende para ser verdadeiro, e confira essa afirmação em outro lugar. No caso da companhia aérea, bastaria abrir a página da política de tarifas. Uma consulta rápida à página oficial separava o passageiro de um processo.

! ATENÇÃO, ISTO É SOBRE VOCÊ

O erro invisível fica quieto enquanto você trabalha. Ele aparece depois, na correção, na arguição, na reunião em que alguém conhece o assunto melhor do que você.

E nesse momento a explicação de que a ferramenta escreveu vale pouco. **O tribunal canadense já respondeu a essa defesa:** quem publica responde pelo que publicou.

Uma última observação, para você sair daqui com a impressão certa. Este módulo continua recomendando a ferramenta: os mesmos consultores do experimento de Harvard produziram trabalho melhor com IA na maior parte das tarefas. **O que muda com este módulo é a sua capacidade de decidir, com consciência, quando confiar, quando verificar e quando preferir fazer por conta própria.**



PARA REFLEXÃO

Lembre de um momento deste semestre em que você delegou algo à IA e aceitou o resultado porque ele parecia confiante. Vale reparar no mecanismo, com calma. Aplique as três perguntas àquela tarefa, agora.

Ela era verificável por você? Fazê-la sozinho ensinaria algo de que você precisava? Envolvia informação rara, local ou recente? Guarde a resposta: justificar por escrito uma decisão de uso para uma tarefa concreta é o exercício que a quinzena inteira prepara.

6. REFERÊNCIAS

As obras abaixo foram conferidas nas publicações originais. Os endereços estão indicados onde existem.

DELL'ACQUA, F.; McFOWLAND III, E.; MOLLICK, E. et al. *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. Harvard Business School Working Paper 24-013, 2023. DOI da versão em periódico: 10.1287/orsc.2025.21838. Disponível em: <https://aiinstitute.hbs.edu/navigating-the-jagged-technological-frontier/>

Jl, Z. et al. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, v. 55, art. 248, 2023. DOI 10.1145/3571730. Disponível em: <https://dl.acm.org/doi/10.1145/3571730>

KALAI, A. T.; NACHUM, O.; VEMPALA, S. S.; ZHANG, E. *Why Language Models Hallucinate*. arXiv:2509.04664, 2025. [preprint, não revisado por pares] Disponível em: <https://arxiv.org/abs/2509.04664>

KANDPAL, N.; DENG, H.; ROBERTS, A.; WALLACE, E.; RAFFEL, C. Large Language Models Struggle to Learn Long-Tail Knowledge. In: *Proceedings of the 40th International Conference on Machine Learning*. PMLR, v. 202, p. 15696-15707, 2023. Disponível em: <https://proceedings.mlr.press/v202/kandpal23a.html>

LEE, H.-P. et al. The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. Yokohama: ACM, 2025. DOI 10.1145/3706598.3713778. Disponível em: https://www.microsoft.com/en-us/research/wp-content/uploads/2025/01/lee_2025_ai_critical_thinking_survey.pdf

MOFFATT v. AIR CANADA, 2024 BCCRT 149. Civil Resolution Tribunal, Colúmbia Britânica, Canadá, fevereiro de 2024. Comentário disponível em: https://www.americanbar.org/groups/business_law/resources/business-law-today/2024-february/bc-tribunal-confirms-companies-remain-liable-information-provided-ai-chatbot/

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
Quando a IA acerta uma tarefa e erra a vizinha

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **13 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.