

# IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



# 04

## QUINZENA 3

CADA MENSAGEM TEM UM CUSTO  
E A CONTA MUDA CONFORME VOCÊ TRABALHA

# 04

QUINZENA 3

## IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

CADA MENSAGEM TEM UM CUSTO  
E A CONTA MUDA CONFORME VOCÊ TRABALHA

# INTRODUÇÃO

## O QUE VOCÊ VAI ENCONTRAR AQUI

1. Nem toda tarefa custa o mesmo
2. O mesmo trabalho, dois jeitos de fazer
3. Por que o mesmo prompt tem dois números
4. Sustentabilidade é uma competência de julgamento
5. O que fazer com isso ainda nesta semana
6. Referências, com endereço para conferir

**Tempo estimado de leitura: 10 minutos**



### ORIGEM DO MATERIAL

As medidas por tipo de tarefa vêm de um trabalho de Luccioni, Jernite e Strubell, apresentado na conferência FAccT de 2024. Os números por prompt vêm de um relatório técnico publicado pelo Google em agosto de 2025, e são identificados no texto como dado do próprio fornecedor. A discussão sobre água se apoia em um artigo de Li, Yang, Islam e Ren, publicado na *Communications of the ACM* em 2025. A conexão com a taxonomia de competências vem de McOwen (2025), a mesma base do Módulo 1. Todos os valores vêm dessas publicações, e os endereços estão nas referências para você conferir.

Comece pelo número menor do que você imagina. Em agosto de 2025, o Google publicou uma medição do que custa o prompt de texto mediano no Gemini, aquele que fica bem no meio da distribuição, com metade dos pedidos custando menos e metade custando mais: cerca de **0,24 watt-hora de eletricidade e 0,26 mililitro de água**. O watt-hora é a unidade que mede energia consumida: um aparelho de 1 watt ligado durante uma hora gasta 1 watt-hora. Para dar tamanho ao resto, a própria empresa comparou com assistir televisão por nove segundos. Cerca de cinco gotas de água.

Se você esperava um número dramático, o dado é mais modesto do que isso. E é importante dizer logo: este módulo existe para dar critério de decisão, e a culpa

por mandar mensagem fica de fora. **Uma pergunta isolada pesa pouco.** O que interessa começa uma linha depois: esse número é uma média de um tipo de tarefa, e muda muito quando a tarefa muda, quando o jeito de trabalhar muda e até quando muda apenas a decisão sobre o que entra na conta.

*O custo de uma mensagem é pequeno. O custo de um semestre inteiro de mensagens é uma decisão sua, e é tomada sem que ninguém a apresente como decisão.*

Este é o último módulo da quinzena, e ele fecha um raciocínio. Você já viu quais competências ficam e quais mudam, dois modos de trabalhar com a ferramenta e como decidir quando verificar um resultado. Falta um critério que a tela guarda para si: o que a sua forma de trabalhar consome.

# 1. NEM TODA TAREFA CUSTA O MESMO

A primeira coisa a desfazer é a ideia de que "usar IA" é uma coisa só. Pedir que a ferramenta classifique um texto, pedir que ela escreva um texto e pedir que ela desenhe uma imagem são operações diferentes por dentro, e o custo entre elas varia **por ordens de grandeza**, ou seja, por fatores de dez, de cem, de mil.

Quem mediu isso com cuidado foi a equipe de Sasha Luccioni, Yacine Jernite e Emma Strubell, em trabalho apresentado na *ACM Conference on Fairness, Accountability, and Transparency* de 2024, uma das principais conferências sobre efeitos sociais de sistemas computacionais. Os pesquisadores rodaram dezenas de modelos **de código aberto**, aqueles cujo código e cujos parâmetros são publicados, em máquinas sob o controle deles, e mediram a energia efetivamente gasta em cada tipo de tarefa. A escolha tem um motivo prático: só com modelos abertos dá para instalar o sistema e medir o consumo por fora.

**Figura 1.** Energia por mil usos, medida em modelos abertos. A régua é a carga completa de um celular.



*Gerar imagem consome mais de 60 vezes a energia de gerar texto. Entre a tarefa mais barata e a mais cara, a diferença chega a 1.450 vezes.*

Fonte: Luccioni, Jernite e Strubell, FAcCT 2024.

Repare no que a comparação diz. Mil classificações de texto custam quase um décimo de uma carga de celular. Mil imagens geradas custam o equivalente a carregá-lo **cerca de cento e trinta vezes**. Entre a tarefa mais barata e a mais cara do estudo, a diferença chega a mil quatrocentas e cinquenta vezes.

Uma ressalva honesta antes de seguir: esses números vêm de modelos abertos medidos em laboratório, e as ferramentas comerciais que você usa trabalham com outros valores. **O que se transporta daqui é a proporção entre eles.** Gerar imagem custa muito mais do que gerar texto, e gerar texto custa muito mais do que apenas analisar um texto que já existe. Essa hierarquia vem do tipo de operação, e por isso tende a se manter de um fornecedor para outro.



#### DICA PRÁTICA

Antes de pedir, repare no verbo do seu pedido. **Analisar, classificar, resumir e extrair são operações baratas.** Gerar texto longo custa mais. Gerar imagem custa muito mais.

Gerar imagem continua sendo uma escolha legítima. O que muda é o cuidado: gerar oito variações de uma capa "para ver como fica" e escolher depois sai bem mais caro do que pensar antes no que você precisa e gerar duas.


## 2. O MESMO TRABALHO, DOIS JEITOS DE FAZER

Agora junte isso ao Módulo 2. Lá você viu dois modos de trabalhar com a ferramenta. No modo **Centauro**, você divide a tarefa antes de começar, delega uma parte delimitada e verifica o resultado depois. No modo **Ciborgue**, você constrói junto com a ferramenta, em trocas contínuas, sem uma divisão prévia clara.

O Módulo 2 comparou os dois modos por critérios de aprendizado e de responsabilidade, e concluiu que cada um serve a um tipo de tarefa. Este módulo acrescenta um ponto que ficou de fora daquela comparação. Os dois modos **consomem quantidades diferentes de energia**, porque produzem um número diferente de requisições ao modelo, ou seja, de vezes em que a ferramenta precisa processar um pedido seu e devolver uma resposta.

Uma tarefa de escrita resolvida em uma sessão, contada em requisições ao modelo.

**Figura 2.** A mesma tarefa de escrita, resolvida de dois jeitos. A diferença está no número de idas e voltas.



*Nenhum dos dois modos é errado. O que muda é que um deles acumula, e a diferença aparece ao longo do semestre.*

Estimativa feita multiplicando o número de requisições pelo consumo por prompt publicado pelo Google (0,24 Wh).

As contagens de 6 e 40 são ilustrativas, e servem para mostrar a ordem de grandeza da diferença.

A aritmética é simples e você pode refazê-la. Se cada requisição de texto custa por volta de 0,24 watt-hora, que é o número do relatório do Google e não o do estudo de laboratório da figura anterior, uma sessão em modo Centauro com meia dúzia de idas e voltas fica na casa de 1,4 watt-hora. Uma sessão em modo Ciborgue com quarenta trocas fica perto de 9,6. **As contagens de seis e quarenta são ilustrativas**, escolhidas para mostrar a ordem de grandeza da diferença, e não medidas de um experimento.

Sozinha, uma sessão dessas pesa pouco. Mesmo as 9,6 watt-hora do modo Ciborgue ficam abaixo da metade de uma carga completa de celular, que são os 22 watt-hora usados como régua na figura anterior. A diferença entre os dois modos, cerca de 8 watt-hora por sessão, ganha peso quando você multiplica. Mantendo as contagens ilustrativas acima, três sessões por dia, cinco dias por semana, dezoito semanas de semestre: são mais de 2 quilowatt-hora por pessoa no semestre. Com colegas fazendo a mesma coisa levam isso a mais de 200 quilowatt-hora, o que uma geladeira doméstica consome em vários meses. **O impacto do uso individual se acumula no hábito.**



## PONTO CRÍTICO

O modo Ciborgue existe porque funciona: em tarefas exploratórias, quando você ainda não sabe onde vai chegar, a troca contínua é justamente o que produz o resultado.

O que este módulo pede é outra coisa: que a escolha entre os dois modos seja **uma escolha**, feita com trinta segundos de pensamento antes de abrir a conversa. Esses trinta segundos costumam eliminar boa parte das idas e voltas, e melhoram o resultado pelo mesmo motivo que reduzem o custo: você sabe o que está pedindo.

## 3. POR QUE O MESMO PROMPT TEM DOIS NÚMEROS

Se você procurar por conta própria quanto custa uma mensagem de IA, vai encontrar valores que divergem entre si, às vezes por dez ou cem vezes. Isso acontece porque **as pessoas estão medindo coisas diferentes e chamando pelo mesmo nome**. Entender essa armadilha vale mais do que decorar qualquer número.

O relatório do Google traz o exemplo mais limpo do mecanismo, porque publica os dois números lado a lado. Responder ao seu pedido envolve dois tipos de peça. Uma é o chip especializado, projetado só para rodar modelos de IA, que faz o trabalho pesado do cálculo. A outra é tudo o que sustenta esse chip: o processador comum do computador, que organiza a tarefa e cuida do resto do sistema, a memória, as máquinas que ficam ligadas em espera para atender o próximo pedido, e a refrigeração do *data center*, o galpão cheio de máquinas onde isso tudo acontece. Contando apenas o chip especializado, o prompt mediano de texto do Gemini custa 0,10 watt-hora. Contando o conjunto inteiro, o mesmo prompt custa 0,24.

### O MESMO PROMPT, DOIS NÚMEROS

Energia de um prompt de texto no Gemini, conforme o que se decide incluir na conta.

**Figura 3.** O mesmo prompt medido de dois jeitos. A diferença é o que se decidiu incluir na conta.

Contando só o chip que processa

**0,10 Wh**

Contando também máquinas ociosas, processador, memória e a estrutura do data center

**0,24 Wh**

*Nenhum dos dois é mentira. A pergunta que separa um do outro é o que entra na conta.*

Fonte: Google, Measuring the environmental impact of delivering AI at Google Scale, agosto de 2025.  
Dado publicado pelo próprio fornecedor, sem verificação independente.



Os dois números são verdadeiros. O primeiro responde "quanta energia o chip gastou". O segundo responde "quanta energia foi preciso para essa resposta existir". **A pergunta que separa um do outro é onde termina o sistema que você está medindo**, e essa decisão é tomada por quem publica o número, antes de o número chegar até você.

A água mostra o mesmo problema de forma ainda mais visível. O relatório do Google informa 0,26 mililitro por prompt, contando o consumo direto de resfriamento nas instalações da empresa. Já Li, Yang, Islam e Ren, em artigo publicado na *Communications of the ACM* em 2025, trabalham com uma conta mais ampla, que inclui a água usada para gerar a eletricidade consumida, e chegam a valores muito maiores para uma conversa inteira. **Os dois estudos tratam de modelos diferentes**, em anos diferentes e com escopos diferentes, e por isso pedem leitura separada, um de cada vez.

#### COMO LER UM NÚMERO DE CONSUMO

Sempre que encontrar um número de consumo de IA, faça três perguntas antes de repassá-lo: **quem mediu, o que entrou na conta e de qual modelo e de qual ano se está falando.**

O número do Google foi publicado pela própria empresa que vende o serviço, e ainda aguarda verificação independente. Ele continua valendo muito: é hoje uma das medições mais detalhadas disponíveis, e a empresa descreve o método que usou. E pede um cuidado a mais na hora de repassá-lo, porque a origem faz parte da informação.

## 4. SUSTENTABILIDADE É UMA COMPETÊNCIA DE JULGAMENTO

Volte ao Módulo 1 por um instante. A taxonomia de competências apresentada lá separa o que permanece, o que muda de forma, o que surge e o que perde espaço. As competências duradouras são as que seguem com você mesmo com a automação por perto, e todas elas têm uma coisa em comum: dependem de julgamento sobre consequências, acima de execução de procedimento.

O raciocínio sobre impacto ambiental está exatamente nessa família. Repare no que ele exige de você: reunir evidência de qualidade desigual, entender o que cada número está medindo, comparar com o benefício da tarefa e decidir. **Todas essas etapas são julgamento.** E essa conta é sua.

*A decisão sobre quanto usar uma ferramenta vem sempre de quem a usa.*

É por isso que este assunto pertence ao mesmo lugar que o Módulo 1 chamou de responsabilidade profissional: quem assina um projeto responde pelas consequências dele, inclusive pelas que ficam fora do resultado imediato. Custo de energia e de água é uma dessas consequências.

#### COMO ISSO APARECE EM CADA EIXO

**No Eixo de Computação:** escolher entre um modelo grande e um modelo menor para uma tarefa simples é uma decisão técnica com consequência ambiental direta. Rodar um modelo pesado para classificar comentários é como usar um caminhão para entregar uma carta. A pergunta profissional é qual é o menor recurso que resolve o problema com a qualidade exigida.

**No Eixo de Negócios e Produção:** quem especifica um processo define quantas chamadas de IA ele vai fazer por dia, e essa especificação vira custo recorrente de energia e de dinheiro. Um fluxo que consulta o modelo a cada etapa e um fluxo que consulta uma vez com o contexto completo entregam resultados parecidos com contas muito diferentes.

**O padrão é o mesmo nos dois casos:** a decisão que importa é tomada no projeto, antes do uso.

## 5. O QUE FAZER COM ISSO AINDA NESTA SEMANA

O que este módulo pede é **intenção antes do uso**, e isso cabe em três hábitos pequenos, que valem tanto pelo resultado quanto pelo consumo.

O primeiro é decidir a tarefa antes de abrir a conversa. Saber o que você quer reduz o número de tentativas, e cada tentativa é uma requisição. O segundo é escolher o verbo certo: quando analisar resolve, peça para analisar. O terceiro é parar em quando a sessão virou hábito e deixou de ser trabalho, aquele momento em que você pede mais uma reformulação sem saber bem o que quer melhorar.

### ATENÇÃO, ISTO É SOBRE VOCÊ

A interface guarda esse custo para si. A tela mostra a resposta e para por aí, e os fornecedores têm pouco motivo para acrescentar um contador.

Isso coloca a estimativa do lado de fora: quem quiser saber precisa procurar, ler método e comparar. **É a mesma competência que você usa para verificar qualquer resultado da ferramenta**, aplicada agora à ferramenta inteira.

## FECHANDO A QUINZENA

Os quatro módulos desta quinzena entregaram quatro instrumentos, e eles funcionam juntos. A **taxonomia de competências** diz o que vale a pena aprofundar na sua formação. Os **dois modos de colaboração** dizem como estruturar o trabalho com a ferramenta. Os **três critérios de verificação** dizem quando desconfiar de um resultado. E o **custo ambiental** diz que a intensidade do uso também é uma escolha sua.

Os quatro respondem à mesma pergunta por ângulos diferentes: **como decidir com critério explícito, em vez de por hábito**. Esta disciplina chama isso de apropriação: o momento em que a ferramenta passa a ser conduzida por você, com cada escolha explicável e sustentável diante de quem perguntar.

### PARA REFLEXÃO

Pense na última semana de uso. Quantas sessões você abriu sem saber exatamente o que queria? Quantas renderam mais do que dez idas e voltas?

A ideia aqui é reparar em quanto do seu consumo vem de trabalho e quanto vem de indecisão. A resposta é diferente para cada pessoa, e só você tem acesso a ela.

## 6. REFERÊNCIAS

As obras abaixo foram conferidas nas publicações originais. Os endereços estão indicados onde existem.

DELL'ACQUA, F.; McFOWLAND III, E.; MOLLIICK, E. et al. *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. Harvard Business School Working Paper 24-013, 2023. DOI da versão em periódico: 10.1287/orsc.2025.21838. Disponível em: <https://aiinstitute.hbs.edu/navigating-the-jagged-technological-frontier/>

GOOGLE. *Measuring the environmental impact of delivering AI at Google Scale*. Google Cloud, agosto de 2025. [relatório técnico do próprio fornecedor, sem verificação independente] Disponível em: <https://cloud.google.com/blog/products/infrastructure/measuring-the-environmental-impact-of-ai-inference>

LI, P.; YANG, J.; ISLAM, M. A.; REN, S. Making AI Less "Thirsty": Uncovering and Addressing the Secret Water Footprint of AI Models. *Communications of the ACM*, v. 68, n. 7, p. 54-61, 2025. DOI 10.1145/3724499. Disponível em: <https://dl.acm.org/doi/10.1145/3724499>

LUCCIONI, S.; JERNITE, Y.; STRUBELL, E. Power Hungry Processing: Watts Driving the Cost of AI Deployment? In: *Proceedings of the 2024 ACM Conference on Fairness, Accountability, and Transparency (FAccT '24)*. Rio de Janeiro: ACM, 2024. p. 85-99. DOI 10.1145/3630106.3658542. Disponível em: <https://facctconference.org/static/papers24/facct24-6.pdf>

McOWEN, B. Engineering Competency Evolution in the AI Era. In: KATZ, A.; KIM, D. et al. (org.). *Integrating Artificial Intelligence into Engineering Education*. Workshop. São Paulo: USP, setembro de 2025.

# CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**  
Coordenação: **Wesley de Souza Lima**  
Design Instrucional: **Claudia Mori**  
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**  
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:  
**Cada mensagem tem um custo  
e a conta muda conforme você trabalha**

Local de publicação:  
**São Paulo, Brasil**

Instituição: **Univesp**  
Ano de publicação: **2026**  
Número de páginas: **13 p.**  
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



**ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)**

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.