IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



03

QUINZENA 4

A JANELA INTEIRA, E OS TRÊS LIMITES QUE ELA NÃO RESOLVE

UNIVESP
Universidade Virtual do Estado de São Paulo

03

QUINZENA 4

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

A JANELA INTEIRA, E OS TRÊS LIMITES QUE ELA NÃO RESOLVE

INTRODUÇÃO

O QUE VOCÊ VAI ENCONTRAR AQUI

1. A janela tem mais coisa do que a sua instrução
2. A janela tem tamanho, e o que você põe no meio dela se perde
3. O treinamento não cobriu todos os assuntos do mesmo jeito
4. Você é o último filtro, e nem sempre percebe o erro
5. O que fazer quando o limite é de janela, de domínio ou de verificação
6. Referências, com endereço para conferir

ORIGEM DO MATERIAL

A organização da quinzena em torno da janela de contexto vem do Workshop Fulbright sobre IA na Educação em Engenharia, realizado na USP em setembro de 2025 (Katz et al., 2025). As evidências vêm de seis estudos revisados por pares: Liu et al. (TACL, 2024), Mallen et al. (ACL, 2023), Linardon et al. (JMIR, 2025), Krupp et al. (HHAI, IOS Press, 2024), Perry et al. (ACM CCS, 2023) e Pádua e Peixoto (Revista Brasileira de Direito, 2025). Entram ainda um pré-print assinalado, um acórdão do TJ/PR e a documentação técnica da Anthropic e da OpenAI. Os números foram conferidos nas publicações de origem, e os endereços estão nas referências..

Você separou as informações da tarefa, escreveu os quatro componentes, conferiu tudo antes de enviar. E o resultado voltou com um erro de conteúdo, uma informação que simplesmente não confere. Os dois módulos anteriores trataram da resposta genérica. Este trata do erro que aparece mesmo quando a instrução está bem construída.

Você está numa cidade desconhecida, com o celular sem bateria, e pergunta a alguém na calçada como se chega à rodoviária. A pessoa responde na hora: segunda à direita, depois sempre em frente, uns dez minutos a pé. Responde com segurança, sem hesitar. Você agradece e vai. Vinte minutos depois, você está num lugar que não é a rodoviária.

Ninguém mentiu ali. E três coisas bem diferentes podem ter acontecido, sem que você tivesse como saber qual delas foi. Talvez você não tenha dito que estava a pé e com uma mala, e a pessoa tenha respondido pensando em quem vai de carro: faltou uma informação que mudaria a resposta. Talvez a pessoa também não fosse dali e tenha respondido assim mesmo, com a mesma cara de quem sabe. Ou talvez você não conhecesse a cidade o bastante para desconfiar enquanto ouvia a resposta.

As três coisas acontecem numa conversa com uma ferramenta de IA, e cada uma tem nome próprio. Ao final desta leitura, você vai conseguir olhar para um resultado que deu errado e dizer quais dos três limites estão em jogo ali. Costuma ser mais de um, e cada um pede uma providência diferente. Antes disso, falta olhar a janela inteira, com tudo o que ela guarda além do que você digitou.

1 A JANELA TEM MAIS COISA DO QUE A SUA INSTRUÇÃO

O Módulo 1 deu nome ao texto único que o modelo lê antes de escrever a primeira palavra da resposta: janela de contexto. A sua mensagem ocupa um lugar dentro dela, e esse lugar também tem nome: instrução. Os quatro componentes do Módulo 2 organizam o que vai ali dentro. Falta olhar o resto da janela, e é disso que trata esta seção.

Fora a instrução, outras três coisas entram na janela por decisão sua.

OS EXEMPLOS

Um exemplo é um pedaço de texto pronto que você cola junto com o pedido, para mostrar o tipo de resposta que quer. Suponha que precise escrever o quarto aviso do semestre para o seu grupo de trabalho. Em vez de descrever o tom que deseja, cole os três avisos anteriores, aqueles que funcionaram, e peça o quarto no mesmo feitio. Mostrar costuma render mais do que descrever: a palavra “informal” significa coisas diferentes para pessoas diferentes, e um texto que já ficou do jeito que você queria deixa pouca margem de interpretação.

AS FONTES FORNECIDAS

Uma fonte fornecida é o material que você entrega para o modelo ler: o arquivo anexado, o trecho colado, a tabela de dados. Cuidado com essa palavra, porque ela tem dois empregos aqui. Fonte fornecida é o documento que você entrega; na seção de referências, fonte é a publicação onde um dado foi conferido. Um exemplo do primeiro caso: colar o enunciado inteiro do trabalho, com as palavras exatas do professor, em lugar de resumi-lo em uma linha. O modelo passa a trabalhar com as exigências como elas foram escritas, inclusive as que você não teria repetido de memória.

O HISTÓRICO

Tudo o que já foi dito naquela conversa continua na janela, e continua pesando na resposta seguinte. Há meia hora você pediu um texto “bem solto, bem informal”, para outra finalidade. Agora pede uma mensagem para a coordenação do curso, e

a resposta volta com um tom estranhamente relaxado. A explicação está algumas telas acima. Fechar aquela conversa e abrir outra tira o pedido antigo da janela.

PRIMEIRA VEZ AQUI

Conversa nova. Nas ferramentas de IA existe um botão de nova conversa, quase sempre no canto da tela, com um sinal de mais. Ele abre uma janela sem nada do que foi dito na conversa anterior. Trocar de assunto dentro da mesma conversa mantém tudo o que veio antes; começar uma conversa nova limpa a mesa. Algumas ferramentas guardam lembranças de uma conversa para outra, e o box Um passo além, mais adiante, explica como essas lembranças chegam à janela

Existe ainda um lugar na janela que não pertence a você: as ordens fixas que a empresa deixou na ferramenta, apresentadas no Módulo 1. Elas ocupam espaço antes de você digitar a primeira letra.

Preste atenção nessa conta, porque ela costuma confundir numa primeira leitura. **Quatro lugares da janela são seus**: a instrução, os exemplos, as fontes fornecidas e o histórico. O quinto é da ferramenta, e você não escreve nem lê o que está nele. **E a instrução, por dentro, tem quatro componentes:** Papel, Objetivo, Restrições e Formato. São dois quatros diferentes, e o segundo mora dentro do primeiro.

CONCEITO-CHAVE

Engenharia de contexto. O Módulo 1 deu o nome e a definição: decidir o que entra na janela e o que fica de fora. Esta seção acrescenta o conteúdo desse trabalho: os quatro lugares sob o seu controle, mais o quinto que a ferramenta ocupa sem pedir licença. A empresa que desenvolve o Claude descreve a prática como escolher e manter, a cada passo, o conjunto de informações que o modelo vai ler (Anthropic, 2025). É o trabalho que dá nome a esta quinzena.

Você não escreve a janela inteira. Você decide o que entra nela.

UM PASSO ALÉM

Se você já usa IA todo dia, a esta altura tem uma objeção pronta: a ferramenta busca na internet e se lembra de conversas antigas. As duas coisas são verdade, e nenhuma delas contraria o que está escrito acima. Quem vai à internet é o programa em volta do modelo, que faz a busca e **cola o resultado dentro da janela** antes de o modelo responder. A documentação da Anthropic diz isso com todas as letras: a ferramenta carrega cada resultado de busca na janela de contexto. E a documentação da OpenAI descreve as lembranças guardadas como parte do contexto que a ferramenta usa para gerar a resposta.

O modelo nunca sai da janela para buscar informação. O programa em volta dele traz a informação até ali. E, como qualquer outro texto colado na janela, busca e memória gastam espaço dela.

Um modelo de linguagem trabalha com duas fontes: o que está na janela daquela conversa e o que ficou do treinamento, aquela leitura enorme feita antes de você chegar. Cada uma das duas tem um limite próprio, e existe um terceiro, que mora em quem lê o resultado. As três seções seguintes tratam de um limite cada. Antes de seguir, faça um teste de um minuto: abra a última conversa em que a resposta saiu torta e compare o que a tarefa exigia com o que você tinha colocado dentro da janela naquela hora. Quase sempre aparece algo que ficou de fora.

2. A JANELA TEM TAMANHO, E O QUE VOCÊ PÕE NO MEIO DELA SE PERDE

O primeiro limite é o mais direto de entender e chama-se **limite de janela**. Ele tem duas caras. A primeira aparece na tela da videoaula deste módulo: o modelo não tem acesso ao que não foi enviado. Se o enunciado do trabalho ficou no papel, em cima da mesa, ele não existe para a ferramenta, e a resposta sai completa e bem escrita, mas ignora a exigência que estava lá. A segunda cara é menos conhecida: o modelo também pode deixar de usar o que você enviou em excesso ou colou no lugar errado da pilha.

Dito assim, o limite sugere uma regra simples: coloque tudo dentro da janela, por garantia. A regra não se sustenta, e existe pesquisa que mede isso.

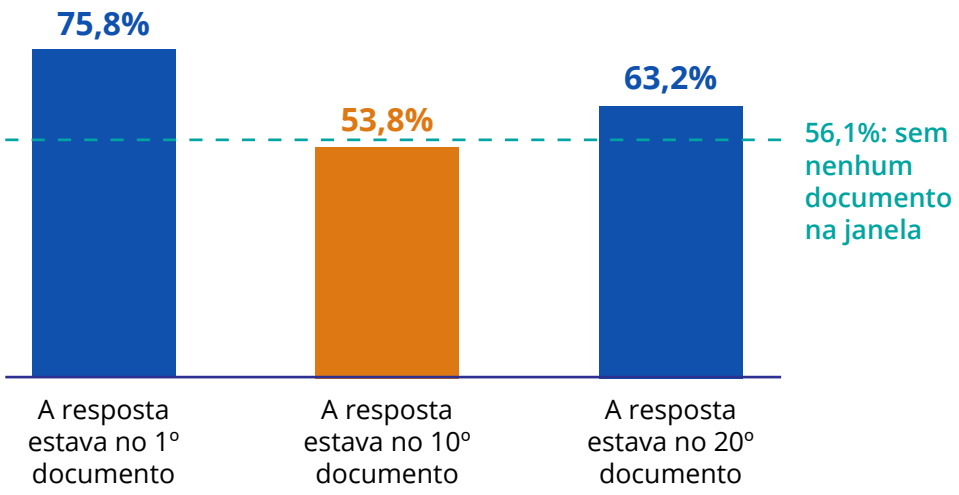
Uma equipe de pesquisadores de universidades americanas montou o teste de um jeito engenhoso. Colou vinte documentos numa conversa, fez uma pergunta cuja resposta estava em um único deles e foi mudando a posição desse documento dentro da pilha. Com o documento certo no começo, o modelo acertou 75,8%

das perguntas, uns 76 em cada 100. Com ele no fim, 63,2%. Com ele bem no meio, 53,8%, pouco mais da metade. E o mesmo modelo, sem nenhum documento na janela, respondendo apenas com o que ficou do treinamento, acertou 56,1% (Liu et al., 2024). O modelo testado foi o GPT-3.5-Turbo, uma versão de 2023 do programa que trabalha por dentro do ChatGPT.

Leia os dois últimos números juntos, porque é neles que está a lição. Colar vinte documentos e enterrar o decisivo no meio deixou o resultado abaixo do que se obtinha sem documento nenhum. Os autores testaram também versões desse modelo e de outros preparadas para textos bem mais longos, e a janela maior não fez o modelo aproveitar melhor o que estava dentro dela.

Figura 1. Onde estava a resposta, dentro dos vinte documentos colados na conversa.

Perguntas respondidas corretamente, conforme a posição da resposta na pilha



Barra laranja: a resposta estava no meio da pilha. Linha verde tracejada: o mesmo modelo, sem documento nenhum. Um único modelo, o GPT-3.5-Turbo, de 2023, em perguntas com resposta certa e verificável. Liu et al. (2024).

Duas ressalvas honestas, e elas importam. Os quatro valores acima vêm de um único modelo, de 2023, e nada garante que a queda tenha hoje esse tamanho. A tarefa era responder perguntas com resposta certa e verificável, um recorte estreito do que você faz com IA. Os valores de cada posição estão nas tabelas do fim do artigo, caso você queira conferir. O que o estudo sustenta é mais modesto do que uma lei geral: a posição da informação dentro da janela muda o resultado, e o meio da pilha é a pior posição de todas.

Some a isso o que o Módulo 1 já mostrou: os modelos anunciam um tamanho de janela, mas sustentam o desempenho só em parte dele; a perda começa muito antes do limite anunciado.

Encher a janela também é uma decisão, e ela cobra um preço.

A consequência prática tem duas partes. A primeira é fornecer o que falta, e para isso você precisa saber o que falta antes de começar a conversa. A segunda é cortar o que não serve: o documento inteiro quando bastavam duas páginas, a conversa de ontem que continua aberta. E ponha o que é decisivo no começo ou no fim do que você cola, porque o meio da pilha é o pior lugar para uma informação que a resposta não pode ignorar.

Some a isso o que o Módulo 1 já mostrou: os modelos anunciam um tamanho de janela, mas sustentam o desempenho só em parte dele; a perda começa muito antes do limite anunciado.

3. O TREINAMENTO NÃO COBRIU TODOS OS ASSUNTOS DO MESMO JEITO

O segundo limite é mais sutil e chama-se **limite de domínio**. A definição técnica, que aparece na tela da videoaula, diz que a tarefa está fora da distribuição do treinamento, e a palavra distribuição pede tradução. Distribuição, aqui, é o mapa do que existe escrito: quanto de cada assunto apareceu na leitura enorme que formou o modelo. Alguns assuntos aparecem muitíssimo por aí. Outros quase não aparecem. Diante de um assunto raro, o modelo continua respondendo, e responde com o mesmo tom de segurança que usa no assunto comum.

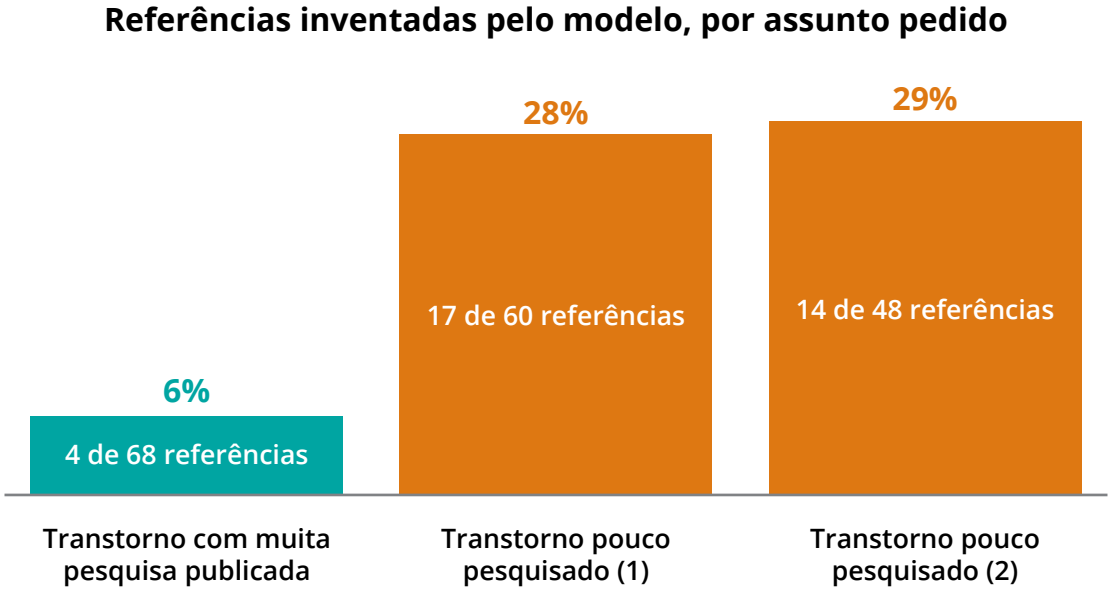
Uma equipe australiana foi medir isso de um jeito que interessa a quem estuda. Escolheu três transtornos de saúde mental, um muito pesquisado e dois pouco estudados, e fez ao mesmo modelo dois pedidos de revisão de literatura para cada um, sempre com pelo menos vinte referências. Uma revisão de literatura é o texto que reúne o que já foi publicado sobre um assunto, com a lista das publicações no fim. Foram seis pedidos e 176 referências, conferidas uma a uma. Trinta e cinco não existiam: 4 de 68 no transtorno mais pesquisado, ou 6%, enquanto nos dois pouco estudados foram 17 de 60 e 14 de 48, ou 28% e 29% (Linardon et al., 2025). O modelo foi o GPT-4o, versão mais recente do mesmo programa por dentro do ChatGPT.

O estudo trouxe ainda um número que muda a forma de conferir. Entre as 141 referências que existiam de verdade, 64 traziam algum erro, quase metade delas, e na maior parte dos casos o erro era um endereço digital inválido. Achar o artigo não basta: os dados da referência precisam bater com a publicação.

PRIMEIRA VEZ AQUI

DOI. É o endereço permanente de um artigo publicado, uma sequência que começa com 10. e serve como número de registro. Digitado numa busca, leva à publicação exata. Uma referência com DOI errado parece completa e não leva a lugar nenhum, e esse tipo de erro passa fácil quando você está com pressa.

Figura 2. Referências inventadas nos seis pedidos de revisão de literatura, agrupadas pelo assunto.



E entre as 141 referências que existiam de verdade, 64 traziam erro: quase metade.

Um único modelo, o GPT-4o, em seis pedidos de revisão de literatura sobre três transtornos: 176 referências ao todo.

Linardon et al. (2025). Os números descrevem esse experimento, e valem para ele.

As ressalvas, de novo. Foi um único modelo, uma única resposta por pedido e uma única área do conhecimento. Os números descrevem aquele experimento, e ninguém deve tomá-los como taxa de invenção da IA em geral. A direção, porém, aparece com clareza: quanto menos escrito existe sobre o assunto, mais o modelo preenche a lacuna por conta própria.

Há um mecanismo plausível para isso, medido em outra tarefa. Um grupo de pesquisadores comparou o acerto de vários modelos em perguntas sobre fatos muito citados e sobre fatos pouco citados, e o acerto caía conforme o fato aparecia menos nos textos de treinamento (Mallen et al., 2023). São tarefas diferentes das do estudo anterior, e ligar os dois resultados é uma leitura nossa. Essa leitura ajuda a formular uma pergunta que você pode fazer antes de abrir a conversa: sobre este assunto existe muita coisa publicada, ou eu estou pedindo justamente aquilo que quase ninguém escreveu?

Duas notas sobre o Brasil, porque a desigualdade do treinamento também é linguística. Um teste recente de modelos em português mediu, num grupo de tarefas traduzidas do inglês, uma diferença média de 3,5 pontos na taxa de acerto, a favor do inglês: em cem perguntas, o mesmo modelo acerta três ou quatro a mais quando a pergunta chega em inglês (Almeida et al., 2025). É um texto que ainda não passou pela leitura crítica de outros pesquisadores, e o número descreve aquele grupo de tarefas.

A segunda nota vem dos tribunais. Em junho de 2026, o Tribunal de Justiça do Paraná puniu um advogado porque o documento que ele entregou no processo citava um acórdão, que é a decisão tomada por um grupo de juízes, e ninguém encontrou essa decisão nas bases do Superior Tribunal de Justiça. A multa foi de 2% sobre o valor discutido no processo, e o tribunal ainda comunicou o caso à Ordem dos Advogados do Brasil, o conselho que fiscaliza a profissão. O próprio tribunal registrou que a peça teria sido confeccionada por inteligência artificial.

E aqui cabe dizer o que ainda não sabemos, porque essa lacuna já ensina algo sobre este limite. Até agosto de 2026 não localizamos nenhum estudo conferido por outros pesquisadores que meça a invenção de referências ou de decisões judiciais sobre legislação brasileira. Um artigo brasileiro testou modelos em tarefas jurídicas e registrou o fenômeno, sem medir a frequência com que ele acontece (Pádua e Peixoto, 2025). Os números que temos vêm de outra área e de outra língua.

⚠ PONTO CRÍTICO

Falta de informação confundida com assunto raro. Os dois primeiros limites produzem erros parecidos na tela, e pedem providências diferentes. Um teste curto separa os dois: se você fornecesse agora, dentro da conversa, a informação que está faltando, isso resolveria?

Se a resposta é sim, o caso é de janela, e a solução está na sua mão. Se você fornecesse o material e ainda assim ficasse em dúvida, o caso é de domínio, e por mais texto que você cole, a conferência na fonte original continua necessária.

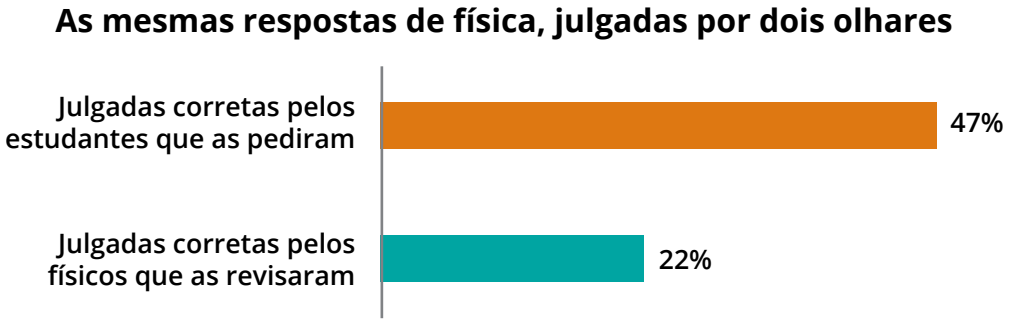
Existe uma providência simples que já serve para esta semana. Sempre que a resposta trouxer uma referência, cole o título dela numa busca acadêmica antes de usá-la. Se o título não aparece em lugar nenhum, você acabou de encontrar uma referência inventada, e gastou vinte segundos nisso. A diferença entre os dois primeiros limites cabe em uma frase, e ela orienta tudo o que vem na seção 5: no limite de janela, fornecer resolve; no limite de domínio, fornecer pode não resolver.

4. VOCÊ É O ÚLTIMO FILTRO, E NEM SEMPRE PERCEBE O ERRO

O terceiro limite muda de lugar. Os dois anteriores falam da ferramenta; este fala de você. Chama-se **limite de verificação**, e a definição, que também vem do letreiro da videoaula, é desconfortável de ler: o estudante não tem domínio para distinguir o certo do errado. O erro está lá, na tela, e passa. Repare na armadilha de vocabulário antes que ela pegue você: no limite de domínio, quem leu pouco sobre o assunto foi o modelo; aqui, quem leu pouco sobre o assunto é você.

O estudo mais próximo da sua situação acompanhou estudantes universitários. Trinta e nove deles resolveram problemas de física, parte com uma ferramenta de IA e parte com um buscador comum. Ao final, os que usaram a ferramenta consideraram corretas 47% das respostas que receberam. Os físicos que avaliaram as mesmas respostas depois consideraram corretas cerca de 22%. Mais da metade do que os estudantes deram por bom estava errado, e eles saíram dali sem saber disso (Krupp et al., 2024).

Figura 3. As mesmas respostas de física, avaliadas por quem as pediu e por quem entende do assunto.



Das respostas que os estudantes deram por certas, 57% os físicos consideraram erradas.

39 estudantes universitários resolvendo problemas de física com ChatGPT, e físicos avaliando as mesmas respostas.
Krupp et al. (2024).

Um segundo estudo mostra o mesmo limite em outra área, e acrescenta um detalhe incômodo. Quarenta e sete pessoas escreveram programas de computador, algumas com um assistente de IA e outras sem. Numa das tarefas, que pedia um recurso de segurança, 3% de quem usou o assistente entregou uma solução segura, enquanto no grupo que trabalhou sem ele o índice foi de 21%; os grupos eram pequenos, e poucas pessoas estão por trás desses percentuais. E quem usou o assistente se declarou mais confiante na segurança do próprio código (Perry et al., 2023). O resultado piorou, e a sensação melhorou.

As ressalvas cabem em duas linhas: os dois estudos são pequenos e as ferramentas testadas são de 2022 e 2023. O que eles medem com solidez é a distância entre o que quem usa achou correto e o que quem entende do assunto achou correto. Essa distância mede o limite de verificação.

O erro que você não sabe ver continua no texto que leva o seu nome.

O perigo específico deste limite tem nome, e a videoaula do módulo o formula bem: ele cria dependência sem construção de competência. Você entrega o trabalho, o texto passa sem reparo, e você continua sem saber julgar aquilo. A defesa contra isso já apareceu duas vezes na sua trajetória, sem este nome: na Quinzena 3 e no módulo anterior, quando você reescreveu as exigências de modo que qualquer pessoa pudesse conferi-las olhando o resultado. Um critério verificável é o instrumento que sobra quando o seu conhecimento do assunto não dá conta de julgar a resposta.

5. O QUE FAZER QUANDO O LIMITE É DE JANELA, DE DOMÍNIO OU DE VERIFICAÇÃO

Os três limites levam à mesma conclusão prática, e a videoaula deste módulo a formula assim: usar a ferramenta com supervisão adequada ao risco da tarefa. Um aviso que você manda para o grupo pede menos cuidado do que um texto que você vai entregar com o seu nome em cima. O procedimento abaixo é curto de propósito, e você aplica antes de abrir qualquer conversa.

Diante do limite de janela, liste o que a tarefa exige e ainda não está escrito em lugar nenhum da conversa: o enunciado, a norma que a tarefa manda seguir, o prazo, o modelo de documento que quem vai receber espera. Forneça isso.

Depois corte o que não serve, inclusive o histórico de assuntos anteriores. A parte difícil é a primeira, e ela acontece antes de você abrir a ferramenta.

Diante do limite de domínio, pergunte se existe muita coisa publicada sobre o assunto. Quando não houver, trate cada referência, número, norma e data como hipótese, e vá conferir na fonte primária, aquela em que a informação foi publicada pela primeira vez: o artigo, o texto da lei, o site oficial. Não conte com o tom da resposta para avisar você, porque ele não muda com o assunto.

Diante do limite de verificação, escreva duas listas antes de pedir qualquer coisa: o que você sabe conferir sozinho e o que não sabe. Escrevê-las leva um minuto, e esse é o hábito que este módulo quer deixar com você.

COMO FAZER, NA PRÁTICA

Na próxima tarefa em que for usar IA, antes de abrir a ferramenta, escreva três linhas num papel ou numa nota do celular. Primeira: o que esta tarefa exige e ainda não está escrito em lugar nenhum. Segunda: qual parte disto é assunto pouco documentado, que eu vou precisar conferir na origem. Terceira, em duas colunas curtas: o que eu consigo julgar sozinho no resultado e o que eu não consigo. O que cair na segunda coluna precisa de outra fonte, de mais tempo de estudo ou de alguém que entenda mais do assunto. As três levam menos tempo do que reescrever o pedido quatro vezes, e servem para qualquer tarefa.

Volte à calçada, agora com os três nomes na mão. A informação que você não deu sobre estar a pé é o limite de janela. A pessoa que respondeu com segurança sobre uma cidade que não conhecia é o limite de domínio. E você, seguindo a resposta sem ter como julgá-la, é o limite de verificação. Na Quinzena 2 a pergunta era por que a IA erra. Aqui a pergunta muda: por que o erro persiste mesmo com um contexto bem construído.

Saber essa diferença muda o que você faz depois que a resposta aparece na tela, e esse trabalho de conferência é a parte que ninguém vê. Conhecer os limites de um instrumento faz parte de saber usá-lo, e não diminui em nada o que ele tem de bom. A responsabilidade sobre o resultado permanece sempre com quem assina, e o nome que vai no trabalho é o seu.

PARA REFLEXÃO

Pense num trabalho que você entregou recentemente, com IA ou sem ela. Se houvesse um erro de conteúdo no meio dele, você teria como perceber? Em que parte do trabalho a sua resposta é sim, e em que parte é não? A parte em que a resposta é não indica onde o seu estudo desta semana rende mais. Ali a ferramenta continua servindo, desde que você acrescente uma conferência a mais.

6. REFERÊNCIAS

Conferimos as obras abaixo nas publicações originais. Os endereços estão indicados onde existem, e o texto que ainda não passou pela leitura crítica de outros pesquisadores está assinalado.

ALMEIDA, Thales Sales et al. PoETa v2: Toward More Robust Evaluation of Large Language Models in Portuguese. arXiv:2511.17808, nov. 2025. Pré-print, texto que ainda não passou pela leitura crítica de outros pesquisadores. Disponível em: https://arxiv.org/abs/2511.17808

ANTHROPIC. Effective context engineering for AI agents. Anthropic Engineering, 29 set. 2025. Disponível em: https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents

ANTHROPIC. Web search tool. Claude Docs, [s.d.]. Disponível em: https://platform.claude.com/docs/en/agents-and-tools/tool-use/web-search-tool

KATZ, Andrew; KIM, Dayoung; GERHARDT, Mitch; McOWEN, Bailey. Innovating Engineering Education with Generative AI. Workshop. IDEEAS Lab e LAB-IREEN, INOVA.USP, São Paulo, 23 a 25 set. 2025. Sem publicação aberta.

KRUPP, Lars et al. Unreflected acceptance: investigating the negative consequences of ChatGPT-assisted problem solving in physics education. In: HHAI 2024: Hybrid Human AI Systems for the Social Good. Amsterdam: IOS Press, 2024. p. 199-212. DOI 10.3233/FAIA240195

LINARDON, Jake et al. Influence of Topic Familiarity and Prompt Specificity on Citation Fabrication in Mental Health Research Using Large Language Models: Experimental Study. JMIR Mental Health, v. 12, e80371, 2025. DOI 10.2196/80371. Disponível em: https://mental.jmir.org/2025/1/e80371

LIU, Nelson F. et al. Lost in the Middle: How Language Models Use Long Contexts. Transactions of the Association for Computational Linguistics, v. 12, p. 157-173, 2024. DOI 10.1162/tacl_a_00638. Disponível em: https://aclanthology.org/2024.tacl-1.9/

MALLEN, Alex et al. When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories. In: Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto: ACL, 2023. p. 9802-9822. DOI 10.18653/v1/2023.acl-long.546

OPENAI. Memory FAQ. OpenAI Help Center, [s.d.]. Disponível em: https://help.openai.com/en/articles/8590148-memory-faq

PÁDUA, Sérgio Rodrigo de; PEIXOTO, Fabiano Hartmann. Inteligência Artificial Generativa no direito: da metodologia de avaliação à correção jurídica de LLMs e agentes de IA. Revista Brasileira de Direito, v. 21, n. 1, e5237, 2025. DOI 10.18256/g4jnx825

PERRY, Neil et al. Do Users Write More Insecure Code with AI Assistants? In: Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security. Nova York: ACM, 2023. p. 2785-2799. DOI 10.1145/3576915.3623157

TJ/PR vê má-fé e multa advogado por julgado "confeccionado" por IA. Migalhas, 30 jun. 2026. Processo 0108267-74.2025.8.16.0000, 9ª Câmara Cível do Tribunal de Justiça do Paraná. Disponível em: https://www.migalhas.com.br/quentes/459252

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
A janela inteira, e os três limites que ela não resolve

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **18 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**

ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)
PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.