IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



01

QUINZENA 4

O QUE A IA LÊ QUANDO VOCÊ APERTA ENVIAR

UNIVESP
Universidade Virtual do Estado de São Paulo

01

QUINZENA 4

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

O QUE A IA LÊ QUANDO VOCÊ APERTA ENVIAR

INTRODUÇÃO

O QUE VOCÊ VAI ENCONTRAR AQUI

1. Um bilhete na geladeira: o que a IA lê e o que ela nunca viu
2. Papel, objetivo, restrições e formato: as quatro perguntas antes de escrever
3. O que acontece quando você diz à IA quem ela deve ser
4. Engenharia de *prompt* e engenharia de contexto: qual é a diferença
5. Referências, com endereço para conferir

ORIGEM DO MATERIAL

A organização da instrução em quatro componentes vem do Workshop Fulbright sobre IA na Educação em Engenharia, realizado na USP em setembro de 2025 (Katz et al., 2025). As evidências vêm de dois estudos revisados por pares: Zheng et al. (Findings of the ACL: EMNLP, 2024) e Modarressi et al. (ICML, PMLR, 2025); e da documentação técnica da Anthropic (2025) e da OpenAI. Os números foram conferidos nas publicações de origem, e os endereços estão nas referências. As conversões de tokens para número de palavras são deste texto.

Você abre a ferramenta de IA com uma tarefa na cabeça. Digita uma linha e envia. O texto que volta serve para qualquer pessoa e para ninguém. Este módulo mostra por que a resposta sai assim, e o que fazer para que ela sirva a você.

Comece por uma cena sem computador nenhum. Alguém deixa um bilhete preso na porta da geladeira: “compra pão”. Para quem mora naquela casa, o bilhete está completo. Essa pessoa já sabe de qual padaria se trata, que tipo de pão a família come, quanto pão cabe no jantar de hoje, e que o pedido não vale para a semana inteira. Ninguém precisou escrever nada disso, porque nada disso é novidade ali dentro.

Agora imagine que o mesmo bilhete cai na mão de alguém que nunca entrou naquela casa. O texto continua idêntico, palavra por palavra, e o resultado é outro. O bilhete não mudou. O que mudou foi tudo aquilo que estava em volta dele e nunca chegou ao papel.

Uma ferramenta de IA está sempre na posição desse segundo leitor. Ela nunca entrou na sua casa, nunca assistiu à sua aula, nunca leu o enunciado que o professor passou. Ela lê o bilhete. Este módulo trata do que fica de fora do bilhete, e do lugar onde isso deveria estar. Ao final da leitura, você vai conseguir dizer, com as suas palavras, o que é um "*prompt*", o que é um "contexto", e por que essas duas palavras nomeiam trabalhos de tamanhos bem diferentes.

1. UM BILHETE NA GELADEIRA: O QUE A IA LÊ E O QUE ELA NUNCA VIU

A linha que você digita e envia tem um nome técnico: *prompt*. Quem a lê do outro lado é o modelo de linguagem, o programa por trás da ferramenta, aquele que escreve a resposta. A palavra ferramenta se refere ao site ou ao aplicativo que você abre; o modelo é o mecanismo que trabalha lá dentro.

Uma observação de vocabulário, para você não se perder ao ler outros materiais. A palavra prompt circula com dois recortes diferentes. Neste texto ela nomeia a linha final, o pedido em si, que é o recorte mais útil para o que vem a seguir. Na documentação técnica das empresas que constroem esses programas, ela costuma nomear a mensagem inteira que sai quando você aperta enviar, e é desse uso mais largo que vem o nome da prática que aparece na seção 4. Os dois recortes se referem à mesma tela, e a diferença está no quanto cada um abrange.

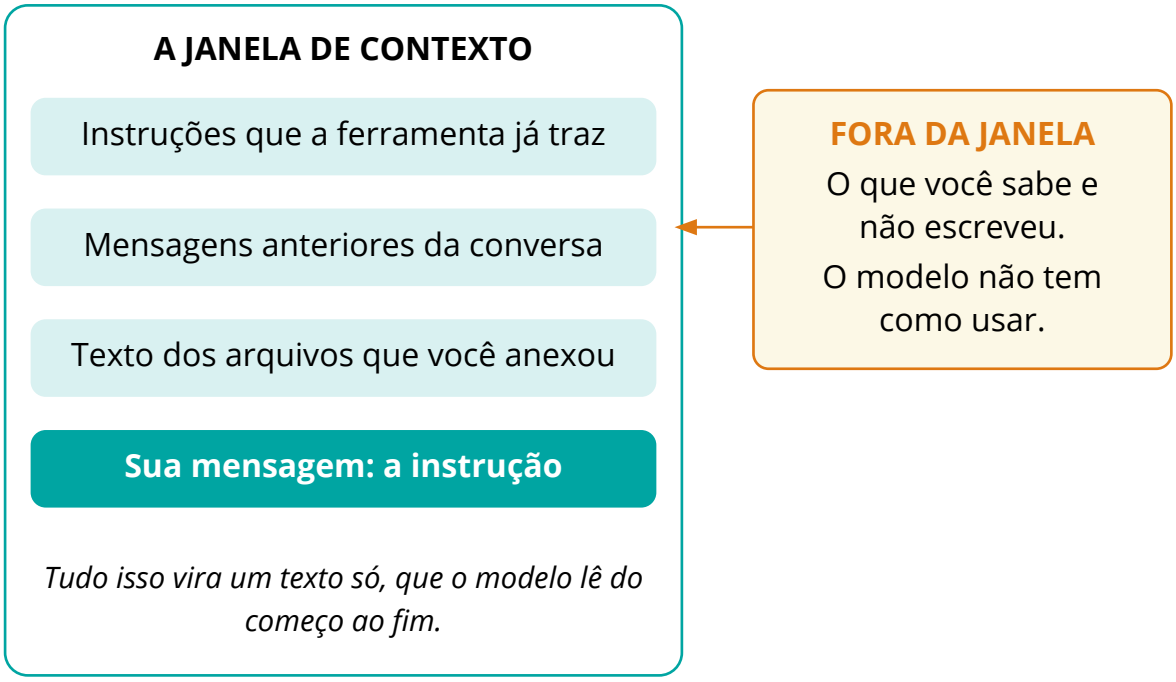
TUDO O QUE VOCÊ ESCREVE VIRA UM TEXTO SÓ

O que vem agora quase ninguém enxerga. Tudo o que participa de uma conversa com IA acaba reunido em um texto único. A sua mensagem de agora, as mensagens anteriores da conversa, o conteúdo dos arquivos que você anexou e ainda um conjunto de ordens que a empresa deixou fixas na ferramenta: a ferramenta emenda tudo isso numa sequência só, e o modelo lê essa sequência do começo ao fim antes de escrever a primeira palavra da resposta.

Aquelas ordens fixas você não escreveu nem consegue ler. São instruções do tipo “responda de forma útil e educada”, que a empresa deixou lá para valer em toda conversa. Elas ocupam espaço na sequência mesmo numa conversa recém-aberta.

Essa sequência inteira tem nome: **janela de contexto**. É a expressão que você vai encontrar em qualquer material sobre o assunto, e convém guardá-la agora, porque quase tudo o que vem depois depende dela.

Figura 1. O que o modelo lê quando você envia uma mensagem.



A janela tem tamanho, e esse tamanho se mede numa unidade de nome curioso: o token. Um token é um pedaço de texto mais ou menos do tamanho de uma palavra curta. "Pão" costuma contar como um pedaço só; "geladeira" costuma virar dois ou três. Os modelos quebram todo texto assim antes de processá-lo, e a Quinzena 2 tratou desse mecanismo em detalhe. Por ora, guarde a consequência: a janela comporta uma quantidade limitada de texto por vez.

E **contexto** é o nome de tudo o que está dentro da janela naquele momento. O que ficou de fora o modelo não tem como levar em conta. Ele responde com o que você escreveu e com o que ficou do treinamento, a leitura de uma quantidade enorme de textos que aconteceu antes de você chegar e não incluiu nada seu. A sua situação específica só chega até ele por escrito.

PRIMEIRA VEZ AQUI

Anexar um arquivo. Nas ferramentas de IA existe um botão com desenho de clipe, ou com um sinal de mais, que permite enviar um documento junto com a sua mensagem. O texto daquele documento entra na conversa e passa a ocupar espaço na janela, exatamente como se você tivesse copiado o conteúdo inteiro e colado ali. Na maior parte das ferramentas, o anexo funciona com arquivo de texto, com planilha e com imagem que tenha texto legível; algumas aceitam menos, e você faz bem em conferir o que a sua aceita.

POR QUE A RESPOSTA GENÉRICA APARECE

Volte ao bilhete. Quando falta informação, quem lê preenche as lacunas com aquilo que costuma acontecer. A pessoa que nunca esteve na sua casa compra o pão mais comum da padaria mais próxima, e faz isso com boa vontade. Um modelo de linguagem faz algo parecido, por um caminho diferente: ele calcula qual é o próximo pedaço de texto mais provável, a partir de tudo o que veio antes na janela.

Suponha que você peça à ferramenta uma mensagem em que você pede mais prazo ao professor, e escreva só isso. Nos textos com que o modelo foi treinado, pedidos de prorrogação costumam ser formais, longos e cheios de justificativas. É isso que volta: quinze linhas de desculpas que você jamais enviaria. O modelo devolveu o pedido de prorrogação mais provável do mundo, aquele que se parece com todos os outros. Você queria o seu.

Quem escreve o bilhete sabe tudo o que ficou de fora dele. Quem lê não sabe.

CONCEITO-CHAVE

***Prompt*:** a linha que você escreve e envia. **Instrução:** tudo o que você digitou naquela mensagem, o *prompt* inclusive. **Contexto:** tudo o que está dentro da janela, a sua instrução mais aquilo que você não digitou. A instrução é a única parte que você escreve por inteiro.

Uma consequência prática, para valer já nesta semana. Em lugar de perguntar "o que eu digito?", passe a perguntar "o que precisa estar escrito na conversa para que essa resposta sirva?". A segunda pergunta obriga você a decidir antes, e é justamente esse trabalho de decidir antes que o resto do módulo detalha.

UM PASSO ALÉM

Se você já usa IA todo dia, provavelmente reparou que os modelos anunciam janelas enormes: 128 mil, 200 mil, até um milhão de tokens. Anunciar e sustentar são coisas diferentes. Num estudo de 2025, pesquisadores mediram treze desses modelos numa tarefa específica: localizar, dentro de um texto longo, uma informação que a pergunta não repete com as mesmas palavras. Em textos curtos, abaixo de mil tokens, os treze iam bem. Em 32 mil tokens, onze deles acertavam menos da metade do que tinham acertado nos textos curtos (Modarressi et al., 2025). Para você imaginar o volume: 32 mil tokens correspondem a algo em torno de 20 mil palavras em português, mais ou menos um trabalho de conclusão de

curso de bom tamanho. O número não marca um ponto em que a ferramenta para de funcionar: a perda é gradual e começa bem antes disso. Encher a janela cobra um preço, e o Módulo 3 volta a esse custo em detalhe.

2. PAPEL, OBJETIVO, RESTRIÇÕES E FORMATO: AS QUATRO PERGUNTAS ANTES DE ESCREVER

De tudo o que está na janela, a sua mensagem é a única parte que depende inteiramente de você. Daqui em diante ela aparece também com outro nome, **instrução**, que é como a literatura técnica costuma chamá-la. E ela se organiza em quatro componentes. Nenhum dos quatro exige vocabulário técnico. O que eles exigem é que você decida alguma coisa antes de escrever, e é aí que está o trabalho.

Uma segunda observação de vocabulário, pelo mesmo motivo da primeira. Você vai encontrar esses quatro chamados de componentes do contexto, e a razão é boa: juntos, eles formam a parte do contexto que você escreve. Aqui eles aparecem como componentes da instrução, para deixar visível que a janela guarda ainda outras coisas que você não digitou. É o mesmo conjunto de quatro, com dois nomes.

Para percorrer os quatro sem trocar de assunto no meio, o melhor é usar um exemplo só. Imagine que você precisa avisar o seu grupo de trabalho de que a reunião mudou de dia, e de que a parte de cada um continua valendo como estava combinada.

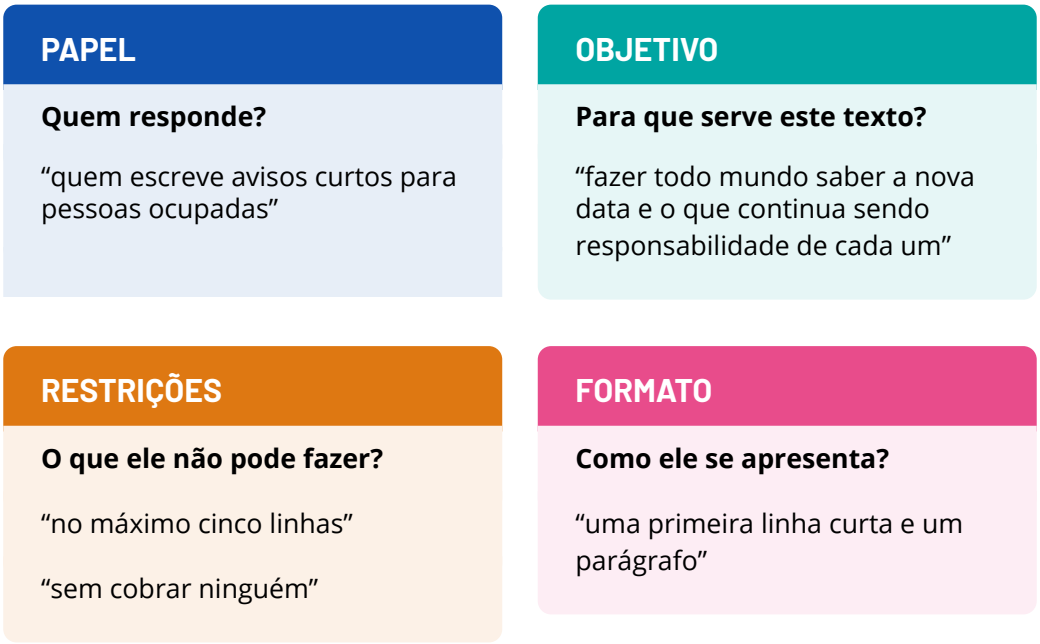
O **Papel** responde à pergunta “quem responde?”. Ele diz ao modelo quem escreve e para quem, e com isso define o vocabulário, o grau de formalidade e o tipo de texto que sai. No exemplo do aviso, o Papel poderia ser “quem escreve avisos curtos para pessoas ocupadas”. Quando esse componente fica em branco, o modelo assume um assistente genérico e devolve um texto de formalidade indefinida, que serve mais ou menos para tudo.

O Objetivo responde à pergunta que mais gente pula: para que serve este texto? O assunto interessa menos do que o efeito. No aviso, o assunto é a mudança de data; o objetivo é “fazer todo mundo saber a nova data e o que continua sendo responsabilidade de cada um”. Um objetivo escrito assim você consegue verificar: ou o texto fez todo mundo saber, ou não fez.

Vêm depois as Restrições, a parte antipática do trabalho e a que mais ajuda na hora de conferir o resultado. Elas dizem o que o resultado não pode fazer: tamanho máximo, tom proibido, palavra que não deve aparecer, norma a seguir. No aviso, poderiam ser “no máximo cinco linhas” e “sem cobrar ninguém”.

O Formato responde à pergunta “como o texto se apresenta?”. Trata da aparência do texto: parágrafo corrido, lista numerada, mensagem com primeira linha curta e um parágrafo, relatório com seções na ordem prevista. No aviso, “uma primeira linha curta e um parágrafo” já resolve.

Figura 2. Os quatro componentes da instrução e a pergunta que cada um responde.



UMA DIFERENÇA PEQUENA NO PEDIDO E GRANDE NO RESULTADO

Compare duas restrições: “seja breve” e “no máximo cinco linhas”. As duas pedem a mesma coisa. Só a segunda você consegue conferir. Uma restrição que você confere contando, medindo ou procurando transforma a leitura do resultado numa checagem, no lugar de uma impressão. Compensa praticar essa troca de uma restrição vaga por uma restrição que se confere, porque ela reaparece toda vez que você precisa julgar se um texto serve.

PONTO CRÍTICO

Formato e Objetivo trocados de lugar. Pedir "faça um resumo da reunião" descreve a forma do texto e deixa a função dele de fora. O resumo é o **Formato**. Fazer com que quem faltou saiba o que precisa entregar até sexta é o Objetivo. Quando o Formato entra no lugar do **Objetivo**, o modelo costuma acertar a forma e errar a função, e o resultado parece bom até alguém tentar usá-lo. Separe os dois antes de escrever, sempre nessa ordem: primeiro para que o texto serve, depois que aparência ele tem.

O MESMO PERCURSO, NUM CASO DE TRABALHO

Troque de situação e repita o exercício. Você precisa registrar por escrito um problema que aconteceu no seu turno, para que a pessoa responsável decida o que fazer. O Papel é o de quem escreve um registro interno para a pessoa que vai decidir. O **Objetivo** é descrever o que houve, com data, horário e o que já foi providenciado, de modo que essa pessoa consiga decidir o próximo passo. As Restrições são caber em uma página e não atribuir culpa a ninguém. O Formato é o formulário que o lugar de trabalho já usa; se não houver formulário, três blocos resolvem: o que aconteceu, o que já foi feito, o que falta decidir.

Em nenhum dos dois exemplos você precisou inventar informação. Cada dado já existia na situação, e o trabalho todo consistiu em identificar a função de cada um. Esse trabalho tem nome, decomposição, e tem método próprio, que o Módulo 2 desenvolve.

DICA PRÁTICA

Antes da próxima tarefa em que você for usar IA, responda por escrito às quatro perguntas da Figura 2, num papel ou numa nota do celular. Leva dois minutos, e serve para qualquer tarefa, de qualquer área.

Se alguma das quatro ficar sem resposta, você encontrou a informação que falta na tarefa. O problema estava ali, antes da ferramenta. Ir atrás dessa informação antes de abrir a conversa rende mais do que reescrever o pedido três vezes depois.

3. O QUE ACONTECE QUANDO VOCÊ DIZ À IA QUEM ELA DEVE SER

Entre os quatro componentes, o Papel é o que você vai ver mais gente comentar. Ele parece a parte criativa do trabalho, e circula por toda parte a receita de começar qualquer conversa com "você é um especialista em...". A receita é simpática e fácil de repetir. Alguns pesquisadores foram medir se ela funciona, e o resultado surpreende.

Uma equipe da Universidade Carnegie Mellon, da Universidade de Michigan e do laboratório de inteligência artificial da LG montou um teste grande. Reuniu 162 papéis diferentes, de relações de convívio a áreas de especialidade, aplicou cada um deles a quatro famílias de modelos, ou seja, quatro linhagens diferentes de programas, e mediu o desempenho em 2.410 perguntas de conhecimento, do tipo que tem resposta certa e verificável. A pergunta do estudo era direta: acrescentar um papel aumenta a taxa de acerto?

A resposta publicada é que não aumenta. Acrescentar um papel, *persona* no vocabulário do artigo, não melhorou o desempenho em relação ao grupo de comparação, que respondia às mesmas perguntas sem papel nenhum. Os autores registram um detalhe que merece atenção: para muitas perguntas isoladas existe algum papel que ajuda; o problema é que descobrir qual seria, antes de fazer a pergunta, mostrou-se impraticável. Daí a conclusão deles, de que o efeito de cada papel pode ser em larga medida aleatório (Zheng et al., 2024).

Antes de generalizar, dois limites do estudo. O primeiro: ele mediu acerto em perguntas de conhecimento, e deixou de fora tom, formalidade, vocabulário e adequação ao tipo de texto, que são justamente as coisas sobre as quais o Papel age. O segundo: o estudo mediu papéis colocados nas instruções fixas que a ferramenta carrega por dentro, e não diz nada sobre a linha que você digita. A conclusão que ele permite é mais estreita, e já diz bastante: onde a promessa de mais acerto foi medida, ela não se confirmou.

PARA QUE SERVE O PAPEL, ENTÃO

O Papel escolhe as palavras e as convenções, e nisso ele é muito bom. Peça a mesma explicação sobre um atraso de entrega "para a coordenação do curso" e depois "para um colega de grupo". Você recebe dois textos diferentes em formalidade,

em extensão e em escolha de vocabulário. Os dois podem estar corretos nos fatos. Só um serve para a pessoa que vai receber.

O Papel escolhe as palavras. A exatidão vem da fonte que você conferiu.

Para o trabalho que você entrega e assina, isso se traduz em duas orientações. Quando o que está em jogo é o modo de dizer, o Papel merece o esforço de você escrevê-lo com precisão. Quando o que está em jogo é a exatidão de um dado, de uma conta ou de uma norma, a confiança precisa vir de outro lugar: da fonte que você foi conferir. Uma frase de abertura escolhe convenções. Ela não confere nada, e nenhum papel transforma um número errado em número certo.

4. ENGENHARIA DE PROMPT E ENGENHARIA DE CONTEXTO: QUAL É A DIFERENÇA

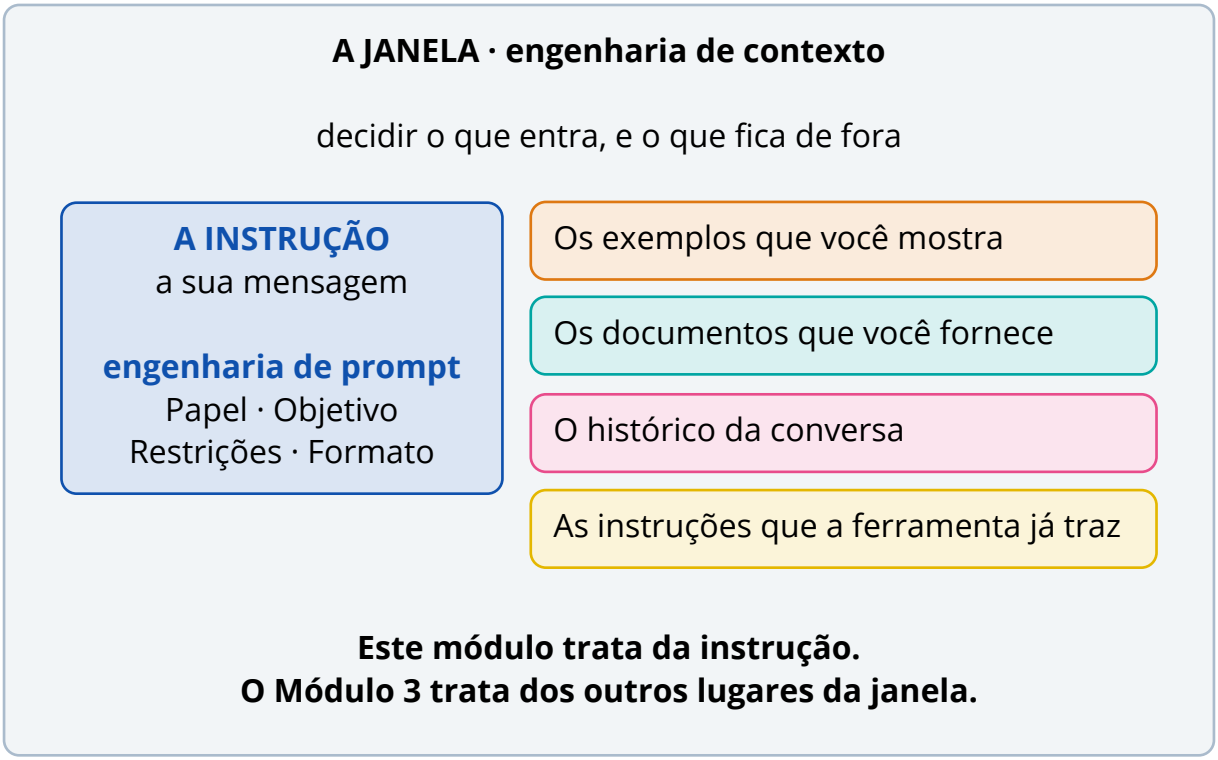
O que você viu até aqui tem nome próprio na literatura técnica e no mercado. São dois nomes, e cada um deles descreve um trabalho de tamanho diferente. Conhecer os dois evita uma confusão que aparece com frequência em cursos, em vídeos e em anúncios de vaga.

Construir bem a instrução, com Papel, Objetivo, Restrições e Formato, chama-se **engenharia de *prompt*** (*prompt engineering*). A Anthropic, empresa que desenvolve um desses modelos, descreve a prática, num artigo técnico de 2025, como a escrita e a organização das instruções dadas ao modelo. A documentação da OpenAI, a empresa responsável pelo ChatGPT, organiza a mesma coisa em quatro blocos com nomes próprios: a identidade de quem responde, as instruções a seguir, os exemplos e o material de apoio. Identidade é o nosso Papel, e o bloco de instruções reúne Objetivo, Restrições e Formato num item só. A documentação também trata os exemplos e o material de apoio como parte do pedido; neste texto eles aparecem uma camada acima, porque é lá que eles ficam quando você olha para a janela inteira.

Decidir o que entra na janela, e o que fica de fora, chama-se **engenharia de contexto** (*context engineering*). O termo ganhou circulação em 2025, quando as empresas que constroem os modelos passaram a usá-lo na própria documentação, e nomeia um trabalho maior. Além da instrução, entram na janela os exemplos que você mostra ao modelo, os documentos que você fornece para ele ler, o histórico

da conversa e aquilo que a própria ferramenta acrescenta sem você pedir. O artigo técnico da Anthropic define a prática como escolher e manter o conjunto de informações que o modelo recebe a cada passo (Anthropic, 2025).

Figura 3. As duas práticas encaixadas: a instrução é um dos lugares da janela.



As duas se encaixam uma dentro da outra. A instrução ocupa um lugar dentro da janela, e esse lugar você controla por inteiro. A janela é o conjunto, e o Módulo 3 volta a ela para mostrar os outros lugares e os limites de cada um.

Engenharia de prompt é construir bem a instrução. Engenharia de contexto é decidir o que entra na janela, e o que fica de fora.

Para você, esta semana, a diferença é bem concreta. Toda vez que a resposta sair errada, a primeira pergunta passa a ser de qual das duas camadas veio o problema. Se faltou informação na instrução, você reescreve os quatro componentes e resolve. Se faltou informação na janela, nenhuma reescrita resolve, e o caminho é anexar ou colar o que está faltando.

O bilhete, então. Quem escreve “compra pão” está contando com uma casa inteira de conhecimento compartilhado que ninguém precisou escrever. Diante de uma ferramenta de IA, essa casa não existe, e tudo o que importa precisa aparecer

escrito. Organizar isso antes de pedir é uma forma de pensar a tarefa com clareza, e o texto que sai fica melhor em consequência disso. Decidir para que serve o texto, quem escreve e o que não pode aparecer é um trabalho que você faria de qualquer forma, com ferramenta ou sem ela; a diferença é que agora ele fica escrito, e escrito antes. Quem organiza o contexto organiza também o próprio raciocínio. O trabalho continua sendo seu.

PARA REFLEXÃO

Na próxima vez que você abrir uma ferramenta de IA, preste atenção em qual dos quatro componentes você escreve sem pensar e qual deles você nunca chega a digitar.

Costuma ser o mesmo componente, em quase toda conversa. Descobrir qual é o componente que você nunca digita muda mais o seu uso da ferramenta do que acertar uma resposta isolada.

6. REFERÊNCIAS

As obras abaixo foram conferidas nas publicações originais. Os endereços estão indicados onde existem.

ANTHROPIC. *Effective context engineering for AI agents*. Anthropic Engineering, 29 set. 2025. Disponível em: https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents

KATZ, Andrew; KIM, Dayoung; GERHARDT, Mitch; McOWEN, Bailey. *Innovating Engineering Education with Generative AI. Workshop*. IDEEAS Lab e LAB-IREEN, INOVA. USP, São Paulo, 23 a 25 set. 2025. Sem publicação aberta.

MODARRESSI, Ali; DEILAMSALEHY, Hanieh; DERNONCOURT, Franck; BUI, Trung; ROSSI, Ryan A.; YOON, Seunghyun; SCHÜTZE, Hinrich. *NoLiMa: Long-Context Evaluation Beyond Literal Matching*. In: Proceedings of the 42nd International Conference on Machine Learning. PMLR, v. 267, p. 44554-44570, 2025. Disponível em: https://proceedings.mlr.press/v267/modarressi25a.html

OPENAI. *Prompt engineering*. OpenAI API Documentation, [s.d.]. Disponível em: https://developers.openai.com/api/docs/guides/prompt-engineering

ZHENG, Mingqian; PEI, Jiaxin; LOGESWARAN, Lajanugen; LEE, Moontae; JURGENS, David. *When "A Helpful Assistant" Is Not Really Helpful*: Personas in System Prompts Do Not Improve Performances of Large Language Models. In: Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024. p. 15126-15154. DOI 10.18653/v1/2024.findings-emnlp.888. Disponível em: https://aclanthology.org/2024.findings-emnlp.888/

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
O que a IA lê quando você aperta enviar

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **16 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**

ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)
PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.