IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



04

QUINZENA 4

O QUE MUDAR QUANDO O RESULTADO VOLTA ERRADO

UNIVESP
Universidade Virtual do Estado de São Paulo

04

QUINZENA 4

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

O QUE MUDAR QUANDO O RESULTADO VOLTA ERRADO

INTRODUÇÃO

O QUE VOCÊ VAI ENCONTRAR AQUI

1. Tentar de novo e iterar: duas reações a um resultado ruim
2. Escreva seus critérios antes de ver o resultado
3. Como descobrir qual componente causou a falha
4. Por que a IA não corrige sozinha o que ela mesma escreveu
5. A ficha de quatro linhas, e por que anotar cada rodada
6. Referências, com endereço para conferir

ORIGEM DO MATERIAL

A organização da quinzena em torno da janela de contexto, que é o espaço limitado de texto que a ferramenta consegue considerar de uma vez, vem do Workshop Fulbright sobre IA na educação em engenharia, realizado na USP em setembro de 2025 (Katz et al., 2025). As evidências, no entanto, vêm de fora dele. Quatro dos estudos citados aqui passaram pela leitura crítica de outros pesquisadores antes de sair em congressos e periódicos internacionais. Um relatório de pesquisa que ainda não passou por essa leitura crítica aparece assinalado no texto, e usamos dele apenas a distinção entre dois modos de trabalho. Entra também um documento da UNESCO, citado justamente para registrar uma lacuna. Todos os números conferem com as publicações de origem, e as referências trazem o endereço de cada uma, para você abrir e conferir. Nas citações, o sobrenome do primeiro autor vem seguido de *et al.*, expressão latina que indica que o trabalho tem outros autores; a lista completa está nas referências. Ao terminar a leitura, você vai saber aplicar um ciclo de três passos a uma tarefa sua: montar o contexto e receber o primeiro resultado; conferir esse resultado com critérios que qualquer pessoa possa verificar; e identificar qual componente da sua instrução causou cada falha.

1. TENTAR DE NOVO E ITERAR: DUAS REAÇÕES A UM RESULTADO RUIM

Você aperta o interruptor do quarto e a luz não acende. Aperta outra vez, sem pensar muito. Depois vai trocar a lâmpada, porque lâmpada queimada é a causa mais comum e a mais simples de resolver. Só que a luz continua apagada. Só então você repara que o carregador na tomada ao lado também parou de funcionar e que o disjuntor caiu. A lâmpada nova estava boa: o problema estava no disjuntor.

Trocar a lâmpada é o palpite mais razoável, e é por isso que quase todo mundo começa por aí. Ainda assim, é um palpite: você trocou a peça antes de verificar onde a energia parava. O passo que faltou custava menos que a ida até a loja, e é sempre o mesmo: procurar a causa antes de trocar a peça.

Repare numa vantagem que a luz do quarto tem: você descobre na hora se resolveu o problema, porque a luz acende ou continua apagada. Com um texto que uma ferramenta de IA escreveu, esse sinal não vem de graça. Ele só aparece se você tiver escrito antes um critério que possa ser contado ou procurado.

CONCEITO-CHAVE

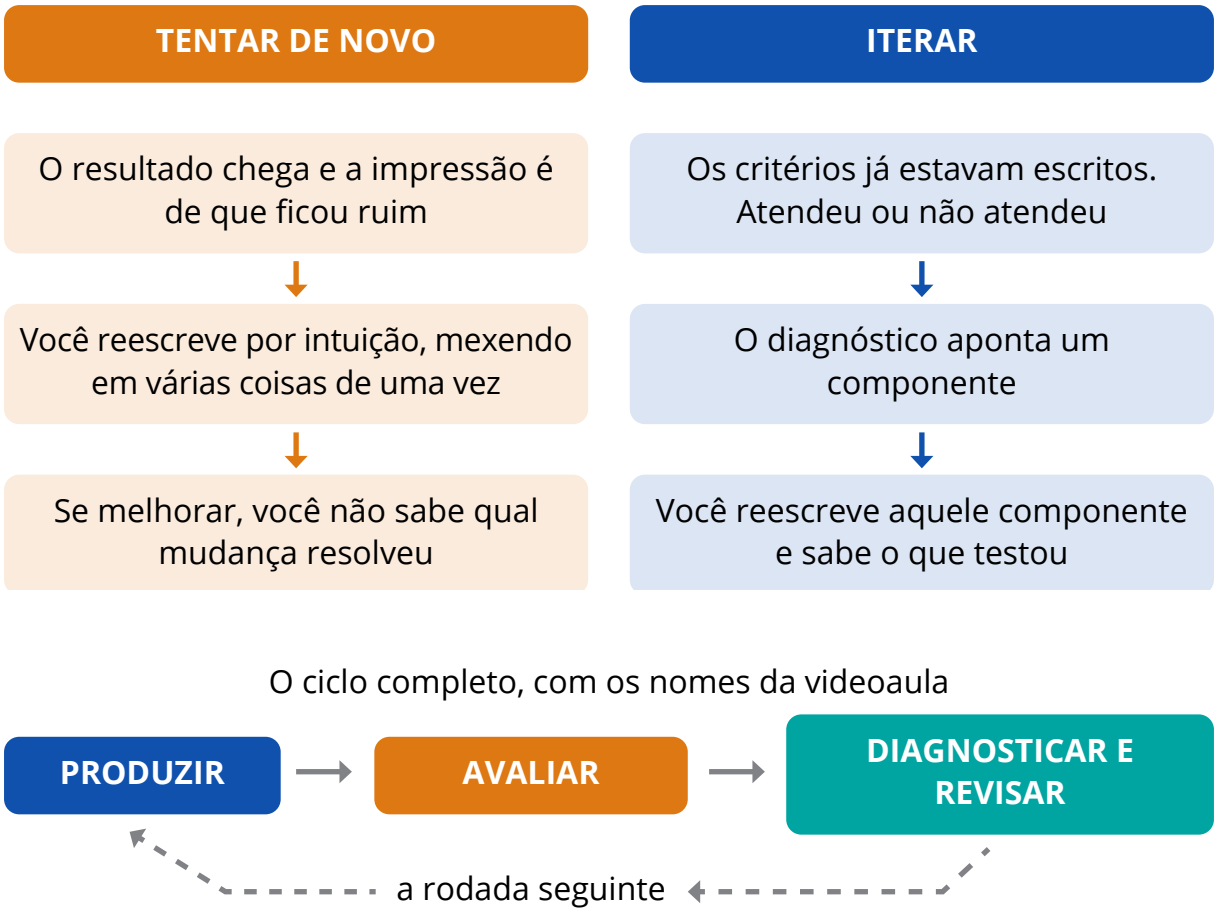
O ciclo de iteração em três passos. A videoaula deste módulo divide esse trabalho em três movimentos e dá nome a cada um. **Produzir:** você monta o contexto e recebe o primeiro resultado. **Avaliar:** você compara esse resultado com os critérios que definiu antes. **Diagnosticar e revisar:** você descobre qual dos componentes causou a falha e reescreve esse componente. Terminada a revisão, começa uma nova rodada, que aproveita o que a anterior mostrou.

Existem duas maneiras de reagir a um resultado ruim, e de fora elas parecem iguais. **Tentar de novo** é reescrever o pedido por intuição, sem ter conferido nada e sem saber o que falhou. **Iterar** é conferir com critério e descobrir onde estava o erro antes de mudar uma palavra. Na videoaula, essa diferença aparece no Pedro, o personagem que acompanha a aula: ele reescrevia o pedido sem nunca ter conferido o que havia falhado.

PRIMEIRA VEZ AQUI

Iterar é repetir a mesma sequência de passos várias vezes, mudando uma coisa por vez e usando o que você aprendeu na tentativa anterior. Quem acerta uma receita ao longo de três domingos, anotando em cada um o que mudou e o que saiu diferente, está iterando. Quem repete a receita esperando dar sorte está apenas tentando de novo.

Figura 1. As duas maneiras de fazer a segunda tentativa, passo a passo, e o ciclo completo com os nomes da videoaula.



O CHI é o principal congresso da área que estuda a relação entre pessoas e computadores. Um estudo apresentado nele em 2023 observou de perto como essa reação por intuição aparece na prática. Os pesquisadores deram até uma hora a dez pessoas sem formação em IA para que ajustassem, por tentativas, o comportamento de um assistente de conversa. Três comportamentos se repetiram. Bastava um acerto para que parassem de ajustar, hábito que os autores descreveram como cantar vitória cedo demais. Bastavam um ou dois erros para que desistissem da ferramenta para aquela tarefa. E nenhuma das dez usou o recurso de teste sistemático que a própria ferramenta oferecia (Zamfirescu-Pereira et al., 2023).

O estudo tem dois limites, e uma terceira informação ajuda a interpretar os dois. É uma pesquisa qualitativa, com dez participantes, e os próprios autores dizem que ela não permite estimar com que frequência esse comportamento aparece fora dali. A ferramenta testada funcionava com um modelo de 2022, anterior ao ChatGPT. E o padrão apareceu tanto em quem tinha experiência prévia em programação quanto em quem não tinha, o que sugere que ele não se explica só por familiaridade com ferramentas. Com dez participantes, isso é uma pista a investigar. Os autores atribuem a causa às expectativas que trazemos da conversa entre pessoas, em que uma boa resposta costuma bastar como prova de que o outro entendeu.

O ciclo não garante que a segunda rodada saia boa. Ele garante outra coisa, menos ambiciosa e mais valiosa no dia a dia: se sair boa, você vai saber por quê; se sair ruim, vai saber o que ainda não testou.

Iterar é saber, ao fim de cada rodada, qual peça você trocou.

2. ESCREVA SEUS CRITÉRIOS ANTES DE VER O RESULTADO

Volte à luz do quarto. Ali o sinal de sucesso é tão evidente que ninguém precisa combinar nada: a luz acende. Com um texto, não existe interruptor. Dizer que ficou bom ou que ficou ruim registra só uma impressão, e a impressão muda com o cansaço: você lê o mesmo parágrafo depois do almoço e ele parece outro. Por isso a conferência começa antes do resultado. Você escreve o que o texto vai precisar cumprir enquanto ainda não tem nada nas mãos para julgar, e faz isso mesmo quando a resposta já chegou.

O Módulo 2 chamou de **instrução verificável** a exigência que qualquer pessoa consegue conferir só olhando o resultado, sem espaço para discussão. Essa exigência tem dois usos, e cada um deles ganhou um nome. Dentro da instrução, ela diz ao modelo o que precisa cumprir. Escrita antes e relida depois, ela serve para você conferir, e nessa segunda função o Módulo 3 a chamou de **critério verificável**. É a mesma exigência, em dois papéis.

A videoaula mostra o Pedro Alves nessa situação. O Pedro é redator de uma empresa de tecnologia financeira criada para a aula. Ele recebeu do time de produto uma lista de três pontos soltos sobre uma mudança no acesso: as transações acima de R$ 5.000 vão passar a pedir uma confirmação a mais, além da senha; existe um prazo para todos se cadastrarem; e o suporte fica no próprio aplicativo.

Essa confirmação a mais é o que os aplicativos chamam de autenticação em dois fatores. O Pedro colou a lista no chat e escreveu “escreva uma notificação push”. A notificação push é o aviso curto que aparece na tela do celular.

Antes de olhar a resposta que voltou, o professor da videoaula escreve na tela três critérios: título com até 120 caracteres, corpo com até 300 caracteres e tom neutro, sem palavras de urgência. Esses três funcionam de maneiras diferentes. Dois deles se resolvem com uma contagem simples. O terceiro depende de procurar palavras dentro do texto. Nos três, só existem duas respostas possíveis, e a videoaula as diz com todas as letras: atendeu ou não atendeu.

O critério de tom é o que costuma emperrar, porque tom parece assunto de gosto pessoal. O Módulo 2 mostrou a saída: transformar a exigência em palavras que dá para procurar no texto. Num aviso institucional, o tom de urgência aparece em cinco marcas: alerta, obrigatória, bloqueio, não cumprimento e o radical imediat-, que cobre imediata, imediato e imediatamente. Com essas cinco marcas anotadas, conferir o tom se resume a usar a busca do editor de texto, e a conversa sobre gosto pessoal não começa.

Não existe número certo de critérios, e o Módulo 2 também não arriscou um. O limite é outro: escreva apenas os critérios que você mesmo consiga conferir depois. Um critério que você não sabe conferir cai no limite de verificação que o módulo anterior descreveu, quando você não domina o assunto o suficiente para separar o certo do errado. Escrever um critério assim produz uma sensação de controle que o resultado não vai confirmar.

A tarefa desta seção leva um minuto. Escreva, numa linha, o que o resultado precisa cumprir para que você possa usá-lo, antes de ler o que a ferramenta devolveu. Se essa linha não sai, o problema ainda está no que você quer do texto, aquilo que o Módulo 2 chamou de Objetivo.

3. COMO DESCOBRIR QUAL COMPONENTE CAUSOU A FALHA

Você aprendeu os quatro componentes numa direção: partiu da informação que tinha em mãos e decidiu em qual gaveta cada pedaço entrava. Papel, Objetivo, Restrições, Formato. O diagnóstico percorre o caminho inverso. Você parte da falha e procura de qual gaveta ela saiu. São os mesmos quatro nomes, agora com outra função.

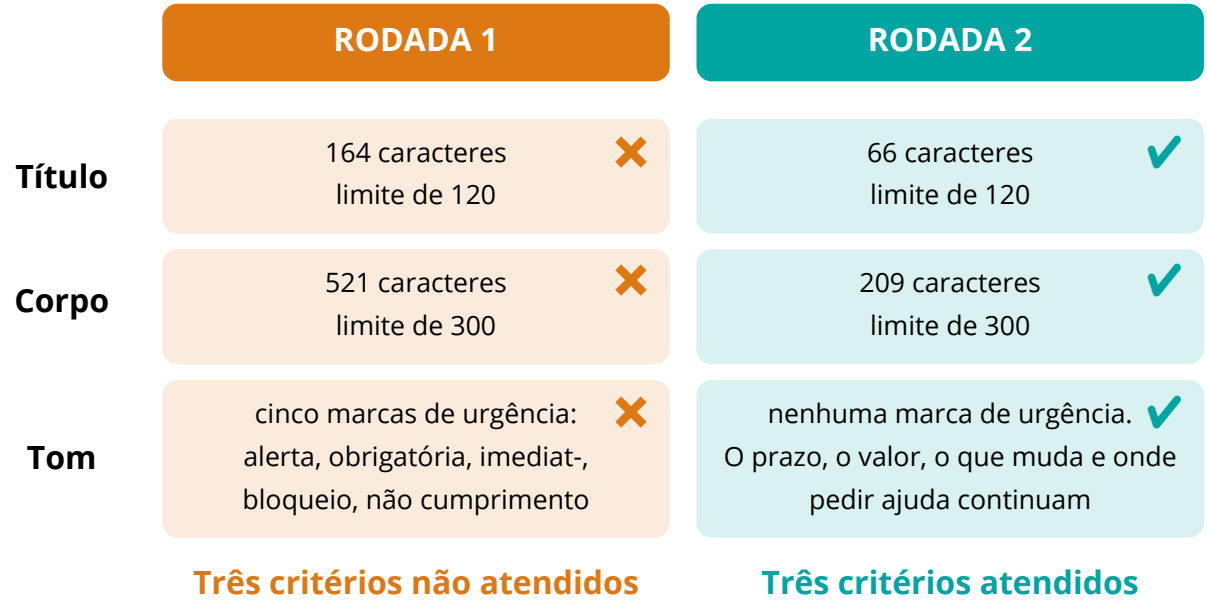
O texto que voltou para o Pedro tinha 164 caracteres no título, onde o limite era 120, e 521 no corpo, onde o limite era 300. Abria com ALERTA IMPORTANTE, avisava que o não cumprimento poderia levar ao bloqueio imediato das operações e pedia que todos acessassem imediatamente as configurações do aplicativo. O texto não cumpriu nenhum dos três critérios, e a aula passa pelos quatro componentes, um a um, para descobrir de onde saiu cada falha.

O **Papel** não estava escrito: o modelo não sabia que devia redigir como quem escreve a comunicação de uma empresa para os próprios clientes. O **Objetivo** parecia estar ali e não estava. A frase “escreva uma notificação push” indica em que forma o texto deve sair, e isso é um pedido de Formato. Ninguém disse ao modelo qual era a função do aviso: informar sem assustar. As **Restrições** simplesmente não existiam, porque nenhum limite de caracteres chegou ao modelo. E o **Formato** também ficou incompleto: a tarefa pedia título e corpo separados, e isso ninguém escreveu. Dizer que tipo de texto você quer ainda não diz como ele deve estar organizado.

A tabela abaixo serve para qualquer tarefa: quatro sintomas frequentes, com o componente que costuma explicar cada um.

Quando o resultado...	Procure em	Um exemplo do dia a dia
veio longo demais, ou trouxe algo que você tinha proibido	**Restrições**	*o resumo pedido em uma página voltou com três*
está bem escrito, mas responde a outra pergunta	**Objetivo**	*o texto sobre a metodologia saiu correto e apresentou o tema, sem responder à pergunta do trabalho*
está correto, mas soa estranho para quem vai receber	**Papel**	*a mensagem para a coordenação saiu com jeito de recado em grupo de amigos*
traz o conteúdo certo na forma errada	**Formato**	*o fichamento voltou em parágrafo corrido, sem os campos pedidos*

Figura 2. Os três critérios nas duas rodadas, com a contagem que você pode refazer.



Nenhuma informação do time de produto foi acrescentada nem retirada. O que mudou foi a organização delas nos quatro componentes.

O Módulo 2 mostrou que Objetivo e Restrições pesam mais que Papel e Formato na qualidade do resultado, e que esses dois últimos refinam o que já está de pé. Daí sai uma prioridade de procura: comece pelo Objetivo e pelas Restrições, que respondem pela maior parte das falhas, e só depois olhe o Papel e o Formato. As falhas de tom se dividem entre os dois lados. Quando você proibiu por escrito um jeito de escrever, como as palavras de urgência do caso do Pedro, a falha é de Restrições. Quando ninguém disse para quem o texto fala, ela é de Papel.

Existe um caso em que essa procura não encontra culpado nenhum. Os quatro componentes estão escritos com cuidado, e o resultado continua errado. Aí a causa pode estar fora da sua instrução. O módulo anterior nomeou três dessas causas: informação que falta dentro da própria conversa, assunto pouco documentado e limite de verificação, quando você não tem como julgar o que voltou. Reescrever o Papel pela quinta vez não resolve nenhuma delas.

⚠ PONTO CRÍTICO

Mudar tudo de uma vez. A tentação, depois de ler um resultado ruim, é reescrever os quatro componentes na mesma rodada. O texto costuma melhorar, mas você fica sem saber o que resolveu. Na tarefa seguinte você repete tudo por precaução, inclusive o que talvez

fosse dispensável. Mexer em um componente por vez exige mais rodadas e ensina algo em cada uma delas.

Existe uma exceção, e o caso do Pedro é ela: quando o diagnóstico mostra que os quatro componentes estão ausentes, a primeira revisão escreve a estrutura inteira de uma vez, porque não há nada para isolar. A regra de um componente por vez começa a valer na rodada seguinte, quando já existe estrutura no papel e cada mudança pode ser atribuída.

Diagnosticar pela estrutura, em lugar de diagnosticar pela aparência, tem uma história bem mais antiga que a da IA. Em 1981, três pesquisadores reuniram oito doutorandos em física e oito estudantes de graduação recém-saídos de um semestre de mecânica. A tarefa: separar 24 problemas de livro didático em grupos, juntando os que se resolveriam de maneira parecida. Os graduandos agruparam pelo que aparecia no enunciado, plano inclinado com plano inclinado, pêndulo com pêndulo. Os doutorandos agruparam pelo princípio de física que resolvia cada problema, e nos grupos deles ficavam juntos enunciados que não se pareciam em nada (Chi et al., 1981).

Trinta anos depois, a mesma tarefa foi repetida com 403 estudantes de graduação, 21 de pós-graduação e 7 professores, e o resultado foi uma distribuição contínua: parte dos estudantes do curso introdutório agrupou por princípio, e nem todos os professores agruparam bem todos os problemas (Mason e Singh, 2011). Repare na distância entre esses estudos e o nosso assunto. O primeiro é de psicologia cognitiva e o segundo, de pesquisa em ensino de física, e nenhum dos dois trata de inteligência artificial. O que trazemos deles é só a diferença entre olhar a aparência e olhar a estrutura. É nessa diferença que a tabela acima se apoia, e a aposta de que ela funciona no trabalho com contexto é deste material.

Na história da luz, a lâmpada é a aparência, e o disjuntor é a estrutura. A tabela acima serve para você chegar ao disjuntor na primeira ida à caixa de luz, em lugar de trocar duas ou três lâmpadas para descobrir que o problema estava em outro lugar.

Veja agora o que aconteceu na segunda rodada do Pedro: nenhuma informação do time de produto foi acrescentada nem retirada. O valor, o que muda e a existência de um prazo já estavam na lista. Dois detalhes, o prazo de 30 dias e o nome da tela de Configurações, apareceram no texto da primeira rodada e não na lista original: saíram da ferramenta, e o Pedro precisa confirmá-los com o time antes de publicar. O que mudou foi a maneira de organizar essas informações nos quatro componentes.

Abaixo estão o título e o corpo das duas rodadas, com a contagem de caracteres de cada um, para você refazer a conta em qualquer contador.

RODADA 1: A LISTA COLADA E O PEDIDO "ESCREVA UMA NOTIFICAÇÃO PUSH"

Título, 164 caracteres, limite de 120. Não atendido.

ALERTA IMPORTANTE: nova etapa de autenticação obrigatória passa a valer para todas as transações acima de R$ 5.000 e exige providência imediata de todos os usuários

Corpo, 521 caracteres, limite de 300. Não atendido.

Comunicamos que, por determinação interna, torna-se obrigatória a autenticação em dois fatores para toda transação acima de R$ 5.000. A medida entra em vigor em 30 dias e o não cumprimento poderá acarretar o bloqueio imediato das operações em curso. Solicitamos que todos os usuários acessem imediatamente as configurações do aplicativo e concluam o cadastro da segunda etapa de verificação. Em caso de dúvida, o canal de suporte permanece disponível no aplicativo, na aba Ajuda, para atendimento referente a este alerta.

Tom neutro. Não atendido: cinco marcas de urgência, em nove ocorrências. Alerta (2), obrigatória (2), bloqueio (1), não cumprimento (1) e o radical imediat- (3).

RODADA 2: A MESMA LISTA, DISTRIBUÍDA NOS QUATRO COMPONENTES

Título, 66 caracteres, limite de 120. Atendido.

Suas transações acima de R$ 5.000 vão pedir uma confirmação a mais

Corpo, 209 caracteres, limite de 300. Atendido.

A partir de 30 dias, transações acima de R$ 5.000 vão pedir uma segunda confirmação, feita pelo aplicativo. O cadastro da segunda etapa fica em Configurações. Se precisar de ajuda, o suporte está na aba Ajuda.

Tom neutro. Atendido: *nenhuma das cinco marcas aparece, e o prazo, o valor, o que muda e onde pedir ajuda continuam no texto.*

4. POR QUE A IA NÃO CORRIGE SOZINHA O QUE ELA MESMA ESCREVEU

Fica no ar uma pergunta razoável, e ela costuma aparecer poucos minutos depois da aula. Se a ferramenta escreve o texto, por que ela não poderia conferir e corrigir o que escreveu? Você ganharia tempo, e a parte mais chata do ciclo deixaria de ser sua.

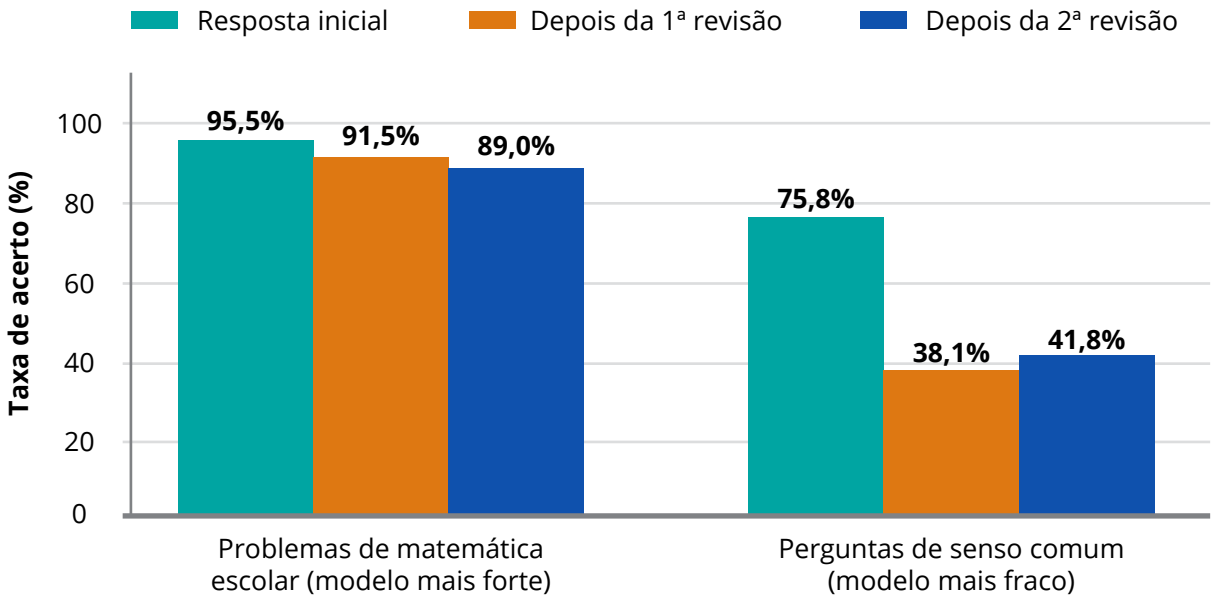
Uma equipe de pesquisa foi medir exatamente isso, num trabalho apresentado no ICLR de 2024, congresso de referência em aprendizado de máquina. O procedimento é simples de descrever, e os pesquisadores o aplicaram a dois modelos de força diferente. O modelo responde a uma pergunta. Em seguida recebe a instrução de considerar que a resposta pode estar certa ou errada, revisá-la com cuidado e relatar os problemas sérios que encontrar. Por fim, recebe o pedido de melhorar a resposta a partir do que encontrou. Em nenhum momento alguém lhe diz se acertou.

O resultado é o contrário do esperado. Em 1.319 problemas de matemática escolar, o modelo mais forte caiu de 95,5% de acerto para 91,5% depois da primeira revisão, e para 89,0% depois da segunda. Num conjunto de perguntas de senso comum, o modelo mais fraco desabou de 75,8% para 38,1% e subiu de volta para 41,8% na rodada seguinte (Huang et al., 2024). Esses percentuais descrevem o desempenho em lotes específicos de perguntas, e a caixa abaixo explica o que isso quer dizer. Os dois modelos foram testados em agosto de 2023.

PRIMEIRA VEZ AQUI

Conjunto de teste. Para medir um modelo, os pesquisadores montam um lote grande de perguntas cuja resposta certa já se conhece e contam quantas ele acerta. O percentual descreve o desempenho naquele lote, com aquelas perguntas: outro lote produz outro número. O uso mais seguro desse tipo de medida está em comparar duas rodadas do mesmo modelo, e é assim que a Figura 3 usa esses números.

Figura 3. Taxa de acerto antes e depois de o modelo revisar a própria resposta, sem critério vindo de fora.



Em cada revisão o modelo recebe uma instrução para procurar problemas na própria resposta, e nunca fica sabendo se acertou. Modelos testados em agosto de 2023.

O título do artigo termina com uma palavra que cai quando alguém o cita de segunda mão: ainda. Os modelos ainda não conseguem corrigir sozinhos o próprio raciocínio. Os autores também delimitam o alcance do que mediram. Eles testaram raciocínio e dizem que, em outros tipos de tarefa, podem existir estratégias de revisão que funcionem. Nada ali permite concluir que pedir um ajuste de estilo estraga o texto.

O mesmo artigo mostra a virada que interessa a este módulo. Quando os pesquisadores diziam ao modelo que a resposta estava errada, usando um gabarito que só eles tinham, o desempenho subia. Isso identifica a origem do ganho: um julgamento vindo de fora do modelo. Antes de transportar o achado, note duas diferenças. Você não tem gabarito, e os seus três critérios não fazem esse papel, porque eles conferem a forma do texto e não a correção do conteúdo. O que o estudo permite dizer é que julgamento externo ajuda, e é isso que os critérios escritos antes levam para a conversa. Essa ponte quem faz é este material.

UM PASSO ALÉM

Alguns critérios se conferem sozinhos. A soma das parcelas tem de fechar com o total, o calendário confirma a data, o editor conta as linhas. Critérios assim levam segundos para

conferir, e você pode escrever vários. Quando a conferência depende de alguém ler e julgar, escreva menos e confira com calma. Este trecho é um aprofundamento opcional, e o módulo se entende sem ele.

Uma mudança pequena no pedido faz bastante diferença aqui. Quando você quiser que a ferramenta ajude na revisão, cole os seus critérios dentro do pedido. Compare duas maneiras de pedir a mesma coisa. A primeira diz: revise este texto. A segunda diz: veja se este texto cumpre estes três critérios e me diga qual deles falhou. Só a segunda devolve uma resposta que você consegue conferir.

5. A FICHA DE QUATRO LINHAS, E POR QUE ANOTAR CADA RODADA

A videoaula diz que o ciclo exige mais uma coisa: anotar o que você fez. Entenda o motivo antes de escrever a primeira ficha, porque anotar sem saber para quê vira tarefa sem sentido, e tarefa sem sentido ninguém sustenta.

COMO FAZER, NA PRÁTICA

A ficha de quatro linhas. Para cada tarefa em que você usar o ciclo, guarde quatro informações, e nada além delas. **Contexto inicial:** o que você escreveu, com os quatro componentes visíveis. **Resultado:** o que voltou, copiado como veio. Diagnóstico: qual critério falhou e qual componente explica a falha. **Contexto revisado:** o que você mudou, e apenas o que mudou. Cada ficha cabe numa página.

Uma ficha isolada serve de pouco. Ela fica útil quando você tem várias para ler de uma vez, porque aí salta aos olhos o que se repete em todas as tarefas, em lugar do erro de uma só. Quem costuma deixar o Papel implícito descobre isso por conta própria, lendo as próprias fichas.

Quando você registra, consegue ver qual componente você consistentemente deixa de fora. Esse padrão é o que a Quinzena 4 quer revelar.

Falta dizer também o que ainda não sabemos. Até agosto de 2026 não localizamos nenhum estudo revisado por outros pesquisadores que meça o efeito de anotar o próprio processo de uso de IA. O marco de competências em IA para estudantes é a referência internacional mais próxima do assunto. Publicado pela UNESCO, ele

organiza doze blocos de competência e não traz nenhum item sobre esse hábito (UNESCO, 2024). O hábito entra aqui pelo motivo que a seção acabou de descrever, várias fichas lidas juntas mostram o que se repete de uma tarefa para outra, e não porque exista medida publicada do efeito dele.

Na quinzena passada você viu dois modos de trabalhar com IA, separados por um único critério: você decidiu a divisão do trabalho antes ou foi decidindo pelo caminho. Quem decide antes trabalha no modo Centauro, e depois consegue apontar de onde veio cada parte do resultado. Quem vai decidindo no caminho trabalha no modo Ciborgue. O ciclo em três passos é essa divisão decidida antes, aplicada a uma tarefa só: o que a ferramenta faz, o que você confere e com qual critério. O diagnóstico continua vindo depois, e ele é sobre o texto, não sobre a divisão do trabalho. Os dois nomes vêm de um relatório de pesquisa que ainda não passou por revisão de outros pesquisadores (Dell'Acqua et al., 2023).

O método diz o que testar na segunda tentativa. Quem assina o resultado continua sendo você.

CONCEITO-CHAVE

As duas definições, lado a lado. Engenharia de prompt é construir bem a instrução: escolher o Papel, dizer o Objetivo, escrever as Restrições, definir o Formato. **Engenharia de contexto** é decidir o que entra na janela e o que fica de fora, incluindo a instrução, os exemplos, os documentos que você fornece, o histórico da conversa e as ordens fixas que a ferramenta já traz. A primeira mora dentro da segunda.

Quando você deixa de depender de inspiração para melhorar um resultado, é porque passou a ter um método. É com esse método que você termina a Quinzena 4.

PARA REFLEXÃO

Lembre-se do último resultado que você achou ruim e reescreveu na hora. Quantas coisas você mudou de uma vez? Se ele tivesse melhorado, você saberia dizer qual dessas mudanças resolveu o problema? A pergunta não tem resposta certa. Ela serve para você ver o que o ciclo resolve.

6. REFERÊNCIAS

CHI, Michelene T. H.; FELTOVICH, Paul J.; GLASER, Robert. Categorization and Representation of Physics Problems by Experts and Novices. *Cognitive Science*, v. 5, n. 2, p. 121-152, 1981. DOI 10.1207/s15516709cog0502_2. Disponível em: https://onlinelibrary.wiley.com/doi/10.1207/s15516709cog0502_2

DELL'ACQUA, Fabrizio et al. Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of Artificial Intelligence on Knowledge Worker Productivity and Quality. *Harvard Business School Working Paper 24-013*, 15 set. 2023. Relatório de pesquisa, ainda sem revisão por outros pesquisadores. Disponível em: https://www.hbs.edu/faculty/Pages/item.aspx?num=64700

HUANG, Jie et al. Large Language Models Cannot Self-Correct Reasoning Yet. In: *The Twelfth International Conference on Learning Representations* (ICLR 2024), Viena, 2024. Disponível em: https://iclr.cc/virtual/2024/poster/18956

KATZ, Andrew; KIM, Dayoung; GERHARDT, Mitch; McOWEN, Bailey. *Innovating Engineering Education with Generative AI. Workshop*. IDEEAS Lab e LAB-IREEN, INOVA. USP, São Paulo, 23 a 25 set. 2025. Sem publicação aberta.

MASON, Andrew; SINGH, Chandralekha. Assessing expertise in introductory physics using categorization task. *Physical Review Special Topics: Physics Education Research*, v. 7, art. 020110, 2011. DOI 10.1103/PhysRevSTPER.7.020110. Disponível em: https://journals.aps.org/prper/abstract/10.1103/PhysRevSTPER.7.020110

UNESCO. *AI competency framework for students*. Paris: UNESCO, 2024. DOI 10.54675/JKJB9835. Edição em português: Marco referencial de competências em IA para estudantes, 2025. Disponível em: https://unesdoc.unesco.org/ark:/48223/pf0000391105 (inglês) e https://unesdoc.unesco.org/ark:/48223/pf0000394281 (português)

ZAMFIRESCU-PEREIRA, J. D.; WONG, Richmond Y.; HARTMANN, Bjoern; YANG, Qian. Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts. In: *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. Nova York: ACM, 2023, artigo 437, p. 1-21. DOI 10.1145/3544548.3581388. Disponível em: https://dl.acm.org/doi/10.1145/3544548.3581388

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
O que mudar quando o resultado volta errado

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **17 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**

ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)
PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.