IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



01

QUINZENA 6

DE ONDE VEM A DECISÃO QUE PARECE ÓBVIA

UNIVESP
Universidade Virtual do Estado de São Paulo

01

QUINZENA 6

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

DE ONDE VEM A DECISÃO QUE PARECE ÓBVIA

INTRODUÇÃO

O QUE VOCÊ VAI ENCONTRAR AQUI

1. Uma previsão feita sobre você
2. Como o sistema aprende e o que ele aprende a medir
3. Quando a medida carrega uma desigualdade
4. Quem usa o sistema e quem recebe a decisão
5. Por que isso é um assunto de inteligência artificial
6. Referências, com endereço para conferir

ORIGEM DO MATERIAL

Primeiro texto de leitura da Quinzena 6. A organização didática vem da base pedagógica da disciplina e do *workshop* Fulbright realizado na Universidade de São Paulo (USP) em setembro de 2025. As evidências vêm de Chagas, Gomide e Santana (2025), de Obermeyer et al. (2019), de Lazer et al. (2014) e do artigo técnico de Covington, Adams e Sargin (2016). Dados conferidos na origem em 11 e 13 de setembro de 2026.

Uma universidade brasileira treinou um sistema de inteligência artificial para prever quais estudantes de engenharia iam abandonar o curso. Nenhum estudante foi entrevistado. O sistema recebeu os registros escolares de turmas anteriores e aprendeu a separar, com boa taxa de acerto, quem ficou de quem saiu. Este texto trata do que essa previsão mede e do que ela deixa de fora.

Um sistema de inteligência artificial aprende a partir de exemplos do passado e é isso que o torna diferente de um programa comum. Para aprender, ele precisa que uma pessoa diga o que conta como resposta certa em cada exemplo. **Essa escolha, feita por pessoas antes do treino, é o assunto deste texto: ela decide o que o sistema vai enxergar e o que vai ficar invisível para ele**.

No último texto de leitura da Quinzena 5, você mesmo aplicou um critério de verificação a um trabalho seu, com o relógio correndo. Uma pergunta ficou aberta ali: quando um critério desses passa a ser aplicado por um sistema, sobre muita gente de uma vez, a quem ele serve? A resposta começa por descobrir o que esse sistema mede.

1. UMA PREVISÃO FEITA SOBRE VOCÊ

Em 2025, três pesquisadores publicaram na *Revista Brasileira de Informática na Educação* um estudo sobre os cursos de Engenharia da Universidade Federal do Rio de Janeiro, no campus de Macaé (Chagas; Gomide; Santana, 2025). Pedro Andrietta Chagas, Janaína Sant'Anna Gomide e Laura Emmanuella Alves dos Santos Santana reuniram os registros acadêmicos guardados pela instituição e treinaram, com esses dados, programas de previsão de três tipos diferentes. A pergunta deles era direta: dá para saber, logo no começo, quem vai abandonar o curso?

Abandonar o curso, no vocabulário das universidades, chama-se evasão. É o estudante que para de renovar a matrícula e não volta. O estudo mostrou que o desempenho acadêmico do primeiro período basta para separar quem evadiu de quem permaneceu, e que as disciplinas Cálculo e Física pesam mais nessa separação. A análise dos dados trouxe, ainda, dois resultados que incomodam: naquele conjunto de cursos, mais estudantes abandonaram do que se formaram, e 75% das desistências aconteceram nos três primeiros semestres. Para dizer quanto um programa de previsão acerta, os autores usam uma nota chamada AUC, explicada no quadro a seguir.

PRIMEIRA VEZ AQUI

AUC é a nota que mede o quanto um sistema de previsão separa dois grupos. Na prática, ela fica entre 0,5 e 1: em 0,5 o sistema acerta o mesmo que uma moeda jogada para o alto e em 1 ele separa os dois grupos sem errar nenhum caso. A sigla vem do inglês *area under the curve*, o nome da área sob uma curva que compara os acertos com os alarmes falsos.

No estudo de Chagas, Gomide e Santana (2025), o melhor dos três programas chegou a uma AUC de 0,80, o que indica separação boa, com erro em parte das pessoas. Essa nota mede uma coisa específica: a capacidade de separar dois grupos que já existiam, com dados de quem passou por aquela universidade em anos anteriores. Ela não explica por que alguém saiu. Não sabe quem trabalhava em dois turnos nem quem ficou três meses sem internet em casa. Na prática, o resultado do sistema é uma lista: os calouros ordenados do maior para o menor risco de abandonar o curso.

Muita gente sente um incômodo ao saber que uma lista dessas existe. O incômodo é um bom ponto de partida e ainda não chega a ser um argumento. Julgar com

critério pede três respostas: o que exatamente o sistema decide, sobre quem ele decide, e o que muda na vida dessa pessoa depois da decisão. No caso do estudo, as respostas seriam: ele ordena estudantes por risco estimado de evasão, decide sobre calouros, e o efeito depende inteiramente do que a instituição faz com a lista que recebe.

O incômodo aponta o lugar onde olhar.
O critério explica o que está acontecendo ali.

Se uma previsão dessas existir no seu curso, a pergunta útil é outra: o que foi medido para chegar até ela?

2. COMO O SISTEMA APRENDE E O QUE ELE APRENDE A MEDIR

O QUE ACONTECE NO TREINO

Na Quinzena 1 desta disciplina, você viu a diferença entre um programa de computador comum e um sistema de inteligência artificial. O programa comum segue regras que uma pessoa escreveu: se a compra passa de cem reais, o frete sai de graça. O sistema de inteligência artificial recebe muitos exemplos já resolvidos e procura, sozinho, o padrão que liga cada exemplo à sua resposta. Essa forma de aprender tem nome: **aprendizado supervisionado**, porque alguém precisa preparar os exemplos com a resposta certa ao lado.

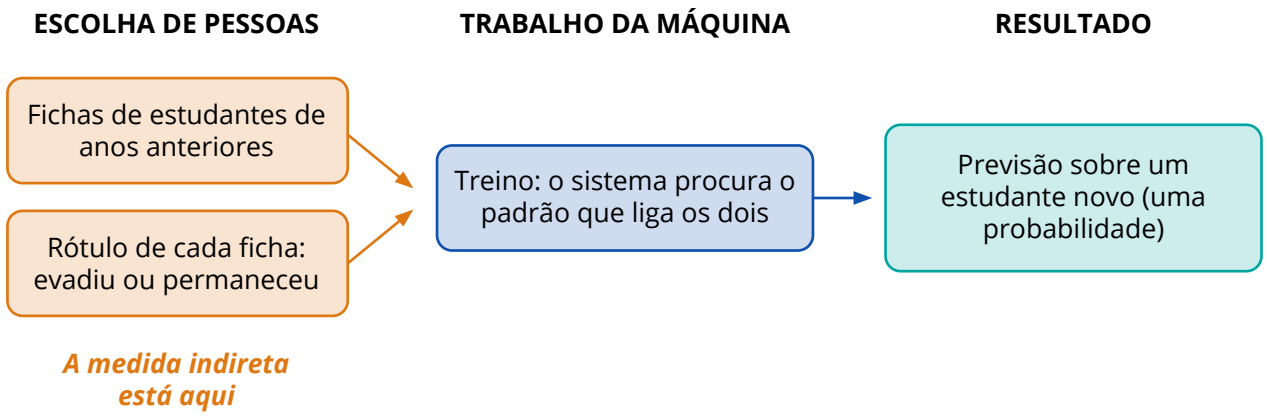
No estudo de Macaé (Chagas; Gomide; Santana, 2025), os exemplos eram fichas de estudantes de anos anteriores, com as notas e as disciplinas cursadas. A resposta certa, em cada ficha, era uma palavra só: esse estudante evadiu ou esse estudante permaneceu. Com milhares de fichas assim, o sistema ajusta os números internos da fórmula que usa até acertar a maior parte das respostas que recebeu. Um programa ajustado desse jeito ganha um nome curto na área: **modelo**. Terminado o treino, o modelo passa a ler a ficha de um estudante novo e devolver um número entre 0 e 1, que é a chance estimada de esse estudante abandonar o curso.

PRIMEIRA VEZ AQUI

Rótulo é a resposta certa que acompanha cada exemplo usado no treino. Numa caixa de *e-mail*, o rótulo é a marca *spam* ou não *spam* que alguém colocou. No estudo de Macaé, o rótulo é evadiu ou permaneceu. O sistema aprende a reproduzir o rótulo que recebeu, seja ele qual for.

Duas escolhas antecedem qualquer treino, e as duas são feitas por pessoas. A primeira é quais informações entram nas fichas. A segunda é qual rótulo será usado como resposta certa. Depois dessas duas escolhas, o trabalho do sistema é mecânico: ele procura o padrão que liga as informações ao rótulo. A figura seguinte mostra onde cada escolha entra.

Figura 1. O caminho do treino até a previsão, com as duas escolhas feitas por pessoas marcadas em destaque.



O sistema aprende a reproduzir o rótulo que recebeu. Quando o rótulo mede outra coisa, a previsão sai fiel a essa outra coisa.

O NOME DA TROCA: MEDIDA INDIRETA

Repare no que aconteceu com o rótulo do estudo. A instituição gostaria de saber quem precisa de apoio para continuar. Isso não está escrito em lugar nenhum e não existe registro com esse nome. O que existe guardado é o histórico escolar e a situação da matrícula. Então o rótulo passou a ser a evasão registrada no sistema acadêmico, e o sistema aprendeu a prever esse registro. Uma pergunta foi trocada por outra: no lugar de “quem precisa de apoio” entrou “quem tem evasão registrada”. Essa troca tem nome.

CONCEITO-CHAVE

Medida indireta é aquilo que um sistema mede quando o que interessa não pode ser medido diretamente. Em inglês, a literatura técnica chama essa medida de *proxy*. Feita a troca, o sistema decide com base na medida substituta e leva para a decisão todas as diferenças que existem entre ela e a pergunta original.

A troca acontece o tempo todo, dentro e fora da tecnologia. Um professor mede aprendizagem por prova. Uma empresa mede satisfação do cliente por nota no aplicativo. Um plano de saúde mede risco por idade. Em cada caso existe uma distância entre a pergunta original e a medida escolhida, e é nessa distância que os problemas aparecem. Num sistema de inteligência artificial a troca fica mais séria por um motivo: a medida escolhida vira o rótulo do treino e o sistema não tem como saber que ela era apenas um substituto.

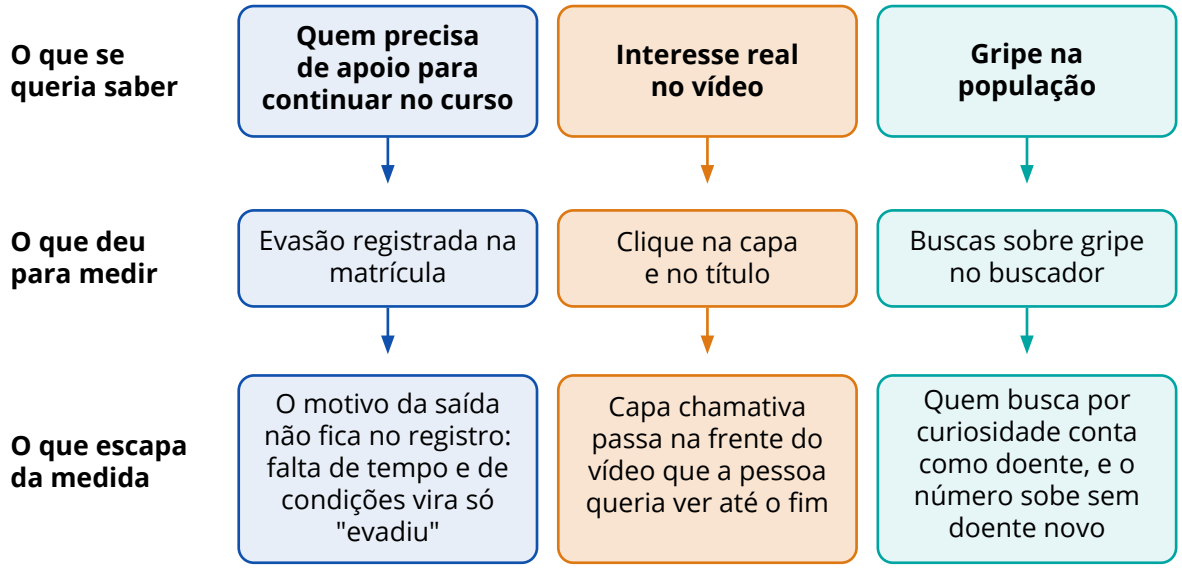
A plataforma de vídeo que você abre todo dia enfrenta esse mesmo problema. Não existe um sensor que meça se a pessoa gostou do vídeo, e ninguém preenche formulário depois de assistir. O clique, ao contrário, fica registrado. Em 2016, três engenheiros da equipe de recomendação do YouTube publicaram um artigo técnico (Covington; Adams; Sargin, 2016) em que escreveram, com todas as letras, que ordenar vídeos pela taxa de cliques costuma promover vídeos enganosos, aqueles que a pessoa abre e não termina de assistir. Por isso passaram a usar outro rótulo: o tempo que a pessoa realmente passa assistindo ao vídeo.

Quem contou essa história foi a própria equipe que construiu o sistema, num artigo público. A escolha do rótulo costuma estar escrita em linguagem técnica e quase nunca chega a quem assiste aos vídeos.

Outro caso ficou conhecido porque o erro apareceu em público. Em 2008 o Google lançou o Google Flu Trends, nome em inglês que significa “tendências de gripe do Google”: uma ferramenta que estimava a quantidade de gripe na população dos Estados Unidos a partir das buscas feitas no buscador. A ideia parecia boa, porque quem tem sintoma costuma pesquisar sintoma. Em fevereiro de 2013 a estimativa passou do dobro da medida oficial dos centros de controle de doenças dos Estados Unidos, o CDC. Ao analisar o caso na revista Science, Lazer *et al*. (2014) mostraram que a ferramenta vinha estimando gripe demais em 100 das 108 semanas anteriores. Eles apontaram duas causas. A primeira foi tratar o grande volume de dados como substituto da coleta feita por médicos e hospitais. A segunda foi o próprio buscador, que mudava ao longo do tempo: o Google passou a sugerir termos durante a digitação, e isso alterou o que as pessoas pesquisavam.

Nesse caso a troca não estava no rótulo, e sim na outra escolha da Figura 1, a das informações de entrada: a busca ficou no lugar do doente. A medida indireta pode entrar por qualquer uma das duas portas.

Figura 2. A mesma troca em três sistemas: a pergunta que interessava, a medida que ficou no lugar dela e o que escapa dessa medida.



Em cada caso, o sistema decide pela medida do meio. A pergunta de cima fica sem resposta direta.

Para você, isso pode virar um hábito de leitura. Quando alguém disser que um sistema mede engajamento, produtividade ou risco, procure a frase seguinte: com o que ele mede isso? A resposta costuma ser um dado simples, escolhido porque já estava disponível.

3. QUANDO A MEDIDA CARREGA UMA DESIGUALDADE

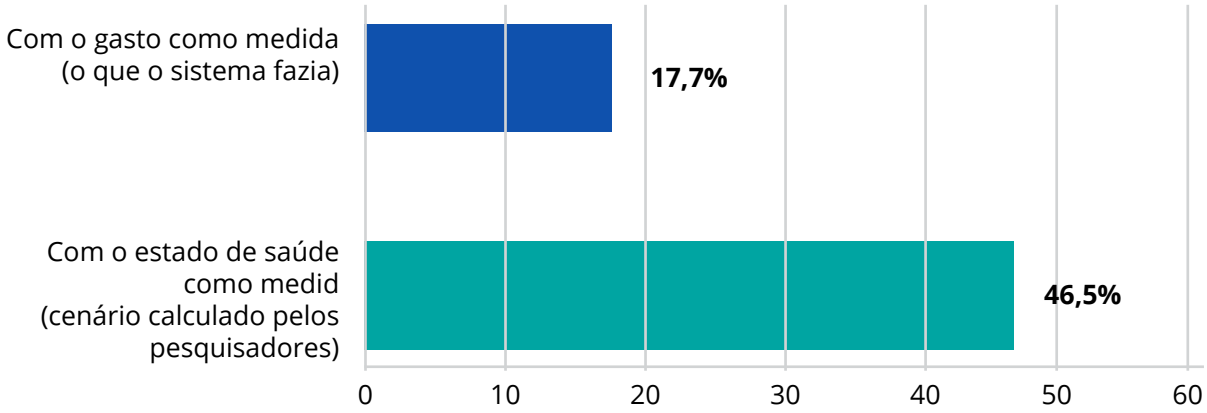
Até aqui a troca de medida aparece como um problema de precisão, do tipo que se corrige com um ajuste técnico. O caso seguinte mostra a outra face do problema, que é mais séria.

Em 2019, quatro pesquisadores publicaram na revista Science o resultado de uma investigação sobre um sistema usado em hospitais dos Estados Unidos (Obermeyer *et al.*, 2019). Ele servia para escolher quem entraria em programas de cuidado extra, aqueles que dão acompanhamento mais próximo a pacientes com doenças de longa duração, como diabetes e insuficiência cardíaca. Para ordenar os pacientes, o sistema tinha sido treinado para prever um número que parecia razoável: quanto aquele paciente gastaria em saúde no ano seguinte. Quem gastaria mais foi tratado como quem precisaria de mais cuidado. Obermeyer *et al.* (2019) compararam pacientes com o mesmo nível de doença e encontraram um padrão que ninguém tinha programado: pacientes negros precisavam estar mais doentes do que pacientes brancos para receber a mesma pontuação.

O mecanismo dessa distorção é simples de acompanhar. Gasto em saúde mede o dinheiro que passou pelo sistema de saúde, e esse dinheiro só existe quando a pessoa consegue chegar ao atendimento. Quem mora longe de um hospital, quem tem plano pior ou quem falta ao médico por causa do trabalho gasta menos, mesmo estando mais doente. Ao aprender com o rótulo do gasto, o sistema aprendeu também a desigualdade de acesso que existia antes dele, e passou a repeti-la na fila de atendimento.

Os pesquisadores refizeram a conta com um rótulo diferente, construído a partir do estado de saúde do paciente. Com essa troca, a proporção de pacientes negros entre os encaminhados ao cuidado extra subiria de 17,7% para 46,5%. Este segundo número descreve um cenário calculado pelos autores dentro dos dados que tinham. A mudança não chegou a ser aplicada no hospital e medida depois. O artigo também registra que sistemas desse tipo alcançavam cerca de 200 milhões de pessoas por ano nos Estados Unidos.

Figura 3. O efeito da escolha do rótulo no programa de cuidado extra, com o critério em uso e com o critério recalculado pelos autores.
Fonte: Obermeyer et al. (2019).



Pacientes negros entre os encaminhados para o programa de cuidado extra

⚠ PONTO CRÍTICO

Escolher uma medida indireta é comum e, em muitos casos, é a única saída disponível. Medir gasto é legítimo para quem cuida do orçamento de um hospital. O erro aparece quando o resultado dessa medida é lido como resposta a outra pergunta e ninguém verifica quem ficou de fora por causa da troca.i

Volte ao estudo brasileiro com essa lente. No hospital, a desigualdade entrou pelo rótulo. No estudo de Macaé, ela pode entrar pela outra escolha, a das informações da ficha. A nota do primeiro período também carrega o que aconteceu fora da sala de aula: quantas horas a pessoa trabalhou, que conexão ela tinha em casa, quantas vezes precisou escolher entre a prova e o plantão. Ao ordenar por desempenho, o sistema ordena, em parte, por condições de vida. Os autores do estudo não fazem essa afirmação, e a conclusão deles trata de padrões acadêmicos. Ler o resultado como medida de esforço ou de capacidade seria ir além do que o estudo permite dizer.

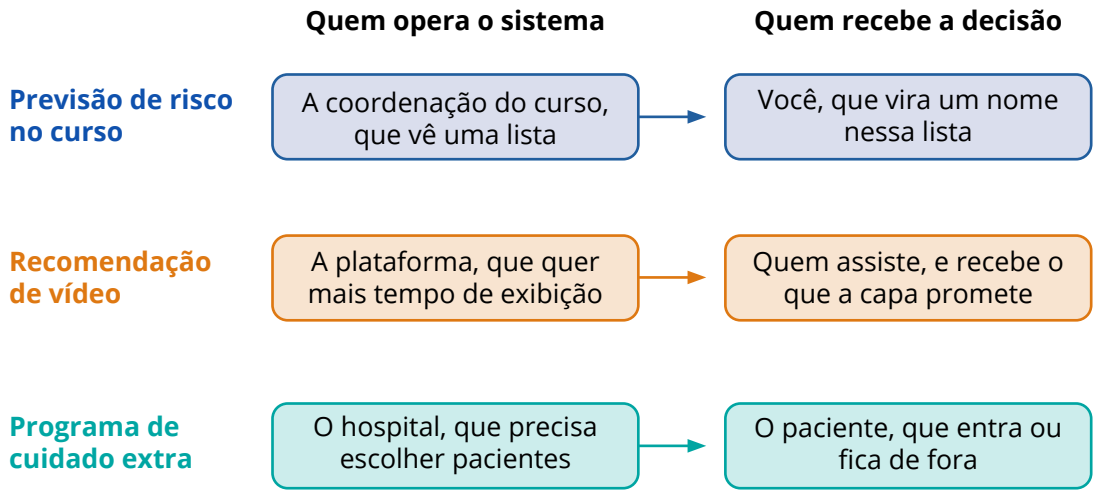
Uma medida escolhida por conveniência carrega junto a desigualdade que já existia antes dela.

No seu curso, isso muda a pergunta que você faz diante de qualquer número sobre você: o que esse número mediu e o que ele deixou de fora?

4. QUEM USA O SISTEMA E QUEM RECEBE A DECISÃO

Nos quatro casos deste texto as pessoas ocupam duas posições bem diferentes. De um lado está quem opera o sistema e decide o que fazer com o resultado. Do outro lado está quem recebe a decisão. A disciplina chama o primeiro de **usuário** e o segundo de **afetado**. Quase nunca são a mesma pessoa, e quem recebe a decisão raramente escolheu estar ali.

Figura 4. Quem opera o sistema e quem recebe a decisão, em três dos casos tratados neste texto.



A diferença entre as duas posições tem efeito prático. Quem opera vê uma lista, um painel, uma média, e um erro aparece como um caso entre muitos. Quem recebe a decisão lê uma frase sobre si: você está no grupo de risco, seu pedido foi negado. Para essa pessoa, o erro tem nome e data.

Dentro do grupo dos afetados também existe diferença. Uma previsão de risco pode chegar ao estudante como convite para monitoria e ajuste de matrícula. Pode também chegar como uma etiqueta que segue a pessoa pelo curso inteiro, repetida a cada semestre. Quem recebe a primeira versão sai ganhando com o sistema. Quem recebe a segunda carrega uma decisão da qual não participou.

ATENÇÃO, ISTO É SOBRE VOCÊ

Se um sistema fizer uma previsão sobre o seu percurso, três perguntas cabem na primeira conversa com a coordenação ou com o facilitador: qual informação foi usada, de que período ela vem e o que acontece com a previsão depois de pronta. Nenhuma das três exige conhecimento técnico.

Ao longo do semestre você vai ocupar as duas posições. Quando usar uma ferramenta para decidir alguma coisa que envolve outras pessoas, como dividir tarefas num trabalho de grupo, você passa para a posição de quem opera. A mesma pergunta continua valendo, agora dirigida a você: o que exatamente eu estou medindo?

5. POR QUE ISSO É UM ASSUNTO DE INTELIGÊNCIA ARTIFICIAL

Escolher uma medida no lugar de outra é um problema antigo, anterior ao computador. Três características dos sistemas de inteligência artificial mudam o tamanho desse problema.

A primeira é que o sistema aprende do passado. Um sistema de inteligência artificial recebe o registro do que aconteceu antes e procura o padrão que se repete ali. Quando o passado inclui desigualdade de acesso, como no caso do hospital, ela entra no padrão junto ao resto e passa a orientar decisões futuras.

A segunda é a escala. Uma pessoa que decide caso a caso erra caso a caso. Um sistema treinado aplica o mesmo critério a milhares de pessoas por dia, sempre da mesma forma. O estudo do hospital (Obermeyer *et al*., 2019), citado na seção 3, diz que sistemas daquele tipo alcançavam cerca de 200 milhões de pessoas por ano, e esse número mostra por que a escolha do rótulo deixa de ser um detalhe técnico.

A terceira é que a escolha desaparece dentro do produto. Quem recebe a decisão vê uma tela com um resultado. A frase que diz qual rótulo foi usado no treino costuma ficar num artigo técnico ou em nenhum lugar. O estudo de Macaé (Chagas; Gomide; Santana, 2025), publicado em revista científica, deixa essa escolha visível, e essa transparência é exceção.

Nenhum dos quatro casos deste texto tem vilão. A equipe do buscador queria acompanhar a gripe mais depressa do que a rede de saúde conseguia, e a equipe

da plataforma de vídeo queria recomendar o que as pessoas de fato assistem. A equipe do hospital precisava escolher pacientes com algum critério, e os pesquisadores do estudo brasileiro queriam entender a evasão para preveni-la. Em todos, a medida foi escolhida porque estava disponível e parecia razoável na hora.

Dano sem má intenção continua sendo dano e continua tendo alguém responsável por ele.

A responsabilidade continua existindo e é possível dizer de quem ela é: de quem escolheu o rótulo, de quem decidiu usar aquele resultado numa situação concreta e de quem tinha o dever de verificar quem ficou de fora. Reconhecer a medida indireta que está em jogo, com as suas palavras, é uma das competências que esta disciplina espera de você, e ela não depende de saber programar.

Este texto trata do primeiro passo, que é enxergar a medida. O passo seguinte é olhar o sistema inteiro e perguntar, de forma organizada, quem é afetado por ele, se essas pessoas sabem que existe um sistema decidindo, quem responde quando ele erra e quanto custa mantê-lo em operação. Essas quatro perguntas são o assunto do próximo texto de leitura desta quinzena.

PARA REFLEXÃO

Pense em um sistema que já decidiu alguma coisa sobre você neste ano: uma triagem de currículo, uma recomendação, uma análise de cadastro, uma nota automática. Escreva em uma linha qual rótulo ele provavelmente usou no treino, no lugar daquilo que dizia medir. Depois escreva o nome de uma pessoa, real ou imaginada, que essa escolha deixaria de fora.

6. REFERÊNCIAS

As obras abaixo dão base ao texto e podem ser localizadas nos endereços indicados. Quando o acesso ao texto integral depende de pagamento, isso está dito na entrada.

CHAGAS, P. A.; GOMIDE, J. S.; SANTANA, L. E. A. S. Previsão do risco de evasão universitária utilizando aprendizado de máquina: características e dinâmica da evasão nos cursos de Engenharia da UFRJ-Macaé. **Revista Brasileira de Informática na Educação**, v. 33, p. 1226-1247, 2025. Disponível em: https://journals-sol.sbc.org.br/index.php/rbie/article/view/5196/3470. Acesso em: 16 set. 2026.

COVINGTON, P.; ADAMS, J.; SARGIN, E. Deep neural networks for YouTube recommendations. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS., 10. 2016, Boston. **Anais** [...]. Boston: ACM, 2016. p. 191-198. Disponível em: https://dl.acm.org/doi/pdf/10.1145/2959100.2959190. Acesso em: 16 set. 2026.

LAZER, D.; KENNEDY, R.; KING, G.; VESPIGNANI, A. The parable of Google Flu: traps in big data analysis. **Science**, v. 343, n. 6176, p. 1203-1205, 14 mar. 2014. Acesso restrito. Disponível em: https://www.science.org/doi/10.1126/science.1248506. Acesso em: 16 set. 2026.

OBERMEYER, Z.; POWERS, B.; VOGELI, C.; MULLAINATHAN, S. Dissecting racial bias in an algorithm used to manage the health of populations. **Science**, v. 366, n. 6464, p. 447-453, 2019. Acesso restrito. Disponível em: https://www.science.org/doi/10.1126/science.aax2342. Acesso em: 16 set. 2026.

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
De onde vem a decisão que parece óbvia

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **15 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**

ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)
PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.